

Proyecto Final — Regresión Avanzada

Análisis Bayesiano Espacial de PM2.5 en el Valle de México

Paulina Garza Allende Andrea Monserrat Arredondo Rodríguez
Othoniel Reyes Camacho

19 de mayo de 2026

Índice

1. Introducción	1
2. Descripción de la información	3
3. Modelado e implementación	8
3.1. Modelo A — Normal global	8
3.2. Modelo B — Efectos fijos por estación	11
3.3. Modelo C1 — Jerárquico Normal	14
3.4. Modelo C2 — Gamma global	17
3.5. Modelo D — Tendencia espacial lineal	19
3.6. Modelo E — Proceso Gaussiano y Kriging Bayesiano	21
3.7. Modelo F — Espacio-Temporal Jerárquico	22
4. Interpretación de resultados	24
4.1. Comparación de modelos	24
4.2. Predicción espacial — Resultados del Modelo E	25
4.3. Resultados del Modelo F	28
5. Referencias	35
A. Código fuente	36

1. Introducción

El Valle de México es una cuenca hidrológica cerrada que alberga la Zona Metropolitana del Valle de México (ZMVM), con aproximadamente 22 millones de habitantes. Su geometría de cuenca cerrada impide la ventilación natural de los contaminantes, lo que convierte al

PM2.5 (material particulado fino con diámetro aerodinámico $\leq 2.5 \mu\text{m}$) en uno de los principales problemas de salud pública de la región. La exposición crónica a PM2.5 está asociada con enfermedades respiratorias, cardiovasculares y aumento en la mortalidad.

La fuente de datos es el Sistema Nacional de Información de la Calidad del Aire (SINAI-CA), operado por el Instituto Nacional de Ecología y Cambio Climático (INECC, s.f.). Se descargaron datos de las 56 estaciones de monitoreo ubicadas dentro de los límites del Valle de México (16 alcaldías de la CDMX, 59 municipios del Estado de México, más Tizayuca en Hidalgo). De estas, solo 14 estaciones reportaron simultáneamente concentración de PM2.5, temperatura y humedad relativa durante 2023, con un total de 2,617 observaciones diarias (enero–diciembre de 2023).

La pregunta central de este proyecto es:

¿Qué tan importante es la estructura espacial para explicar la variación de PM2.5 en el Valle de México, y podemos usarla para predecir la contaminación en zonas sin sensores?

Para responderla se ajustan seis modelos bayesianos de complejidad creciente en JAGS a través del paquete `R2jags` (Plummer, 2003; R Core Team, 2025):

1. **Modelo A — Normal global:** ¿cuánto de la variación de PM2.5 explican el clima y la estacionalidad, sin considerar la ubicación?
2. **Modelo B — Efectos fijos:** ¿existen diferencias sistemáticas entre estaciones que no se explican por clima?
3. **Modelo C1 — Jerárquico:** ¿es mejor modelar esas diferencias como un proceso aleatorio común con encogimiento (*shrinkage*) que como parámetros independientes?
4. **Modelo C2 — Gamma:** ¿es la distribución Gamma, que respeta el soporte positivo de PM2.5, mejor que la Normal sobre el logaritmo?
5. **Modelo D — Tendencia lat/lon:** ¿captura un gradiente lineal en latitud y longitud el patrón espacial, o se necesita un modelo no lineal?

El **Modelo E** usa los efectos espaciales del Modelo C1 para hacer kriging bayesiano y predecir PM2.5 en los 141 polígonos del Valle de México (Global Administrative Areas, s.f.), incluyendo los 44 municipios de Edomex sin estaciones de monitoreo.

Finalmente, el **Modelo F — Espacio-Temporal Jerárquico** integra ambas dimensiones en un marco unificado: ajusta un panel balanceado 365×14 donde los valores faltantes se imputan directamente como variables latentes dentro del muestreador MCMC, la estructura espacial entre estaciones se modela mediante una Normal Multivariada con kernel exponencial, y una segunda etapa de agregación jerárquica estima la tendencia macro-ambiental diaria de la ZMVM con propagación explícita de la incertidumbre de la primera etapa.

2. Descripción de la información

Variables

Cuadro 1: Variables utilizadas en el análisis.

Variable	Descripción	Rol	Escala
pm25	Concentración diaria promedio de PM2.5 ($\mu\text{g}/\text{m}^3$)	Respuesta	Razón
temp	Temperatura diaria promedio ($^{\circ}\text{C}$)	Covariable meteorológica	Intervalo
hr	Humedad relativa diaria promedio (%)	Covariable meteorológica	Intervalo
sen_t	$\sin(2\pi \cdot \text{día}/365)$	Covariable estacional (Fourier)	Intervalo
cos_t	$\cos(2\pi \cdot \text{día}/365)$	Covariable estacional (Fourier)	Intervalo
lat, lon	Coordenadas geográficas de la estación	Predictor espacial	Intervalo
estación	Nombre de la estación de monitoreo	Agrupador	Nominal

La temperatura y la humedad relativa se estandarizaron (media 0, desviación estándar 1) antes de ingresarlas a JAGS, para mejorar la convergencia del MCMC y hacer comparables las magnitudes de los coeficientes. PM2.5 se transforma a escala logarítmica en todos los modelos Normal (A, B, C1, D), lo que estabiliza la varianza y linealiza la relación con las covariables. Los términos de Fourier sen_t y cos_t capturan el ciclo anual de la contaminación mediante una suma armónica de un solo par de frecuencias, suficiente para describir la estacionalidad predominante observada en los datos.

Estaciones de monitoreo

Cuadro 2: Resumen por estación (datos 2023, $n = 2,617$ observaciones totales).

Estación	Municipio	n	Temp. (°C)	HR (%)	PM2.5 ($\mu\text{g}/\text{m}^3$)
Santiago Acahualtepec	Iztapalapa	189	17.4	46.4	23.5
Hospital General México	Cuauhtémoc	52	19.2	33.1	22.7
Gustavo A. Madero	G. A. Madero	154	19.4	45.2	22.7
Tlalnepantla	Tlalnepantla	174	18.5	41.9	21.8
San Agustín	Ecatepec	84	19.9	49.5	20.7
UAM Iztapalapa	Iztapalapa	207	19.7	49.5	20.6
Merced	Venustiano C.	235	20.0	47.8	20.6
UAM Xochimilco	Coyoacán	233	17.5	48.2	20.5
Nezahualcóyotl	Nezahualcóyotl	218	19.5	43.9	20.4
Benito Juárez	Benito Juárez	236	19.2	45.3	19.8
FES Aragón	Nezahualcóyotl	233	20.1	48.0	18.0
Pedregal	Álvaro Obregón	181	17.2	49.7	16.2
Ajusco Medio	Tlalpan	188	14.5	55.2	16.0
Biblioteca	Tizayuca	233	14.5	50.9	15.4

El rango de concentraciones promedio entre estaciones va de $15.4 \mu\text{g}/\text{m}^3$ (Biblioteca, Tizayuca) a $23.5 \mu\text{g}/\text{m}^3$ (Santiago Acahualtepec, Iztapalapa), una diferencia de 52 % entre la estación más limpia y la más contaminada. Todas las estaciones superan la guía de la Organización Mundial de la Salud (OMS, 2021) de $5 \mu\text{g}/\text{m}^3$ para el promedio anual.

Análisis exploratorio




Figura 1: Histogramas de las variables principales. La distribución de PM2.5 tiene cola de-
 recha pronunciada; en escala logarítmica se aproxima más a la Normal, lo que justifica la
 transformación utilizada en los modelos.




Figura 2: $\log(\text{PM}_{2.5})$ en función de temperatura, humedad relativa y día del año. La línea lowess muestra la tendencia suavizada. La relación con temperatura es positiva; con humedad relativa, también positiva dentro de cada estación; con el tiempo, se observa un mínimo estival seguido de un repunte en agosto–septiembre que coincide con el final de la temporada de lluvias.




Figura 3: $\text{PM}_{2.5}$ en función de temperatura, humedad y día del año, coloreado por entidad federativa (CDMX, Estado de México, Hidalgo). La heterogeneidad espacial visible entre grupos motiva la inclusión de efectos por estación en los modelos.




Figura 4: PM_{2.5} por estación, ordenadas de menor a mayor concentración media. La línea punteada roja marca el promedio global ($\approx 19.7 \mu\text{g}/\text{m}^3$). Se observan diferencias claras entre estaciones, especialmente en los extremos: Ajusco Medio y Biblioteca tienen niveles sistemáticamente menores que Santiago Acahualtepec y Gustavo A. Madero.




Figura 5: PM2.5 por mes. Se aprecia un máximo en invierno (enero–marzo), un mínimo en verano (junio–julio) y un repunte en agosto–septiembre, patrón que motiva el uso de términos de Fourier en la especificación del modelo.




Figura 6: Matriz de correlación de las variables. PM2.5 está más correlacionado con `sen.t` ($r = 0.48$) y con `cos.t`, lo que confirma la importancia de la estacionalidad. La correlación con temperatura y humedad es moderada.

3. Modelado e implementación

Configuración general

Todos los modelos se ajustaron en JAGS con dos cadenas de Markov, partiendo de valores iniciales distintos para verificar convergencia. Las distribuciones iniciales son poco informativas: $\mathcal{N}(0, 1000)$ para los coeficientes (varianza 1,000, equivalente a la precisión $\tau = 0.001$ en notación JAGS) y $\text{Ga}(0.001, 0.001)$ para las precisiones.

La convergencia se evalúa mediante seis paneles por parámetro: traza de ambas cadenas (patrón tipo “oruga” indica buena mezcla), promedio ergódico (debe estabilizarse al mismo valor en ambas cadenas), histogramas de la distribución final en cada cadena (deben coincidir) y función de autocorrelación (ACF, debe caer rápidamente a cero).

Criterio de información de la desvianza (DIC). Para comparar modelos dentro de una misma familia distribucional se usa el DIC (Lunn et al., 2013), definido como

$$\text{DIC} = \bar{D} + p_D = 2\bar{D} - D(\bar{\theta}),$$

donde $\bar{D} = E_{\theta|\mathbf{y}}[-2 \log f(\mathbf{y}|\theta)]$ es la deviance media posterior, $D(\bar{\theta})$ es la deviance evaluada en la media posterior, y $p_D = \bar{D} - D(\bar{\theta})$ es el número efectivo de parámetros. Modelos con DIC menor son preferibles; diferencias > 10 puntos son consideradas sustanciales. El DIC sólo es comparable entre modelos con idéntica variable respuesta y familia distribucional.

Pseudo- R^2 y significancia. El pseudo- R^2 se define como el cuadrado de la correlación entre los valores observados y los predichos a posteriori:

$$R^2 = [\text{Corr}(y_i, \hat{y}_i)]^2,$$

donde $\hat{y}_i = E[Y_i|\mathbf{y}]$ es la media de la distribución final predictiva.

La significancia de los coeficientes se evalúa mediante el intervalo de credibilidad al 95 %: si el intervalo no contiene el cero, el parámetro es considerado significativo. Como medida complementaria se reporta

$$p(\beta_k) = \min(P(\beta_k > 0), P(\beta_k < 0)),$$

donde valores cercanos a 0 indican que toda la masa de la distribución final se concentra en un solo signo (el parámetro es claramente distinto de cero).

3.1. Modelo A — Normal global

El Modelo A es la línea base. Ignora por completo la ubicación geográfica y modela $\log(\text{PM2.5})$ exclusivamente con clima y estacionalidad:

$$\log(\text{PM2.5}_i) \sim \mathcal{N}(\mu_i, \tau^{-1}), \quad \mu_i = \alpha + \beta_1 \text{temp}_i + \beta_2 \text{hr}_i + \beta_3 \text{sen_t}_i + \beta_4 \text{cos_t}_i. \quad (1)$$

Las distribuciones iniciales son:

$$\alpha \sim \mathcal{N}(0, 1000), \quad \beta_k \sim \mathcal{N}(0, 1000) \quad (k = 1, \dots, 4), \quad \tau \sim \text{Ga}(0.001, 0.001).$$

Se corrieron 10,000 iteraciones con 1,000 de calentamiento y sin adelgazamiento, con 9,000 muestras activas por cadena.

Diagnóstico




Figura 7: Diagnósticos del Modelo A para el intercepto α . La traza muestra el patrón de “oruga” característico de buena mezcla; el promedio ergódico de ambas cadenas converge al mismo valor; los histogramas de la distribución final son idénticos; la ACF cae a cero desde el rezago 1. El mismo comportamiento se observa para $\beta_1, \dots, \beta_4$ y σ .

Resultados

Cuadro 3: Media de la distribución final del Modelo A.

Parámetro	Media
Intercepto α (log-PM2.5 global promedio)	2.819
β_1 : cambio en log-PM2.5 por 1-DE de temperatura	0.096
β_2 : cambio en log-PM2.5 por 1-DE de humedad relativa	0.031
β_3 : amplitud seno del patrón estacional (sen_t)	0.351
β_4 : amplitud coseno del patrón estacional (cos_t)	0.172
Desviación estándar residual $\sigma = 1/\sqrt{\tau}$	0.424
DIC	2 942.6
Pseudo- R^2	0.313

El intercepto $\hat{\alpha} = 2.819$ corresponde a un PM2.5 esperado de $e^{2.819} \approx 16.8 \mu\text{g}/\text{m}^3$ cuando todas las covariables están en sus valores medios. El coeficiente de temperatura ($\hat{\beta}_1 = 0.096$) indica que por cada unidad de desviación estándar adicional en temperatura (equivalente a $\approx 2.1^\circ\text{C}$), la concentración esperada de PM2.5 aumenta en $e^{0.096} \approx 1.10$, es decir un 10 %. En el contexto del Valle de México, esto refleja que los días más cálidos dentro de una misma temporada tienden a ser más secos y con menor dilución de contaminantes por lluvias.

Los términos de Fourier describen un ciclo anual con amplitud $\sqrt{0.351^2 + 0.172^2} \approx 0.39$ log-unidades, equivalente a una variación de $\pm 38\%$ alrededor de la media estacional. El máximo de la función estacional ocurre alrededor del día 58 (fines de febrero), correspondiente al final de la temporada seca e inicio de la temporada de incendios forestales.

El Modelo A explica el 31.3 % de la variación total de log-PM2.5 (pseudo- $R^2 = 0.313$).




Figura 8: Observado vs. predicho en escala log para el Modelo A. La dispersión considerable alrededor de la diagonal indica que el modelo global no captura las diferencias sistemáticas entre estaciones.

3.2. Modelo B — Efectos fijos por estación

El Modelo B agrega a la ecuación (1) un efecto fijo α_j por cada estación:

$$\log(\text{PM2.5}_i) \sim \mathcal{N}(\mu_i, \tau^{-1}), \quad \mu_i = \tilde{\alpha} + \tilde{\alpha}_{j[i]} + \beta_1 \text{temp}_i + \beta_2 \text{hr}_i + \beta_3 \text{sen_t}_i + \beta_4 \text{cos_t}_i, \quad (2)$$

donde $\tilde{\alpha} = \alpha + \overline{\alpha_j}$ y $\tilde{\alpha}_j = \alpha_j - \overline{\alpha_j}$ son los ajustes de suma-cero aplicados post-muestreo para garantizar identificabilidad. Cada efecto tiene distribución inicial independiente: $\alpha_j \sim \mathcal{N}(0, 1000)$.

Se corrieron 12,000 iteraciones con 2,000 de calentamiento y adelgazamiento de 2, con 5,000 muestras activas por cadena.

Diagnóstico




Figura 9: Diagnósticos del Modelo B para el intercepto α . Las cadenas muestran buena convergencia: traza estacionaria, promedios ergódicos que coinciden, histogramas de la distribución final idénticos y ACF que cae rápidamente.

Resultados

Cuadro 4: Distribución final de los coeficientes del Modelo B. IC: intervalo de credibilidad al 95 %. $p = \min(P(\beta_k > 0), P(\beta_k < 0))$: valores cercanos a 0 indican que el parámetro es claramente distinto de cero.

Parámetro	Media	IC 2.5 %	IC 97.5 %	p
β_1 (temp., 1-DE ≈ 2.1 °C)	0.1045	0.0665	0.1416	0.000
β_2 (humedad rel., 1-DE ≈ 7.8 pp)	0.0460	0.0159	0.0754	0.001
β_3 (sen.t, amplitud estacional)	0.3331	0.3028	0.3635	0.000
β_4 (cos.t, fase estacional)	0.2145	0.1708	0.2571	0.000
Intercepto ajustado $\tilde{\alpha}$				2.830
σ residual				0.406
DIC				2724.2
Pseudo- R^2				0.375

Al controlar por estación, la humedad relativa se vuelve significativa ($\hat{\beta}_2 = 0.046$, IC = [0.016, 0.075]). Esto se debe a que, en el Modelo A, la correlación de HR con la estación de monitoreo ocultaba parte del efecto real. Por cada unidad de desviación estándar en HR (≈ 7.8 puntos porcentuales adicionales), PM2.5 sube $e^{0.046} - 1 \approx 4.7$ %. El patrón estacional se mantiene: amplitud conjunta $\sqrt{0.333^2 + 0.215^2} \approx 0.397$ log-unidades.




Figura 10: Efectos fijos por estación $\tilde{\alpha}_j$ (ajuste suma-cero). Barras verticales son intervalos de credibilidad al 95 %. Valores positivos indican estaciones más contaminadas que el promedio global; negativos, menos contaminadas. Santiago Acahualtepec es la estación más contaminada (+0.26 log-unidades, equivalente a +29 %) y Biblioteca la más limpia (−0.28, equivalente a −24 %).

Cuadro 5: Efectos fijos por estación del Modelo B ($\tilde{\alpha}_j$, restricción suma-cero). Un factor $e^{\tilde{\alpha}_j}$ mayor que 1 indica una estación más contaminada que el promedio global.

Estación	$\tilde{\alpha}_j$	Factor ($e^{\tilde{\alpha}_j}$)
Santiago Acahualtepec	+0.258	1.29
Tlalnepantla	+0.143	1.15
Ajusco Medio	+0.073	1.08
UAM Xochimilco	+0.075	1.08
Benito Juárez	+0.048	1.05
Merced	+0.032	1.03
Nezahualcóyotl	+0.019	1.02
San Agustín	+0.016	1.02
Gustavo A. Madero	-0.040	0.96
UAM Iztapalapa	-0.045	0.96
Pedregal	-0.059	0.94
Hospital General México	-0.102	0.90
FES Aragón	-0.143	0.87
Biblioteca	-0.275	0.76

La mejora sobre el Modelo A es sustancial: $\Delta\text{DIC} = 2,942.6 - 2,724.2 = 218.4$ puntos, lo que indica que la estructura espacial tiene un efecto fuerte sobre PM2.5 que no es explicado por clima ni estacionalidad.

3.3. Modelo C1 — Jerárquico Normal

Fundamento teórico. El Modelo B trata los 14 efectos por estación como parámetros fijos e independientes. Sin embargo, si consideramos que las estaciones comparten una misma cuenca atmosférica y están sometidas a procesos de contaminación similares, resulta razonable suponer que sus efectos son *intercambiables* (de Finetti, 1937): la distribución conjunta de $(\alpha_1, \dots, \alpha_J)$ es invariante ante permutaciones. Bajo este supuesto, el teorema de representación de de Finetti garantiza que los efectos son condicionalmente independientes dado un parámetro común, lo que conduce naturalmente al modelo jerárquico.

Especificación. El Modelo C1 trata las diferencias entre estaciones como realizaciones de una distribución común, en lugar de parámetros fijos independientes:

$$\begin{aligned}
 \log(\text{PM2.5}_i) &\sim \mathcal{N}(\mu_i, \tau^{-1}), \\
 \mu_i &= \alpha + \alpha_{j[i]} + \beta_1 \text{temp}_i + \beta_2 \text{hr}_i + \beta_3 \text{sen_t}_i + \beta_4 \text{cos_t}_i, \\
 \alpha_j &\sim \mathcal{N}(0, \tau_\alpha^{-1}), \quad j = 1, \dots, 14.
 \end{aligned} \tag{3}$$

Aquí $\tau_\alpha = 1/\sigma_\alpha^2$ es la hiperprecisión que controla cuánto se permite que las estaciones se devíen del intercepto global α . Las distribuciones iniciales son:

$$\alpha \sim \mathcal{N}(0, 1000), \quad \beta_k \sim \mathcal{N}(0, 1000), \quad \tau \sim \text{Ga}(0.001, 0.001), \quad \tau_\alpha \sim \text{Ga}(0.001, 0.001).$$

El modelo jerárquico induce *encogimiento* (*shrinkage*): los efectos estimados para estaciones con pocas observaciones o con valores extremos son atraídos hacia el promedio global α , lo que reduce la varianza del estimador a costa de un pequeño sesgo.

Se corrieron 12,000 iteraciones con 2,000 de calentamiento y adelgazamiento de 2 (5,000 muestras activas por cadena).

Diagnóstico




Figura 11: Diagnósticos del Modelo C1: intercepto α (izq.) e hiperparámetro σ_α (der.). Ambos muestran convergencia satisfactoria. El mismo comportamiento se observa para $\beta_1, \dots, \beta_4$ y σ .

Resultados

Cuadro 6: Media de la distribución final del Modelo C1 (modelo preferido).

Parámetro	Media
Intercepto global α	2.830
β_1 (temperatura, 1-DE $\approx 2.1^\circ\text{C}$)	0.103
β_2 (humedad relativa, 1-DE ≈ 7.8 pp)	0.045
β_3 (sen_t)	0.334
β_4 (cos_t)	0.211
σ residual (variabilidad dentro de estación)	0.406
σ_α (variabilidad entre estaciones)	0.134
DIC	2723.7
Pseudo- R^2	0.375

El hiperparámetro $\hat{\sigma}_\alpha = 0.134$ resume la variabilidad entre estaciones: el 68 % de las estaciones se desvía menos de ± 0.134 log-unidades del promedio global, lo que en escala multiplicativa equivale a ± 14 %. El 95 % se desvía menos de ± 0.268 log-unidades (± 31 %). Este valor es sustancial en un contexto de salud pública: dos habitantes del Valle de México, uno en la estación más contaminada y otro en la más limpia, están expuestos a concentraciones que difieren en un factor de $e^{0.134 \times 4} \approx 1.71$, es decir 71 % más en la zona más contaminada.




Figura 12: Efectos aleatorios por estación α_j del Modelo C1. Barras verticales son intervalos de credibilidad al 95 %. Comparado con el Modelo B (Fig. 10), los efectos son ligeramente más pequeños debido al encogimiento jerárquico hacia la media global. El orden relativo de las estaciones se preserva.

Cuadro 7: Efectos aleatorios por estación del Modelo C1 (α_j). IC al 95 %.

Estación	Media	DE	IC 95 %
Santiago Acahualtepec	+0.243	0.047	[+0.151, +0.334]
Tlalnepantla	+0.133	0.047	[+0.041, +0.225]
UAM Xochimilco	+0.071	0.045	[-0.017, +0.159]
Ajusco Medio	+0.065	0.052	[-0.037, +0.167]
Benito Juárez	+0.045	0.044	[-0.041, +0.132]
Merced	+0.031	0.046	[-0.059, +0.121]
Nezahualcóyotl	+0.018	0.045	[-0.070, +0.107]
San Agustín	+0.015	0.055	[-0.093, +0.123]
Gustavo A. Madero	-0.037	0.049	[-0.133, +0.059]
UAM Iztapalapa	-0.042	0.046	[-0.133, +0.049]
Pedregal	-0.058	0.046	[-0.148, +0.033]
Hospital General México	-0.086	0.061	[-0.206, +0.034]
FES Aragón	-0.137	0.046	[-0.227, -0.048]
Biblioteca	-0.265	0.048	[-0.359, -0.172]

Comparando con el Modelo B, se observa el encogimiento jerárquico esperado: Santiago Acahualtepec pasa de +0.258 (B) a +0.243 (C1), y Biblioteca de -0.275 a -0.265 . Con ≈ 186 observaciones por estación en promedio, los datos tienen suficiente información para que el hiperparámetro esté bien identificado y el encogimiento sea moderado.

3.4. Modelo C2 — Gamma global

El Modelo C2 modela PM2.5 directamente en escala original (no logarítmica), usando una distribución Gamma con función liga logarítmica:

$$\text{PM2.5}_i \sim \text{Gamma}(a, a/\mu_i), \quad \log(\mu_i) = \alpha + \beta_1 \text{tempc}_i + \beta_2 \text{hrc}_i + \beta_3 \text{sen_t}_i + \beta_4 \text{cos_t}_i, \quad (4)$$

donde tempc_i y hrc_i son temperatura y HR centradas (restando la media global, sin estandarizar, para mayor estabilidad numérica del muestreador Metropolis-Hastings de JAGS). El parámetro $a > 0$ es la forma de la Gamma: su media es μ_i y su varianza es μ_i^2/a ; valores grandes de a implican menor coeficiente de variación. La distribución inicial es $a \sim \text{Ga}(0.001, 0.001)$. Los valores iniciales se fijan en $\alpha_0 = \log(\bar{y}) \approx 2.94$ para evitar valores inválidos de μ durante el calentamiento.

Se corrieron 15,000 iteraciones con 3,000 de calentamiento y adelgazamiento de 3 (4,000 muestras activas por cadena).

Diagnóstico




Figura 13: Diagnósticos del parámetro de forma a del Modelo C2. Las cadenas muestran mayor autocorrelación que en los modelos Normal (la ACF tarda más en caer), lo que es típico de la Gamma ajustada con Metropolis-Hastings en JAGS. El promedio ergódico converge alrededor de $a \approx 6.6$.

Resultados

Cuadro 8: Media de la distribución final del Modelo C2 (Gamma global). El DIC *no es comparable* con los modelos A, B, C1 y D porque la variable respuesta está en escala original (no logarítmica). Se usa el pseudo- R^2 en escala log para comparar entre familias.

Parámetro	Media
Intercepto α (log-media cuando covariables = 0)	2.908
β_1 (temperatura, por °C centrado)	0.027
β_2 (humedad relativa, por punto porcentual centrado)	0.004
β_3 (sen_t)	0.312
β_4 (cos_t)	0.190
Parámetro de forma a (mayor a = menor variabilidad)	6.625
DIC (no comparable entre familias)	17 636.6
Pseudo- R^2 en escala log	0.310

El Modelo C2 tiene un pseudo- R^2 ligeramente menor que el Modelo A (0.310 vs 0.313), lo que sugiere que, sin efectos por estación, la Normal sobre el logaritmo describe los datos tan bien o mejor que la Gamma. La ventaja conceptual de la Gamma (soporte positivo estricto para PM2.5) no se traduce en mejor ajuste empírico con este conjunto de datos. El parámetro $\hat{a} = 6.6$ implica un coeficiente de variación de $1/\sqrt{6.6} \approx 0.39$, consistente con la dispersión observada. El DIC de C2 es muy alto porque se calcula sobre PM2.5 en escala original (no logarítmica), por lo que *no debe compararse* con los valores de A, B, C1 o D.

3.5. Modelo D — Tendencia espacial lineal

El Modelo D agrega al Modelo A los efectos lineales de latitud y longitud estandarizadas:

$$\log(\text{PM2.5}_i) \sim \mathcal{N}(\mu_i, \tau^{-1}), \quad \mu_i = \alpha + \beta_1 \text{temp}_i + \cdots + \beta_4 \text{cos_t}_i + \beta_5 \text{lat}_i + \beta_6 \text{lon}_i, \quad (5)$$

con 6 coeficientes en total. Este modelo prueba si el patrón espacial puede describirse con un gradiente lineal simple en lugar de efectos individuales por estación. Se corrieron 10,000 iteraciones con 1,000 de calentamiento.

Diagnóstico




Figura 14: Diagnósticos del Modelo D para el intercepto α . La convergencia es satisfactoria: traza estacionaria, promedios ergódicos coincidentes y ACF que decae rápidamente.

Resultados

Cuadro 9: Distribuciones finales del Modelo D, con énfasis en los coeficientes espaciales.

Parámetro	Media
β_1 (temperatura)	0.084
β_2 (humedad relativa)	0.020
β_3 (sen.t)	0.326
β_4 (cos.t)	0.185
β_5 (latitud, 1-DE $\approx 0.25^\circ \approx 28$ km)	-0.089
β_6 (longitud, 1-DE $\approx 0.19^\circ \approx 18$ km)	+0.004
σ residual	0.416
DIC	2841.6
Pseudo- R^2	0.341

Aunque el coeficiente de latitud tiene signo negativo ($\hat{\beta}_5 = -0.089$), su intervalo de credibilidad incluye el cero, y lo mismo ocurre para la longitud. Más importante: el Modelo D apenas mejora sobre el Modelo A ($\Delta\text{DIC} = 2,942.6 - 2,841.6 = 101.0$ puntos), muy por debajo de los 218 puntos ganados por el Modelo B. Esto confirma que el patrón espacial de PM2.5 en el Valle de México *no es un gradiente lineal* en latitud y longitud: hay zonas contaminadas y limpias que no siguen una tendencia norte-sur o este-oeste simple. La estructura espacial requiere un modelo no lineal, como el proceso gaussiano del Modelo E.

3.6. Modelo E — Proceso Gaussiano y Kriging Bayesiano

Proceso gaussiano como modelo espacial

Los datos de PM2.5 son observaciones *referenciadas puntualmente*: cada medición $Y(s_j)$ corresponde a una localización específica $s_j = (\text{lon}_j, \text{lat}_j)$. Cuando las observaciones presentan dependencia espacial, el marco adecuado es el *proceso gaussiano* (PG; Gelfand & Schliep, 2016): una colección de variables aleatorias tal que cualquier subconjunto finito tiene distribución normal multivariada. Un PG se caracteriza por su función de media $\mu(s)$ y su función de covarianza $\Sigma(s, t)$ (Nieto Barajas, 2026):

$$Y(s) \sim \mathcal{N}(\mu(s), \Sigma(s, t)).$$

Bajo el supuesto de *estacionariedad de segundo orden* — $\mu(s) = \mu$ constante y $\text{Cov}(Y(s), Y(s+h)) = C(h)$ solo depende del desplazamiento h — e *isotropía* — $C(h)$ depende solo de la distancia $\|h\|$ — la función de covarianza exponencial es:

$$\Sigma(s_i, s_j) = \sigma^2 e^{-\phi d_{ij}},$$

donde $d_{ij} = \|s_i - s_j\|$ es la distancia euclidiana entre localizaciones y $\phi > 0$ es el parámetro de rango inverso.

Especificación del Modelo E

El modelo de regresión espacial adoptado tiene la forma aditiva (Nieto Barajas, 2026, §7.2):

$$Y(s) = \mu(s) + \omega(s),$$

donde $\mu(s) = \mathbf{x}(s)' \boldsymbol{\beta}$ es el predictor lineal fijo y $\omega(s)$ es un efecto aleatorio espacial con distribución gaussiana.

En lugar de ajustar el PG completo en JAGS — lo que requeriría muestrear la matriz de covarianzas $n \times n$ en cada iteración — se adopta una aproximación en dos etapas que es computacionalmente eficiente y aprovecha los resultados del Modelo C1:

1. Los efectos aleatorios $\hat{\alpha}_j$ del Modelo C1 se interpretan como realizaciones del proceso gaussiano en las 14 localizaciones con estaciones: $\hat{\alpha}_j \approx \omega(s_j)$.
2. Se modela $\boldsymbol{\omega} = (\omega(s_1), \dots, \omega(s_J))'$ como un PG estacionario e isotrópico con kernel exponencial:

$$\boldsymbol{\omega} \sim \mathcal{N}_J(\mathbf{0}, \Sigma_{\text{obs}}), \quad [\Sigma_{\text{obs}}]_{ij} = e^{-d_{ij}/\rho},$$

con rango $\rho = 0.08^\circ \approx 8.9$ km. A esa distancia la correlación cae a $e^{-1} \approx 0.37$; para estaciones a $d > 3\rho \approx 27$ km la correlación es prácticamente nula (< 0.05).

Kriging bayesiano

La predicción en un polígono sin estación con centroide s_0 se obtiene mediante la distribución predictiva bayesiana (Nieto Barajas, 2026, §7.2):

$$f(y_0 | \mathbf{y}, \mathbf{x}_0) = \int f(y_0 | \mathbf{y}, \theta, \mathbf{x}_0) f(\theta | \mathbf{y}) d\theta,$$

integrada sobre la incertidumbre paramétrica $\theta = (\alpha, \beta, \tau)$. El predictor del efecto espacial en s_0 , condicional en los efectos observados, es:

$$\hat{\omega}(s_0) = \Sigma_{\text{pred,obs}} \Sigma_{\text{obs,obs}}^{-1} \hat{\alpha},$$

donde $[\Sigma_{\text{pred,obs}}]_j = e^{-d_{0j}/\rho}$ es el vector de covarianzas entre el punto nuevo y las 14 estaciones. La predicción final combina la componente fija (covariables en sus valores medios anuales) con la componente espacial:

$$\hat{y}_0 = \hat{\alpha} + \hat{\beta}' \bar{\mathbf{x}} + \hat{\omega}(s_0).$$

Se usan 2,000 muestras MCMC de la distribución final del Modelo C1 para propagar la incertidumbre paramétrica y obtener intervalos de credibilidad para cada polígono.

3.7. Modelo F — Espacio-Temporal Jerárquico

El Modelo F aborda las dos limitaciones principales del Modelo E: (i) los datos faltantes se tratan como parámetros a estimar, no se descartan, y (ii) la estructura espacio-temporal se ajusta de forma conjunta en lugar de proceder en dos pasos. El modelo se ajusta en dos etapas secuenciales.

Etapas 1 — Modelo espacio-temporal con proceso gaussiano

Se construye un panel balanceado 365×14 donde las celdas sin observación quedan como NA en la variable respuesta. JAGS trata esas celdas como variables latentes y las imputa simultáneamente con el resto del muestreo.

La verosimilitud del panel es:

$$\log(\text{PM}_{2.5})_{t,j} \sim \mathcal{N}(\mu_{t,j}, \tau_y^{-1}),$$

$$\mu_{t,j} = \alpha_j + \beta_1 \text{sen}_t + \beta_2 \text{cos}_t + \beta_3 \text{temp}_{t,j} + \beta_4 \text{hr}_{t,j}.$$

Los efectos espaciales de estación $\alpha = (\alpha_1, \dots, \alpha_J)'$ se modelan mediante una Normal Multivariada con estructura de covarianza exponencial en función de la distancia euclidiana en km (proyección UTM 14N):

$$\alpha \sim \mathcal{N}_J(\mathbf{0}, \Sigma_\alpha), \quad [\Sigma_\alpha]_{kl} = \frac{1}{\tau_\alpha} e^{-\phi D_{kl}},$$

donde D_{kl} es la distancia en km entre las estaciones k y l , y $\phi > 0$ es el parámetro de rango estimado desde los datos (a diferencia del Modelo E, donde ρ se fijó en 0.08°).

Las distribuciones iniciales son:

$$\beta_k \sim \mathcal{N}(0, 0.001), \quad \tau_y \sim \text{Ga}(0.1, 0.1), \quad \tau_\alpha \sim \text{Ga}(0.1, 0.1), \quad \phi \sim \text{Uniforme}(0.01, 5).$$

La cadena se corrió con `jags.parallel`: 2 cadenas, 10,000 iteraciones, 3,000 de calentamiento, adelgazamiento `thin` = 4. La salida principal es el array tridimensional de simulaciones de $\log(\text{PM}_{2.5})_{t,j}$, incluyendo los valores imputados.

Etapla 2 — Agregación jerárquica a nivel ZMVM

Las medias posteriores $\hat{y}_{t,j}$ y varianzas posteriores $\hat{v}_{t,j}$ de $\log(\text{PM}_{2.5})_{t,j}$ de la Etapa 1 sirven como datos para un segundo modelo jerárquico que estima la tendencia macro-ambiental diaria de la cuenca:

$$\hat{y}_{t,j} \sim \mathcal{N}(\mu_t^{\text{ZMVM}} + \alpha_j^*, \hat{\tau}_{t,j}), \quad \hat{\tau}_{t,j} = \min\left(\frac{1}{\hat{v}_{t,j}}, 500\right),$$

donde la precisión heredada $\hat{\tau}_{t,j}$ pondera cada estación en función de la información que aportó en la Etapa 1 (estaciones con mayor incertidumbre reciben menor peso). La tendencia macro-ambiental sigue un modelo armónico:

$$\mu_t^{\text{ZMVM}} = \gamma_1 + \gamma_2 \sin t + \gamma_3 \cos t.$$

Los efectos espaciales de estación α_j^* se modelan con una restricción de suma cero para identificabilidad:

$$\alpha_j \sim \mathcal{N}(0, \tau_{\text{est}}^{-1}), \quad \alpha_j^* = \alpha_j - \bar{\alpha},$$

con distribuciones iniciales $\gamma_k \sim \mathcal{N}(0, 0.001)$ y $\tau_{\text{est}} \sim \text{Ga}(0.1, 0.1)$.

La cadena se corrió con `jags.parallel`: 3 cadenas, 25,000 iteraciones, 5,000 de calentamiento, adelgazamiento `thin` = 50. El adelgazamiento agresivo es necesario porque el modelo M-H sobre parámetros continuos genera autocorrelación serial alta. Los parámetros de interés son γ , α^* y μ_t^{ZMVM} ($t = 1, \dots, 365$).

4. Interpretación de resultados

4.1. Comparación de modelos

Cuadro 10: Comparación de los modelos. El DIC es comparable solo dentro de los modelos con la misma variable respuesta y familia distribucional (A, B, C1, D). El Modelo C2 (Gamma) no es comparable con ellos porque la variable respuesta está en escala original; se compara mediante el pseudo- R^2 en escala logarítmica.

Modelo	Estructura	DIC	Pseudo- R^2	σ
A — Normal global	Solo clima y estacionalidad	2 942.6	0.313	0.424
D — Tendencia lat/lon	A + gradiente lineal espacial	2 841.6	0.341	0.416
B — Efectos fijos	A + 14 efectos fijos estación	2 724.2	0.375	0.406
C1 — Jerárquico	A + efectos aleatorios est.	2 723.7	0.375	0.406
C2 — Gamma global	Familia Gamma (DIC no comparable)	—	0.310	—

La jerarquía de modelos es clara:

1. El Modelo A es la línea base; el clima y la estacionalidad explican el 31 % de la variación.
2. El Modelo D mejora sobre A ($\Delta\text{DIC} = -101$), pero mucho menos de lo esperado si el patrón fuera un gradiente lineal: la dependencia espacial es no lineal.
3. Los Modelos B y C1 son claramente superiores ($\Delta\text{DIC} \approx -218$ respecto a A), lo que confirma que la heterogeneidad espacial entre estaciones es el factor explicativo más importante después del clima.
4. El Modelo C1 es marginalmente preferible al B ($\Delta\text{DIC} = 0.5$) y tiene la ventaja adicional de cuantificar la variabilidad entre estaciones mediante σ_α y de permitir predicciones en nuevas estaciones sin datos mediante el proceso gaussiano del Modelo E.

Se elige el **Modelo C1** como el modelo preferido.

4.2. Predicción espacial — Resultados del Modelo E




Figura 15: Efectos espaciales $\hat{\alpha}_j$ por estación usados como puntos de anclaje para el kriging. El rango de variación (-0.27 a $+0.24$) es consistente con $\hat{\sigma}_\alpha = 0.134$ del Modelo C1.




Figura 16: Predicción de PM2.5 promedio para los 141 polígonos del Valle de México (Modelo E, kriging bayesiano con kernel exponencial, $\rho = 0.08^\circ$). Puntos blancos indican la ubicación de las 14 estaciones de monitoreo. El gradiente sur-oriente (más contaminado) hacia el norte (más limpio) es coherente con la topografía de cuenca cerrada y la ventilación predominante del poniente.

Cuadro 11: Municipios y alcaldías más y menos contaminados según el Modelo E. IC: intervalo de credibilidad al 95 %.

Municipio/Alcaldía	Entidad	PM2.5 ($\mu\text{g}/\text{m}^3$)	IC 2.5 %	IC 97.5 %
<i>Zonas más contaminadas</i>				
Tláhuac	CDMX	19.53	18.68	20.43
La Paz	Edomex	19.37	18.53	20.24
Valle de Chalco Solidaridad	Edomex	19.06	18.08	20.12
Tlalnepantla de Baz	Edomex	18.97	18.22	19.80
Xochimilco	CDMX	18.66	17.88	19.47
<i>Zonas menos contaminadas</i>				
Zumpango	Edomex	16.33	15.46	17.23
Temascalapa	Edomex	16.40	15.47	17.34
Hueypoxtla	Edomex	16.65	15.64	17.66
Tecámac	Edomex	16.88	15.93	17.85
Nextlalpan	Edomex	17.02	16.04	18.02

El rango de predicciones va de $16.3 \mu\text{g}/\text{m}^3$ (Zumpango) a $19.5 \mu\text{g}/\text{m}^3$ (Tláhuac), con una desviación estándar entre polígonos de $0.41 \mu\text{g}/\text{m}^3$. Aunque el rango absoluto es moderado ($3.2 \mu\text{g}/\text{m}^3$), las implicaciones para salud son relevantes: la evidencia epidemiológica sugiere que aumentos de $10 \mu\text{g}/\text{m}^3$ en PM2.5 se asocian con incrementos del 7–10 % en mortalidad cardiovascular (OMS, 2021). Un habitante de Tláhuac está expuesto, en promedio, a 19 % más PM2.5 que uno de Zumpango.

¿Qué factores explican la variación temporal de PM2.5? Los términos de Fourier (estacionalidad anual) son los predictores más fuertes: un ciclo con amplitud ≈ 0.40 log-unidades captura el máximo invernal (febrero-marzo) y el mínimo de verano (junio-julio). La temperatura tiene un efecto positivo y significativo (+10 % de PM2.5 por cada desviación estándar adicional, $\approx 2.1^\circ\text{C}$), consistente con condiciones de menor dilución y mayor inversión térmica en días cálidos. La humedad relativa también tiene un efecto positivo y significativo (+4.7 %), detectado una vez que se controla por estación.

¿Existen diferencias sistemáticas entre municipios no explicadas por clima? Sí, y son grandes. La inclusión de efectos por estación reduce el DIC en 218 puntos (de 2,942.6 a 2,724.2), evidencia contundente de heterogeneidad espacial. Las diferencias entre la estación más contaminada (Santiago Acahualtepec, +29 %) y la más limpia (Biblioteca, Tizayuca, –24 %) no son atribuibles al clima: son características estructurales del territorio.

¿Es mejor el modelo jerárquico que los efectos fijos? Con el tamaño de muestra disponible (≈ 186 obs/estación), ambos son prácticamente equivalentes en ajuste ($\Delta\text{DIC} = 0.5$ puntos). La ventaja del Modelo C1 es doble: cuantifica explícitamente la variabilidad entre estaciones ($\hat{\sigma}_\alpha = 0.134$) y proporciona los efectos espaciales $\hat{\alpha}_j$ como puntos de anclaje para el kriging bayesiano del Modelo E, algo imposible con efectos fijos no estructurados.

¿Podemos predecir en zonas sin sensores? El Modelo E produce predicciones plausibles para los 141 polígonos, coherentes con la topografía: las zonas de cuenca baja (Tláhuac, La Paz, Valle de Chalco) acumulan más contaminantes, mientras que las zonas al norte del valle (Zumpango, Temascalapa) presentan mejor calidad del aire. La principal limitación es que el parámetro de rango $\rho = 0.08^\circ$ está fijo (no se estima desde los datos), lo que introduce un supuesto que no se verifica formalmente con 14 estaciones. Los intervalos de credibilidad en municipios sin estaciones cercanas son 30–50 % más amplios que en los municipios con cobertura directa, reflejando correctamente la mayor incertidumbre de la interpolación en zonas alejadas de sensores.

4.3. Resultados del Modelo F




Figura 17: Diagnósticos MCMC del Modelo F Etapa 1 para β_1 (coeficiente del término sen_t). Las dos cadenas mezclan correctamente y la ACF decae dentro de los primeros lags.




Figura 18: Diagnósticos MCMC del Modelo F Etapa 2 para γ_1 (intercepto global de la ZMVM). Se usaron 3 cadenas con adelgazamiento $\text{thin} = 50$; las tres trayectorias convergen a la misma región.

Diagnóstico de convergencia.

Parámetros estimados — Etapa 1. El Cuadro 12 resume los estimadores posteriores principales. El parámetro de rango espacial $\hat{\phi} = 0.0123$ implica una distancia de semivida de correlación de $-\ln(0.5)/0.0123 \approx 56.4$ km, coincidiendo con la extensión longitudinal de la zona metropolitana, lo que valida geográficamente la estructura de covarianza adoptada. La varianza espacial ($\sigma_\alpha = 1/\sqrt{1.84} \approx 0.738$ log-unidades) supera a la varianza residual ($\sigma_y = 1/\sqrt{6.08} \approx 0.406$ log-unidades), confirmando que los gradientes geográficos dominan la variación entre estaciones. Todos los $\hat{R} < 1.003$.

Cuadro 12: Estimadores posteriores — Modelo F Etapa 1 (MET-PGE).

Parámetro	Descripción	Media post.	$\hat{R}$
β_1	Armónico seno (estacionalidad)	0.3359	1.0012
β_2	Armónico coseno	0.2245	1.0010
β_3	Temperatura	0.0368	1.0009
β_4	Humedad relativa	0.0040	1.0015
ϕ	Parámetro de rango espacial	0.0123	1.0011
τ_y	Precisión residual	6.0769	1.0008
τ_α	Precisión espacial	1.8354	1.0022

Imputación de datos faltantes. La Etapa 1 imputa de forma coherente los valores no observados de cada estación. El modelo asigna mayor incertidumbre en las fechas sin observación, lo que se refleja en intervalos de credibilidad más amplios en esas celdas.

Modelo F Etapa 1: Validacion de imputacion MCMC

Línea: media posterior | Banda: IC 95% | Puntos: observados




Figura 19: Validación de la imputación MCMC (Etapa 1) para tres estaciones con distinta densidad de datos: Hospital General de México (52 obs, escenario crítico), Santiago Acahualtepec (189 obs, escenario típico) y Benito Juárez (236 obs, escenario óptimo). La banda gris es el intervalo de credibilidad al 95%; los puntos grises son los valores observados.

Tendencia macro-ambiental de la ZMVM. La Etapa 2 produce la serie de tiempo μ_t^{ZMVM} que resume la tendencia diaria de la calidad del aire en la cuenca, libre del ruido local de cada estación.




Figura 20: Serie de tiempo macro-ambiental de la ZMVM estimada por el Modelo F Etapa 2. La línea sólida es la media posterior de $\exp(\mu_t^{ZMVM})$ en escala $\mu\text{g}/\text{m}^3$; la banda roja es el intervalo de credibilidad al 95 %. El patrón estacional es claro: máximo invernal (enero–marzo), mínimo estival (junio–agosto) y repunte en el cuarto trimestre.

La Figura 21 muestra el anclaje de la tendencia teórica sobre la estación de mayor cobertura (Benito Juárez, 236 observaciones): la curva estimada pasa a través del centro de gravedad empírico de los datos, validando el ajuste del sistema en escala original.




Figura 21: Validación del Modelo F Etapa 2 sobre Benito Juárez (estación de mayor cobertura: 236 observaciones). La línea teórica estimada es consistente con la distribución empírica de los datos observados.

Efectos espaciales de estación. Los coeficientes α_j^* (suma cero) cuantifican la desviación de cada estación respecto a la tendencia de la cuenca, controlando por estacionalidad.




Figura 22: Efectos espaciales de estación del Modelo F Etapa 2 (α_j^* , restricción de suma cero). Los valores positivos indican estaciones sistemáticamente más contaminadas que la media de la cuenca; los negativos, más limpias.

El Cuadro 13 presenta los estimadores de la tendencia macro-ambiental. El intercepto $\hat{\gamma}_1 = 2.8197$ corresponde a una concentración basal de $\exp(2.8197) \approx 16.8 \mu\text{g}/\text{m}^3$, interpretable como el nivel de fondo de $\text{PM}_{2.5}$ de la cuenca después de remover estacionalidad, meteorología local y efectos espaciales. Los coeficientes armónicos ($\hat{\gamma}_2 = 0.3315$, $\hat{\gamma}_3 = 0.1221$) implican una amplitud combinada del ciclo anual de aproximadamente $\pm 35\%$ respecto a esa línea base.

Cuadro 13: Estimadores posteriores — Modelo F Etapa 2 (MJTC-RSC).

Parámetro	Descripción	Media	IC 95 %	$\hat{R}$
γ_1	Intercepto basal ZMVM	2.8197	[2.8176, 2.8219]	1.0016
γ_2	Amplitud armónica seno	0.3315	[0.3287, 0.3342]	1.0047
γ_3	Amplitud armónica coseno	0.1221	[0.1195, 0.1250]	1.0006

La Figura 23 ilustra el mecanismo de desplazamiento geográfico: Ajusco Medio ($\hat{\alpha}_3^* = -0.370$, equivalente a un 31 % menos que la media de la cuenca) frente a la tendencia basal. En contraste, UAM Iztapalapa presenta el mayor exceso positivo ($\hat{\alpha}_{11}^* = +0.215$, +24 % sobre la media).




Figura 23: Efecto de desplazamiento geográfico del Modelo F Etapa 2: perfil estimado de $PM_{2.5}$ para Ajusco Medio ($\hat{\alpha}^* = -0.370$, -31%) frente a la tendencia macro-ambiental de la cuenca. La distancia vertical entre ambas curvas cuantifica el efecto espacial de la estación.

Comparación con los modelos previos. El Modelo F extiende al E en tres aspectos clave: (i) el parámetro de rango espacial ϕ se estima desde los datos (no se fija a priori), lo que permite que los propios datos determinen el alcance de la dependencia espacial; (ii) la imputación de los 2,617 valores observados se complementa con la estimación de los $365 \times 14 - 2,617 = 2,493$ valores faltantes como variables latentes, aprovechando la estructura espacio-temporal; (iii) la Etapa 2 produce una síntesis coherente de la calidad del aire de la ZMVM que propaga la incertidumbre de la Etapa 1 mediante las precisiones heredadas $\hat{t}_{t,j}$.

5. Referencias

1. de Finetti, B. (1937). La prévision: ses lois logiques, ses sources subjectives. *Annales de l'Institut Henri Poincaré*, 7, 1–68.
2. Gelfand, A. E., & Schliep, E. M. (2016). Spatial statistics and Gaussian processes: A beautiful marriage. *Statistical Science*, 31(1), 109–130.
3. Global Administrative Areas. (s.f.). *GADM database of global administrative areas* (Nivel 2). <https://gadm.org>
4. Instituto Nacional de Ecología y Cambio Climático. (s.f.). *Sistema Nacional de Información de la Calidad del Aire (SINAICA)*. <https://sinaica.inecc.gob.mx/data.php?tipo=V>

5. Lunn, D., Jackson, C., Best, N., Thomas, A., & Spiegelhalter, D. (2013). *The BUGS Book: A Practical Introduction to Bayesian Analysis*. CRC Press.
6. Nieto Barajas, L. E. (2026). *Notas de Regresión Avanzada* (Temas 2–7). Departamento de Estadística, ITAM.
7. Organización Mundial de la Salud. (2021). *Global air quality guidelines*. OMS.
8. Plummer, M. (2003). JAGS: A program for analysis of Bayesian graphical models using Gibbs sampling. En *Proceedings of the 3rd International Workshop on Distributed Statistical Computing* (pp. 1–10). Vienna, Austria.
9. R Core Team. (2025). *R: A language and environment for statistical computing*. R Foundation for Statistical Computing. <https://www.R-project.org/>

A. Código fuente

El apéndice contiene el código completo utilizado en el análisis, en el orden del flujo de trabajo: descarga y preparación de datos, análisis exploratorio, ajuste de modelos y generación de figuras. Al final se incluyen las especificaciones JAGS de todos los modelos.

Nota sobre notación JAGS: El segundo argumento de `dnorm` es la *precisión* $\tau = 1/\sigma^2$ (no la varianza), por lo que `dnorm(0, 0.001)` corresponde a $\mathcal{N}(0, 1000)$ —una distribución inicial prácticamente plana sobre los coeficientes.

Descarga de datos SINAICA — `descarga_masiva_valle.R`

```
options(repos="http://cran.itam.mx/")
library(rsinaica)
library(dplyr)
library(lubridate)

wdir <- normalizePath(file.path(dirname(rstudioapi::getActiveDocumentContext())$path), "..")
setwd(wdir)

dir.create("data/raw", recursive=TRUE, showWarnings=FALSE)

# =====
# Descarga masiva --- 56 estaciones, mes por mes (API limite = 1 mes)
# =====

est <- read.csv("data/raw/estaciones_territorio_valle.csv", stringsAsFactors=FALSE)
cat("Estaciones a descargar:", nrow(est), "\n")

VARS <- c("PM2.5"="PM2.5", "temp"="TMP", "hr"="HR")

# Contadores
n_existen <- 0
n_descargados <- 0
```

```

n_sin_datos <- 0
n_errores <- 0

for (i in 1:nrow(est)) {
  sid <- est$station_id[i]
  sname_raw <- est$station_name[i]
  # Limpiar nombre para archivo
  sname <- tolower(gsub("[\\.]", "", sname_raw))
  sname <- iconv(sname, to="ASCII//TRANSLIT")
  # Prefijo segun estado
  prefijo <- ifelse(est$estado[i] == "Distrito Federal", "cdmx",
                    ifelse(est$estado[i] == "México", "edomex", "hidalgo"))

  for (vname in names(VARS)) {
    vcode <- VARS[vname]
    fname <- file.path("data/raw", paste0(prefijo, "_", sname, "_", vname, "_2023.csv")
    )

    if (file.exists(fname)) {
      cat("[", i, "/", nrow(est), "] YA EXISTE:", basename(fname), "\n")
      n_existen <- n_existen + 1
      next
    }

    cat("[", i, "/", nrow(est), "] Descargando:", sname_raw, "-", vname, "(id=", sid, "
    )\n")

    chunk_list <- list()
    for (mes in 1:12) {
      ini <- as.Date(paste0("2023-", sprintf("%02d", mes), "-01"))
      fin <- as.Date(paste0("2023-", sprintf("%02d", mes), "-", days_in_month(ini)))

      tryCatch({
        chunk <- sinaica_station_data(station_id=as.integer(sid), parameter=as.
character(vcode),
                                     start_date=ini, end_date=fin)

        if (!is.null(chunk) && nrow(chunk) > 0) {
          chunk_list[[length(chunk_list)+1]] <- chunk
          cat(" Mes", mes, ":", nrow(chunk), "registros\n")
        } else {
          cat(" Mes", mes, ": sin datos\n")
        }
      }, error=function(e) {
        cat(" Mes", mes, ": ERROR -", conditionMessage(e), "\n")
        n_errores <- n_errores + 1
      })

      Sys.sleep(0.5)
    }

    if (length(chunk_list) > 0) {
      datos <- bind_rows(chunk_list)
      write.csv(datos, fname, row.names=FALSE)
      cat(" -> GUARDADO:", basename(fname), "(", nrow(datos), "filas )\n")
    }
  }
}

```

```

    n_descargados <- n_descargados + 1
  } else {
    cat("  -> SIN DATOS para esta estacion/variable\n")
    n_sin_datos <- n_sin_datos + 1
  }
}
}

cat("\n=== RESUMEN DESCARGA ===\n")
cat("Ya existian:", n_existen, "\n")
cat("Descargados:", n_descargados, "\n")
cat("Sin datos:", n_sin_datos, "\n")
cat("Errores:", n_errores, "\n")
cat("=====\n")

```

Filtrado espacial de estaciones — filtrar_estaciones_territorio.R

```

options(repos="http://cran.itam.mx/")
library(terra)
library(dplyr)

wdir <- normalizePath(file.path(dirname(rstudioapi::getActiveDocumentContext())$path), "..")
setwd(wdir)

# =====
# Filtrar estaciones SINAICA por territorio (spatial join)
# =====

# 1. Cargar estaciones
st <- read.csv("data/raw/todas_estaciones_sinaica.csv", stringsAsFactors=FALSE)
cat("Total estaciones SINAICA:", nrow(st), "\n")

# 2. Crear SpatVector de puntos (lon/lat)
pts <- vect(st, geom=c("lon", "lat"), crs="EPSG:4326")

# 3. Cargar GADM nivel 2 y filtrar territorios de interes
mex <- vect("data/gadm_mexico/gadm41_MEX_2.shp")

# Territorios de interes
alcaldias_cdmx <- c("Álvaro Obregón", "Azcapotzalco", "Benito Juárez", "Coyoacán",
                  "Cuajimalpa de Morelos", "Cuauhtémoc", "Gustavo A. Madero",
                  "Iztacalco", "Iztapalapa", "La Magdalena Contreras",
                  "Miguel Hidalgo", "Milpa Alta", "Tláhuac", "Tlalpan",
                  "Venustiano Carranza", "Xochimilco")

municipios_edomex <- c("Acolman", "Amecameca", "Apaxco", "Atenco", "Atizapán de
Zaragoza",
                      "Atlautla", "Axapusco", "Ayapango", "Chalco", "Chiautla",
                      "Chicoloapan", "Chiconcuac", "Chimalhuacán", "Coacalco de
Berriozábal",
                      "Cocotitlán", "Coyotepec", "Cuautitlán", "Cuautitlán Izcalli",

```

```

"Ecatepec de Morelos", "Ecatzingo", "Huehuetoca", "Hueypoxtlá",
"Huixquilucan", "Isidro Fabela", "Ixtapaluca", "Jaltenco",
"Jilotzingo", "Juchitepec", "La Paz", "Melchor Ocampo",
"Naucalpan de Juárez", "Nextlalpan", "Nezahualcóyotl",
"Nicolás Romero", "Nopaltepec", "Otumba", "Ozumba",
"Papalotla", "San Martín de las Pirámides", "Tecámac",
"Temamatla", "Temascalapa", "Tenango del Aire", "Teoloyucan",
"Teotihuacán", "Tepetlaoxtoc", "Tepetlixpa", "Tepotzotlán",
"Tequixquiac", "Texcoco", "Tezoyuca", "Tlalmanalco",
"Tlalnepantla de Baz", "Tonanitla", "Tultepec", "Tultitlán",
"Valle de Chalco Solidaridad", "Villa del Carbón", "Zumpango")

municipios_hidalgo <- c("Tizayuca")

# Filtrar GADM
gadm_filtrado <- mex[mex$NAME_1 %in% c("Distrito Federal", "México", "Hidalgo") &
  mex$NAME_2 %in% c(alcaldias_cdmx, municipios_edomex, municipios_
    hidalgo), ]

cat("Poligonos en territorio de interes:", nrow(gadm_filtrado), "\n")

# 4. Spatial join con extract (mas robusto que intersect)
# extract devuelve el ID del poligono que contiene cada punto
ext <- terra::extract(gadm_filtrado, pts)

# Filtrar puntos que cayeron en algun poligono
idx_en_poligono <- which(!is.na(ext$NAME_1))
cat("Estaciones dentro del territorio:", length(idx_en_poligono), "\n")

if (length(idx_en_poligono) == 0) {
  cat("ERROR: No se encontraron estaciones dentro del territorio\n")
  cat("Primeras 10 estaciones en area CDMX:\n")
  st_cdmx_area <- st[st$lon > -100 & st$lon < -98.5 & st$lat > 19 & st$lat < 20.5, ]
  print(head(st_cdmx_area[, c("station_id", "station_name", "lat", "lon")], 10))
} else {
  est_filtradas <- st[idx_en_poligono, ]
  est_filtradas$estado <- ext$NAME_1[idx_en_poligono]
  est_filtradas$municipio <- ext$NAME_2[idx_en_poligono]

  # Seleccionar columnas relevantes
  est_filtradas <- est_filtradas %>%
    select(station_id, station_name, network_name, estado, municipio, lat, lon) %>%
    arrange(estado, municipio, station_name)

  cat("\nEstaciones encontradas:\n")
  print(est_filtradas)

  write.csv(est_filtradas, "data/raw/estaciones_territorio_valle.csv", row.names=FALSE)
  cat("\nGuardado: data/raw/estaciones_territorio_valle.csv\n")

  cat("\nResumen por estado:\n")
  print(table(est_filtradas$estado))

  cat("\nResumen por municipio/alcaldia:\n")

```

```
print(table(est_filtradas$municipio))
}
```

Limpieza y preparación de datos — limpieza_valle_mexicoR

```
options(repos="http://cran.itam.mx/")
library(dplyr)
library(lubridate)

wdir <- normalizePath(file.path(dirname(rstudioapi::getActiveDocumentContext())$path), "..")
setwd(wdir)

# =====
# Limpieza --- 56 estaciones en territorio Valle de Mexico
# =====
# Decisiones de limpieza:
# 1. Solo incluir estaciones con PM2.5, temp Y HR disponibles
# 2. Calcular medias diarias para homogeneizar frecuencias
# 3. Filtrar observaciones con complete.cases()
# 4. Estandarizar covariables despues de la limpieza (no antes)
# 5. Usar spatial join pre-calculado para asignar municipio/alcaldia

cat("=== Limpieza: 56 estaciones Valle de Mexico ===\n")

# 1. Cargar metadatos de estaciones
est_meta <- read.csv("data/raw/estaciones_territorio_valle.csv", stringsAsFactors=FALSE)
cat("Estaciones en metadatos:", nrow(est_meta), "\n")

# 2. Leer todos los CSVs disponibles en data/raw/
all_files <- list.files("data/raw", pattern="_(PM2[.]5|temp|hr)_2023[.]csv$", full.names=TRUE)
cat("Archivos CSV encontrados:", length(all_files), "\n")

# Mapear archivo -> estacion + variable
leer_csv <- function(f) {
  # Extraer info del nombre: {prefijo}_{nombre}_{variable}_2023.csv
  bn <- basename(f)
  parts <- strsplit(bn, "_")[[1]]
  # El prefijo es parts[1], la variable es parts[length(parts)-1]
  # El nombre puede tener _ internos
  prefijo <- parts[1]
  variable <- parts[length(parts)-1]
  # Reconstruir nombre de estacion
  nombre_est <- paste(parts[-c(1, length(parts)-1, length(parts))], collapse="_")
  nombre_est <- gsub("_2023", "", nombre_est)

  df <- tryCatch({
    read.csv(f, stringsAsFactors=FALSE)
  }, error=function(e) {
    cat("ERROR leyendo", bn, ":", conditionMessage(e), "\n")
  })
}
```



```

    NULL
  })

  if (is.null(df)) return(NULL)

  # Determinar que columna contiene el valor y la fecha
  # SINAICA usualmente tiene: date, pollutant/parameter, value, unit, etc.
  # Intentar detectar automaticamente
  col_names <- tolower(names(df))

  # Buscar columna de fecha
  fecha_col <- grep("fecha|date|hora", col_names, value=TRUE)[1]
  if (is.na(fecha_col)) fecha_col <- names(df)[1]

  # Buscar columna de valor
  valor_col <- grep("valor|value|concentracion|conc|pm25|tmp|hr|hum|temp", col_names,
    value=TRUE)[1]
  if (is.na(valor_col)) valor_col <- names(df)[ncol(df)]

  # Renombrar
  df$fecha_raw <- df[[fecha_col]]
  df$valor_raw <- suppressWarnings(as.numeric(as.character(df[[valor_col]])))

  # Parsear fecha (SINAICA usa formato ISO o similar)
  df$date <- as.Date(df$fecha_raw)

  # Filtrar solo 2023 y valores validos
  df <- df %>%
    filter(!is.na(date), year(date)==2023, !is.na(valor_raw), valor_raw >= 0) %>%
    select(date, valor_raw) %>%
    mutate(estacion_file = nombre_est, variable = variable)

  return(df)
}

# Leer todos los archivos
datos_list <- lapply(all_files, leer_csv)
datos_list <- datos_list[!sapply(datos_list, is.null)]

cat("Archivos leidos exitosamente:", length(datos_list), "\n")

if (length(datos_list) == 0) {
  cat("ERROR: No se pudieron leer archivos. Terminando.\n")
  quit(status=1)
}

# 3. Combinar y calcular medias diarias
all_datos <- bind_rows(datos_list)

cat("Total registros brutos:", nrow(all_datos), "\n")
cat("Variables encontradas:", paste(unique(all_datos$variable), collapse=" "), "\n")
cat("Estaciones encontradas:", length(unique(all_datos$estacion_file)), "\n")

# Pivotear: cada fila = estacion + fecha, columnas = PM2.5, temp, hr

```

```

daily <- all_datos %>%
  group_by(estacion_file, date, variable) %>%
  summarise(valor_dia = mean(valor_raw, na.rm=TRUE), .groups="drop") %>%
  tidyr::pivot_wider(names_from=variable, values_from=valor_dia)

cat("Observaciones diarias (antes de filtrar):", nrow(daily), "\n")
cat("Columnas:", paste(names(daily), collapse=" "), "\n")

# Renombrar columnas estandar
# SINAICA usa PM2.5, TMP, HR en los nombres de archivo
# Pero las columnas pueden llamarse de otra forma
# Ajustar nombres
names(daily) <- tolower(names(daily))
if ("pm2.5" %in% names(daily)) daily <- daily %>% rename(pm25 = 'pm2.5')
if ("tmp" %in% names(daily)) daily <- daily %>% rename(temp = tmp)

# Verificar que tenemos las 3 variables
vars_presentes <- intersect(c("pm25", "temp", "hr"), names(daily))
cat("Variables presentes:", paste(vars_presentes, collapse=" "), "\n")

if (length(vars_presentes) < 3) {
  cat("ADVERTENCIA: No todas las variables presentes. Filtrando con las disponibles.\n"
    )
}

# 4. Filtrar complete cases para las 3 variables
# Solo si las 3 existen
if (all(c("pm25", "temp", "hr") %in% names(daily))) {
  daily <- daily %>% filter(complete.cases(pm25, temp, hr))
  cat("Observaciones con las 3 variables:", nrow(daily), "\n")
} else {
  # Filtrar con las que tengamos
  daily <- daily %>% filter(complete.cases(across(any_of(c("pm25", "temp", "hr")))))
  cat("Observaciones con variables disponibles:", nrow(daily), "\n")
}

# 5. Mapear estacion_file a metadatos (nombre canonico, lat, lon, municipio)
# Construir nombre canonico para matching
est_meta$estacion_file <- tolower(gsub("[ \\.]", "", est_meta$station_name))
est_meta$estacion_file <- iconv(est_meta$estacion_file, to="ASCII//TRANSLIT")

daily <- daily %>%
  left_join(est_meta %>% select(estacion_file, station_name, municipio, estado, lat,
    lon),
    by="estacion_file")

# Filtrar las que hicieron match
daily <- daily %>% filter(!is.na(station_name))
cat("Observaciones con match en metadatos:", nrow(daily), "\n")

# 6. Crear variables temporales
daily <- daily %>%
  mutate(
    dia_año = yday(date),

```

```

    mes = month(date),
    dia_semana = wday(date),
    sen_t = sin(2 * pi * dia_año / 365),
    cos_t = cos(2 * pi * dia_año / 365),
    estacion = station_name,
    ciudad = ifelse(estado == "Distrito Federal", "cdmx",
                    ifelse(estado == "México", "edomex", "hidalgo"))
  )

# 7. Resumen por estacion
resumen <- daily %>%
  group_by(estacion, ciudad, municipio, lat, lon) %>%
  summarise(
    n = n(),
    pm25_mean = mean(pm25),
    pm25_sd = sd(pm25),
    temp_mean = mean(temp),
    hr_mean = mean(hr),
    .groups="drop"
  ) %>%
  arrange(desc(pm25_mean))

cat("\n=== Resumen por estacion ===\n")
print(resumen)

# 8. Guardar
write.csv(daily, "data/clean/pm25_valle_mexico.csv", row.names=FALSE)
write.csv(resumen, "data/clean/resumen_estaciones.csv", row.names=FALSE)

cat("\nGuardado:\n")
cat(" data/clean/pm25_valle_mexico.csv (", nrow(daily), "obs x", ncol(daily), "vars )\n")
cat(" data/clean/resumen_estaciones.csv (", nrow(resumen), "estaciones )\n")

# 9. Comparar con version anterior
if (file.exists("data/clean/pm25_valle_mexico.csv")) {
  old <- read.csv("data/clean/pm25_valle_mexico.csv", stringsAsFactors=FALSE)
  cat("\nComparacion con version anterior:\n")
  cat(" Anterior:", nrow(old), "obs,", length(unique(old$estacion)), "estaciones\n")
  cat(" Nueva:   ", nrow(daily), "obs,", length(unique(daily$estacion)), "estaciones\n")
}

```

Análisis exploratorio de datos — eda_valle_mexicoR

```

options(repos="http://cran.itam.mx/")
library(dplyr)
library(lubridate)
library(ggplot2)
library(tidyr)
library(corrplot)

```

```

wdir <- normalizePath(file.path(dirname(rstudioapi::getActiveDocumentContext())$path), "..")
setwd(wdir)

# =====
# EDA --- Exploracion del dataset expandido
# =====

df <- read.csv("data/clean/pm25_valle_mexico.csv", stringsAsFactors=FALSE)
df$date <- as.Date(df$date)

cat("=== EDA: Valle de Mexico expandido ===\n")
cat("Observaciones:", nrow(df), "\n")
cat("Estaciones:", length(unique(df$estacion)), "\n")
cat("Periodo:", min(df$date), "a", max(df$date), "\n")

# Resumen por estacion
resumen <- df %>%
  group_by(estacion, ciudad, municipio, lat, lon) %>%
  summarise(
    n = n(),
    pm25_mean = mean(pm25),
    pm25_sd = sd(pm25),
    pm25_min = min(pm25),
    pm25_max = max(pm25),
    temp_mean = mean(temp),
    hr_mean = mean(hr),
    .groups = "drop"
  ) %>%
  arrange(desc(pm25_mean))

cat("\n--- Top 10 estaciones mas contaminadas ---\n")
print(head(resumen[, c("estacion", "municipio", "ciudad", "n", "pm25_mean")], 10))

cat("\n--- Top 10 estaciones menos contaminadas ---\n")
print(tail(resumen[, c("estacion", "municipio", "ciudad", "n", "pm25_mean")], 10))

# Comparacion CDMX vs Edomex vs Hidalgo
comp_ciudad <- df %>%
  group_by(ciudad) %>%
  summarise(
    n = n(),
    estaciones = n_distinct(estacion),
    pm25_mean = mean(pm25),
    pm25_sd = sd(pm25),
    temp_mean = mean(temp),
    hr_mean = mean(hr),
    .groups = "drop"
  )
cat("\n--- Comparacion por ciudad ---\n")
print(comp_ciudad)

# Serie temporal: promedio diario
daily_mean <- df %>%

```

```

group_by(date) %>%
  summarise(pm25 = mean(pm25), temp = mean(temp), hr = mean(hr), .groups="drop")

daily_long <- daily_mean %>%
  tidyr::pivot_longer(cols = c(pm25, temp, hr),
                      names_to = "variable",
                      values_to = "valor") %>%
  mutate(variable = factor(variable,
                          levels = c("pm25", "temp", "hr"),
                          labels = c("PM2.5 ( $\mu\text{g}/\text{m}^3$ )", "Temperatura ( $^{\circ}\text{C}$ )", "Humedad
                          relativa (%)"))))
p_series <- ggplot(daily_long, aes(x = date, y = valor, color = variable)) +
  geom_line(linewidth = 0.7, lineend = "round") +
  facet_wrap(~variable, scales = "free_y", ncol = 3) +
  scale_color_manual(values = c("PM2.5 ( $\mu\text{g}/\text{m}^3$ )" = "#E74C3C",
                              "Temperatura ( $^{\circ}\text{C}$ )" = "#3498DB",
                              "Humedad relativa (%)" = "#2ECC71")) +
  labs(title = "Series temporales diarias --- Valle de México 2023",
       subtitle = "Promedio de las 14 estaciones de monitoreo",
       x = NULL, y = NULL) +
  theme_minimal() +
  theme(legend.position = "none",
        plot.title = element_text(face = "bold", size = 13, color = "#2C3E50"),
        plot.subtitle = element_text(size = 9.5, face = "italic", color = "gray30"),
        panel.grid.minor = element_blank(),
        strip.text = element_text(face = "bold", size = 10))
ggsave("output/figures/eda_valle_series.png", plot = p_series,
       width = 12, height = 4, dpi = 120)
cat("\nGuardado: output/figures/eda_valle_series.png\n")

# Boxplot por estacion (ordenadas por PM2.5)
est_ord <- resumen$estacion[order(resumen$pm25_mean)]
df$estacion <- factor(df$estacion, levels=est_ord)

media_global <- mean(df$pm25)
p_box_est <- ggplot(df, aes(x = estacion, y = pm25, fill = ciudad)) +
  geom_boxplot(color = "#2C3E50", alpha = 0.75, outlier.alpha = 0.3, outlier.size =
    0.8) +
  geom_hline(yintercept = media_global, color = "#E74C3C", linetype = "dashed",
    linewidth = 0.8) +
  scale_fill_manual(values = c(cdmx = "#3498DB", edomex = "#E74C3C", hidalgo = "#2ECC71"),
    labels = c(cdmx = "CDMX", edomex = "Edo. Méx.", hidalgo = "Hidalgo")
  )) +
  annotate("text", x = 14.4, y = media_global + 0.5,
    label = paste0("Global: ", round(media_global, 1), "  $\mu\text{g}/\text{m}^3$ "),
    color = "#E74C3C", size = 3, hjust = 1) +
  coord_flip() +
  labs(title = "PM2.5 por estación --- Valle de México 2023",
       subtitle = "Estaciones ordenadas por PM2.5 promedio anual",
       x = NULL,
       y = expression(paste(PM[2.5], " (", mu, "g/", m^3, ")")),
       fill = "Entidad") +

```

```

theme_minimal() +
theme(plot.title      = element_text(face = "bold", size = 13, color = "#2C3E50"),
      plot.subtitle   = element_text(size = 9.5, face = "italic", color = "gray30"),
      panel.grid.minor = element_blank(),
      legend.position  = "bottom",
      legend.title     = element_text(face = "bold", size = 9))
ggsave("output/figures/eda_valle_boxplot_estacion.png", plot = p_box_est,
       width = 10, height = 7, dpi = 120)
cat("Guardado: output/figures/eda_valle_boxplot_estacion.png\n")

# Boxplot por mes
meses_esp <- c("Ene", "Feb", "Mar", "Abr", "May", "Jun", "Jul", "Ago", "Sep", "Oct", "Nov", "Dic")
df$mes_nombre <- factor(meses_esp[df$mes], levels=meses_esp)
p_box_mes <- ggplot(df, aes(x = mes_nombre, y = pm25)) +
  geom_boxplot(fill = "#3498DB", color = "#2C3E50", alpha = 0.7,
               outlier.alpha = 0.3, outlier.size = 0.8) +
  labs(title      = "PM2.5 por mes --- Valle de México 2023",
        subtitle  = "Distribución mensual agregada de las 14 estaciones",
        x = NULL,
        y = expression(paste(PM[2.5], " (", mu, "g/", m^3, ")")) +
  theme_minimal() +
  theme(plot.title      = element_text(face = "bold", size = 13, color = "#2C3E50"),
        plot.subtitle   = element_text(size = 9.5, face = "italic", color = "gray30"),
        panel.grid.minor = element_blank())
ggsave("output/figures/eda_valle_boxplot_mes.png", plot = p_box_mes,
       width = 9, height = 5, dpi = 120)
cat("Guardado: output/figures/eda_valle_boxplot_mes.png\n")

# Histogramas
df_hist <- data.frame(
  pm25      = df$pm25,
  log_pm25  = log(df$pm25),
  temp      = df$temp,
  hr        = df$hr
) %>%
  tidyr::pivot_longer(everything(), names_to = "variable", values_to = "valor") %>%
  mutate(variable = factor(variable,
                           levels = c("pm25", "log_pm25", "temp", "hr"),
                           labels = c("PM2.5 (µg/m³)", "log(PM2.5)", "Temperatura (°C)", "
Humedad relativa (%)"))))
p_hist <- ggplot(df_hist, aes(x = valor)) +
  geom_histogram(fill = "#3498DB", color = "white", bins = 30) +
  facet_wrap(~variable, scales = "free", ncol = 4) +
  labs(title      = "Distribución de variables --- Valle de México 2023",
        subtitle  = "Histogramas con 30 intervalos",
        x = NULL, y = "Frecuencia") +
  theme_minimal() +
  theme(plot.title      = element_text(face = "bold", size = 13, color = "#2C3E50"),
        plot.subtitle   = element_text(size = 9.5, face = "italic", color = "gray30"),
        panel.grid.minor = element_blank(),
        strip.text      = element_text(face = "bold", size = 9))
ggsave("output/figures/eda_valle_histogramas.png", plot = p_hist,
       width = 12, height = 4, dpi = 120)
cat("Guardado: output/figures/eda_valle_histogramas.png\n")

```

```

# Correlacion --- estilo Otho
vars_cor <- c("temp", "hr", "sen_t", "cos_t", "pm25")
labs_cor <- c("Temperatura", "Humedad rel.", "Sen estacional", "Cos estacional", "PM2.5")
cor_mat <- cor(df[, vars_cor], use = "complete.obs")
rownames(cor_mat) <- colnames(cor_mat) <- labs_cor

cor_long_eda <- as.data.frame(as.table(cor_mat), stringsAsFactors = FALSE)
names(cor_long_eda) <- c("var1", "var2", "corr")
cor_long_eda <- cor_long_eda[cor_long_eda$var1 != cor_long_eda$var2, ]
cor_long_eda$var1 <- factor(cor_long_eda$var1, levels = rev(labs_cor))
cor_long_eda$var2 <- factor(cor_long_eda$var2, levels = labs_cor)
cor_long_eda$txt_color <- ifelse(abs(cor_long_eda$corr) >= 0.35, "white", "#2C3E50")

p_cor <- ggplot(cor_long_eda, aes(x = var2, y = var1, fill = corr)) +
  geom_tile(color = "white", linewidth = 1.2) +
  geom_text(aes(label = sprintf("%.2f", corr), color = txt_color),
    size = 4, fontface = "bold") +
  scale_color_identity() +
  scale_fill_gradient2(low = "#E74C3C", mid = "#F7F7F7", high = "#3498DB",
    midpoint = 0, limits = c(-1, 1), name = "Correlación\nde Pearson") +
  coord_fixed() +
  labs(title = "Matriz de correlación --- Valle de México 2023",
    subtitle = "Correlación de Pearson entre PM2.5 y covariables climáticas",
    x = NULL, y = NULL) +
  theme_minimal() +
  theme(plot.title = element_text(face = "bold", size = 13, color = "#2C3E50"),
    plot.subtitle = element_text(size = 9.5, face = "italic", color = "gray30"),
    panel.grid = element_blank(),
    axis.text.x = element_text(face = "bold", size = 10, color = "#2C3E50",
      angle = 30, hjust = 1),
    axis.text.y = element_text(face = "bold", size = 10, color = "#2C3E50"),
    legend.title = element_text(face = "bold", size = 9),
    legend.position = "right")
ggsave("output/figures/eda_valle_correlacion.png", plot = p_cor,
  width = 6.5, height = 5.5, dpi = 120)
cat("Guardado: output/figures/eda_valle_correlacion.png\n")

# Scatter con lowess --- estilo Otho
df_sc <- data.frame(temp = df$temp, hr = df$hr, dia = df$dia_año, pm25 = df$pm25) %>%
  tidyr::pivot_longer(cols = c(temp, hr, dia), names_to = "cov", values_to = "x") %>%
  mutate(cov = factor(cov,
    levels = c("temp", "hr", "dia"),
    labels = c("Temperatura (°C)", "Humedad relativa (%)", "Día del año")
  )))
p_scatter <- ggplot(df_sc, aes(x = x, y = pm25)) +
  geom_point(color = "#7F8C8D", alpha = 0.20, size = 0.8) +
  geom_smooth(method = "loess", color = "#E74C3C", fill = "#E74C3C",
    alpha = 0.20, se = TRUE, linewidth = 1.0) +
  facet_wrap(~cov, scales = "free_x", ncol = 3) +
  labs(title = expression(paste(PM[2.5], " vs covariables --- Valle de México 2023"))
  ),

```

```

    subtitle = "Puntos observados con curva LOESS",
    x = NULL,
    y = expression(paste(PM[2.5], " (", mu, "g/", m^3, ")")) +
  theme_minimal() +
  theme(plot.title      = element_text(face = "bold", size = 13, color = "#2C3E50"),
        plot.subtitle   = element_text(size = 9.5, face = "italic", color = "gray30"),
        panel.grid.minor = element_blank(),
        strip.text       = element_text(face = "bold", size = 10))
ggsave("output/figures/eda_valle_scatter.png", plot = p_scatter,
       width = 12, height = 4.5, dpi = 120)
cat("Guardado: output/figures/eda_valle_scatter.png\n")

# Scatter log(PM2.5) vs covariables --- motiva la transformación log
df_scl <- data.frame(temp = df$temp, hr = df$hr, dia = df$dia_año, logpm25 = log(df$
  pm25)) %>%
  tidyr::pivot_longer(cols = c(temp, hr, dia), names_to = "cov", values_to = "x") %>%
  mutate(cov = factor(cov,
    levels = c("temp","hr","dia"),
    labels = c("Temperatura (°C)","Humedad relativa (%)","Día del año
      ")))
p_scl <- ggplot(df_scl, aes(x = x, y = logpm25)) +
  geom_point(color = "#7F8C8D", alpha = 0.20, size = 0.8) +
  geom_smooth(method = "loess", color = "#E74C3C", fill = "#E74C3C",
    alpha = 0.20, se = TRUE, linewidth = 1.0) +
  facet_wrap(~cov, scales = "free_x", ncol = 3) +
  labs(title = "log(PM2.5) vs covariables --- motiva transformación logarítmica",
    subtitle = "La relación es más lineal en escala log --- justifica el modelo
      Normal en log(PM2.5)",
    x = NULL, y = "log(PM2.5)") +
  theme_minimal() +
  theme(plot.title      = element_text(face = "bold", size = 13, color = "#2C3E50"),
        plot.subtitle   = element_text(size = 9.5, face = "italic", color = "gray30"),
        panel.grid.minor = element_blank(),
        strip.text       = element_text(face = "bold", size = 10))
ggsave("output/figures/eda_valle_scatter_log.png", plot = p_scl,
       width = 12, height = 4.5, dpi = 120)
cat("Guardado: output/figures/eda_valle_scatter_log.png\n")

# Scatter coloreado por ciudad --- heterogeneidad espacial antes del modelo
df_scc <- data.frame(temp = df$temp, hr = df$hr, dia = df$dia_año,
  pm25 = df$pm25, ciudad = df$ciudad) %>%
  tidyr::pivot_longer(cols = c(temp, hr, dia), names_to = "cov", values_to = "x") %>%
  mutate(cov = factor(cov,
    levels = c("temp","hr","dia"),
    labels = c("Temperatura (°C)","Humedad relativa (%)","Día del año
      ")),
    ciudad = factor(ciudad, levels = c("cdmx","edomex","hidalgo"),
      labels = c("CDMX","Edo. Méx.,"Hidalgo")))
p_scc <- ggplot(df_scc, aes(x = x, y = pm25, color = ciudad)) +
  geom_point(alpha = 0.25, size = 0.8) +
  scale_color_manual(values = c("CDMX" = "#3498DB", "Edo. Méx." = "#E74C3C", "Hidalgo"
    = "#2ECC71")) +
  facet_wrap(~cov, scales = "free_x", ncol = 3) +

```



```

labs(title = expression(paste(PM[2.5], " vs covariables por entidad ---
heterogeneidad espacial")),
      subtitle = "Cada punto es una observación diaria; colores por entidad federativa
",
      x = NULL,
      y = expression(paste(PM[2.5], " (", mu, "g/", m^3, ")")),
      color = "Entidad") +
theme_minimal() +
theme(plot.title = element_text(face = "bold", size = 13, color = "#2C3E50"),
      plot.subtitle = element_text(size = 9.5, face = "italic", color = "gray30"),
      panel.grid.minor = element_blank(),
      strip.text = element_text(face = "bold", size = 10),
      legend.position = "bottom",
      legend.title = element_text(face = "bold", size = 9))
ggsave("output/figures/eda_valle_scatter_ciudad.png", plot = p_scc,
      width = 12, height = 4.5, dpi = 120)
cat("Guardado: output/figures/eda_valle_scatter_ciudad.png\n")

# Guardar resumen
write.csv(resumen, "output/figures/eda_valle_resumen.csv", row.names=FALSE)
cat("\nResumen guardado: output/figures/eda_valle_resumen.csv\n")

```

Modelos A, B, C1, C2 y D — modelos_A_B_C1_DR

```

### ----- REGRESION AVANZADA ----- ###
# --- Modelos A, B, C1, D (14 estaciones) --- #

options(repos="http://cran.itam.mx/")

library(R2jags)
library(dplyr)
library(ggplot2)

prob <- function(x) {
  min(length(x[x>0])/length(x), length(x[x<0])/length(x))
}

diagnostico_cadena <- function(sim.obj, param.name, outdir, model.name) {
  out.a <- sim.obj$BUGSoutput$sims.array
  param.names <- dimnames(out.a)[[3]]
  idx <- grep(param.name, param.names, fixed = TRUE)
  if(length(idx) == 0) {
    cat("Parametro", param.name, "no encontrado en", model.name, "\n")
    return(NULL)
  }
  idx <- idx[1]
  z1 <- out.a[,1,idx]
  z2 <- out.a[,2,idx]
  png(file.path(outdir, paste0("diag_cadena_", model.name, "_", param.name, ".png")),
      width = 900, height = 900)
  par(mfrow=c(3,2))
  plot(z1, type="l", col="grey50", main = paste("Traza -", param.name))

```

```

lines(z2, col="firebrick2")
y1 <- cumsum(z1)/(1:length(z1))
y2 <- cumsum(z2)/(1:length(z2))
plot(y1, type="l", col="grey50", ylim=c(min(y1,y2), max(y1,y2)), main = "Media
  ergodica")
lines(y2, col="firebrick2")
hist(z1, freq=FALSE, col="grey50", main = paste("Posterior cadena 1 -", param.name))
hist(z2, freq=FALSE, col="firebrick2", main = paste("Posterior cadena 2 -", param.
  name))
acf(z1, main = "ACF cadena 1")
acf(z2, main = "ACF cadena 2")
dev.off()
cat(" Diagnostico guardado:", param.name, "\n")
}

wdir <- normalizePath(file.path(dirname(rstudioapi::getActiveDocumentContext())$path), ".")
setwd(wdir)
outdir <- "output/figures"

df <- read.csv("data/clean/pm25_valle_mexico.csv", stringsAsFactors = FALSE)

logy <- log(df$pm25)
temp.s <- scale(df$temp)[,1]
hr.s <- scale(df$hr)[,1]
sen_t <- df$sen_t
cos_t <- df$cos_t
est <- as.numeric(as.factor(df$estacion))
lat.s <- scale(df$lat)[,1]
lon.s <- scale(df$lon)[,1]

n <- length(logy)
J <- length(unique(est))

cat("=== Datos ===\n")
cat("Observaciones:", n, "\n")
cat("Estaciones:", J, "\n")
cat("Estaciones:", paste(levels(as.factor(df$estacion)), collapse = ", "), "\n\n")

# =====
#--- Modelo A: Normal global ---
# =====
cat("=== MODELO A: Normal global ===\n")

#-Defining data-
data.A <- list(n = n, logy = logy, temp = temp.s, hr = hr.s, sen_t = sen_t, cos_t = cos
  _t)

#-Defining inits-
inits.A <- function() list(alpha = 0, beta = rep(0,4), tau = 1)

#-Selecting parameters to monitor-
pars.A <- c("alpha", "beta", "tau", "sigma", "yf1")

```

```

#-Running code-
ejA <- jags(data.A, inits.A, pars.A, model.file = "scripts/jags_modelo_A_valle.txt",
            n.iter = 10000, n.chains = 2, n.burnin = 1000, n.thin = 1)

#-Monitoring chain-
resA <- ejA$BUGSoutput

save(ejA, file = file.path(outdir, "modelo_A.RData"))

cat("  Generando diagnosticos de cadena...\n")
diagnostico_cadena(ejA, "alpha", outdir, "A")
diagnostico_cadena(ejA, "beta[1]", outdir, "A")
diagnostico_cadena(ejA, "sigma", outdir, "A")

out.sum.A <- resA$summary
out.sum.t.A <- out.sum.A[grepl("beta", rownames(out.sum.A)), c(1,3,7)]
out.sum.t.A <- cbind(out.sum.t.A, apply(resA$sims.list$beta, 2, prob))
dimnames(out.sum.t.A)[[2]][4] <- "prob"
cat("\n--- Betas Modelo A ---\n")
print(out.sum.t.A)

R2.A <- cor(logy, apply(resA$sims.list$yf1, 2, mean))^2
cat("Modelo A: DIC =", resA$DIC, "| Pseudo-R2 =", round(R2.A, 4), "\n")

out.yf.A <- out.sum.A[grepl("yf1", rownames(out.sum.A)), ]
df_pvo <- data.frame(obs = logy, pred = out.yf.A[, 1])
rng <- range(logy, out.yf.A[, c(1, 3, 7)])
p_pvo <- ggplot(df_pvo, aes(x = obs, y = pred)) +
  geom_abline(slope = 1, intercept = 0, color = "gray70", linetype = "dashed", size =
    0.7) +
  geom_point(color = "#7F8C8D", alpha = 0.40, size = 1.2) +
  xlim(rng) + ylim(rng) +
  labs(
    title = "Modelo A: Observado vs Predicho",
    subtitle = "log(PM2.5) observado vs media posterior predictiva",
    x = "log(PM2.5) observado",
    y = "log(PM2.5) predicho (media posterior)"
  ) +
  theme_minimal() +
  theme(
    plot.title = element_text(face = "bold", size = 13, color = "#2C3E50"),
    plot.subtitle = element_text(size = 9.5, face = "italic", color = "gray30"),
    panel.grid.minor = element_blank()
  )
ggsave(file.path(outdir, "pred_vs_obs_A.png"), plot = p_pvo,
        width = 5, height = 5, dpi = 120)

write.csv(data.frame(parametro = c("alpha", "beta_temp", "beta_hr", "beta_sen", "beta_cos",
  "sigma", "DIC", "pseudo_R2"),
            media = c(resA$mean$alpha, resA$mean$beta, resA$mean$sigma, resA$
  DIC, R2.A)),
  file.path(outdir, "resumen_modelo_A.csv"), row.names = FALSE)

```

```

# =====
#--- Modelo B: Efectos fijos por estacion ---
# =====
cat("\n=== MODELO B: Efectos fijos por estacion ===\n")

#-Defining data-
data.B <- list(n = n, J = J, logy = logy, temp = temp.s, hr = hr.s, sen_t = sen_t, cos_
  t = cos_t, est = est)

#-Defining inits-
inits.B <- function() list(alpha = 0, beta = rep(0,4), alphaj = rep(0,J), tau = 1)

#-Selecting parameters to monitor-
pars.B <- c("alpha", "beta", "alphaj", "tau", "sigma", "yf1")

#-Running code-
ejB <- jags(data.B, inits.B, pars.B, model.file = "scripts/jags_modelo_B_valle.txt",
  n.iter = 12000, n.chains = 2, n.burnin = 2000, n.thin = 2)

#-Monitoring chain-
resB <- ejB$BUGSoutput

save(ejB, file = file.path(outdir, "modelo_B.RData"))

cat(" Generando diagnosticos de cadena...\n")
diagnostico_cadena(ejB, "alpha", outdir, "B")
diagnostico_cadena(ejB, "beta[1]", outdir, "B")
diagnostico_cadena(ejB, "sigma", outdir, "B")

out.sum.B <- resB$summary
out.sum.t.B <- out.sum.B[grep("beta", rownames(out.sum.B)), c(1,3,7)]
out.sum.t.B <- cbind(out.sum.t.B, apply(resB$sims.list$beta, 2, prob))
dimnames(out.sum.t.B)[[2]][4] <- "prob"
cat("\n--- Betas Modelo B ---\n")
print(out.sum.t.B)

alphaj_adj <- resB$mean$alphaj - mean(resB$mean$alphaj)
alpha_adj <- resB$mean$alpha + mean(resB$mean$alphaj)

out.alphaj.B <- out.sum.B[grep("^alphaj\\.adj\\[", rownames(out.sum.B)), c(1,3,7)]

alphaj_df <- data.frame(estacion = levels(as.factor(df$estacion)),
  alphaj_media = resB$mean$alphaj,
  alphaj_adj = alphaj_adj,
  alphaj_sd = resB$sd$alphaj)
write.csv(alphaj_df, file.path(outdir, "alphaj_modelo_B.csv"), row.names = FALSE)

R2.B <- cor(logy, apply(resB$sims.list$yf1, 2, mean))^2
cat("Modelo B: DIC =", resB$DIC, "| Pseudo-R2 =", round(R2.B, 4), "\n")

write.csv(data.frame(parametro = c("alpha_adj", "beta_temp", "beta_hr", "beta_sen", "beta_
  cos", "sigma", "DIC", "pseudo_R2"),
  media = c(alpha_adj, resB$mean$beta, resB$mean$sigma, resB$DIC, R2
  .B)),

```

```

        file.path(outdir, "resumen_modelo_B.csv"), row.names = FALSE)

# =====
#--- Modelo C1: Jerarquico Normal ---
# =====
cat("\n=== MODELO C1: Jerarquico Normal ===\n")

#-Defining data-
data.C1 <- list(n = n, J = J, logy = logy, temp = temp.s, hr = hr.s, sen_t = sen_t, cos
  _t = cos_t, est = est)

#-Defining inits-
inits.C1 <- function() list(alpha = 0, beta = rep(0,4), alphaj = rep(0,J), tau = 1, tau
  .alphaj = 1)

#-Selecting parameters to monitor-
pars.C1 <- c("alpha", "beta", "alphaj", "tau", "sigma", "tau.alphaj", "sigma.alphaj", "
  yf1")

#-Running code-
ejC1 <- jags(data.C1, inits.C1, pars.C1, model.file = "scripts/jags_modelo_C1_valle.txt
  ",
            n.iter = 12000, n.chains = 2, n.burnin = 2000, n.thin = 2)

#-Monitoring chain-
resC1 <- ejC1$BUGSoutput

save(ejC1, file = file.path(outdir, "modelo_C1.RData"))

cat(" Generando diagnosticos de cadena...\n")
diagnostico_cadena(ejC1, "alpha", outdir, "C1")
diagnostico_cadena(ejC1, "beta[1]", outdir, "C1")
diagnostico_cadena(ejC1, "sigma", outdir, "C1")
diagnostico_cadena(ejC1, "sigma.alphaj", outdir, "C1")

out.sum.C1 <- resC1$summary
out.sum.t.C1 <- out.sum.C1[grep("beta", rownames(out.sum.C1)), c(1,3,7)]
out.sum.t.C1 <- cbind(out.sum.t.C1, apply(resC1$sims.list$beta, 2, prob))
dimnames(out.sum.t.C1)[[2]][4] <- "prob"
cat("\n--- Betas Modelo C1 ---\n")
print(out.sum.t.C1)

out.alphaj.C1 <- out.sum.C1[grep("^alphaj\\\[", rownames(out.sum.C1)), c(1,3,7)]

k <- J
ymin <- min(out.alphaj.B[,2], out.alphaj.C1[,2]) - 0.05
ymax <- max(out.alphaj.B[,3], out.alphaj.C1[,3]) + 0.05

est_labels <- levels(as.factor(df$estacion))

df_efB <- data.frame(
  estacion = factor(est_labels, levels = est_labels),
  media = out.alphaj.B[, 1], q025 = out.alphaj.B[, 2], q975 = out.alphaj.B[, 3]

```

```

)
pB <- ggplot(df_efB, aes(x = estacion, y = media, ymin = q025, ymax = q975)) +
  geom_hline(yintercept = 0, color = "gray70", linetype = "dashed", linewidth = 0.6) +
  geom_errorbar(width = 0.3, color = "#3498DB", linewidth = 0.8) +
  geom_point(color = "#3498DB", size = 2.8) +
  ylim(ymin, ymax) +
  labs(title = "Modelo B: Efectos fijos por estación (alphaj, suma-cero)",
        subtitle = "IC 95% posterior --- restricción de identificabilidad aplicada en R"
        ,
        x = NULL, y = "Efecto por estación (log-unidades)") +
  theme_minimal() +
  theme(axis.text.x = element_text(angle = 45, hjust = 1, size = 8),
        plot.title = element_text(face = "bold", size = 13, color = "#2C3E50"),
        plot.subtitle = element_text(size = 9, face = "italic", color = "gray30"),
        panel.grid.minor = element_blank())
ggsave(file.path(outdir, "efectos_estacion_B.png"), plot = pB,
        width = 8.5, height = 5, dpi = 120)

df_efC1 <- data.frame(
  estacion = factor(est_labels, levels = est_labels),
  media = out.alphaj.C1[, 1], q025 = out.alphaj.C1[, 2], q975 = out.alphaj.C1[, 3]
)
pC1 <- ggplot(df_efC1, aes(x = estacion, y = media, ymin = q025, ymax = q975)) +
  geom_hline(yintercept = 0, color = "gray70", linetype = "dashed", linewidth = 0.6) +
  geom_errorbar(width = 0.3, color = "#E74C3C", linewidth = 0.8) +
  geom_point(color = "#E74C3C", size = 2.8) +
  ylim(ymin, ymax) +
  labs(title = "Modelo C1: Efectos aleatorios por estación (alphaj)",
        subtitle = "IC 95% posterior --- hiperprior N(0, tau_alpha), shrinkage bayesiano"
        ,
        x = NULL, y = "Efecto por estación (log-unidades)") +
  theme_minimal() +
  theme(axis.text.x = element_text(angle = 45, hjust = 1, size = 8),
        plot.title = element_text(face = "bold", size = 13, color = "#2C3E50"),
        plot.subtitle = element_text(size = 9, face = "italic", color = "gray30"),
        panel.grid.minor = element_blank())
ggsave(file.path(outdir, "efectos_estacion_C1.png"), plot = pC1,
        width = 8.5, height = 5, dpi = 120)

alphaj_C1 <- data.frame(estacion = levels(as.factor(df$estacion)),
  alphaj_media = resC1$mean$alphaj,
  alphaj_sd = resC1$sd$alphaj)
write.csv(alphaj_C1, file.path(outdir, "alphaj_modelo_C1.csv"), row.names = FALSE)

R2.C1 <- cor(logy, apply(resC1$sims.list$yf1, 2, mean))^2
cat("Modelo C1: DIC =", resC1$DIC, "| Pseudo-R2 =", round(R2.C1, 4), "| sigma.alphaj =",
    , round(resC1$mean$sigma.alphaj, 4), "\n")

write.csv(data.frame(parametro = c("alpha", "beta_temp", "beta_hr", "beta_sen", "beta_cos",
  "sigma", "sigma.alphaj", "DIC", "pseudo_R2"),
  media = c(resC1$mean$alpha, resC1$mean$beta, resC1$mean$sigma,
    resC1$mean$sigma.alphaj, resC1$DIC, R2.C1)),
  file.path(outdir, "resumen_modelo_C1.csv"), row.names = FALSE)

```

```

# =====
#--- Modelo D: Tendencia espacial directa ---
# =====
cat("\n=== MODELO D: Tendencia espacial directa ===\n")

#-Defining data-
data.D <- list(n = n, logy = logy, temp = temp.s, hr = hr.s, sen_t = sen_t, cos_t = cos
  _t, lat = lat.s, lon = lon.s)

#-Defining inits-
inits.D <- function() list(alpha = 0, beta = rep(0,6), tau = 1)

#-Selecting parameters to monitor-
pars.D <- c("alpha", "beta", "tau", "sigma", "yf1")

#-Running code-
ejD <- jags(data.D, inits.D, pars.D, model.file = "scripts/jags_modelo_D_valle.txt",
  n.iter = 10000, n.chains = 2, n.burnin = 1000, n.thin = 1)

#-Monitoring chain-
resD <- ejD$BUGSoutput

save(ejD, file = file.path(outdir, "modelo_D.RData"))

cat(" Generando diagnosticos de cadena...\n")
diagnostico_cadena(ejD, "alpha", outdir, "D")
diagnostico_cadena(ejD, "beta[1]", outdir, "D")
diagnostico_cadena(ejD, "sigma", outdir, "D")

out.sum.D <- resD$summary
out.sum.t.D <- out.sum.D[grep("beta", rownames(out.sum.D)), c(1,3,7)]
out.sum.t.D <- cbind(out.sum.t.D, apply(resD$sims.list$beta, 2, prob))
dimnames(out.sum.t.D)[[2]][4] <- "prob"
cat("\n--- Betas Modelo D ---\n")
print(out.sum.t.D)

R2.D <- cor(logy, apply(resD$sims.list$yf1, 2, mean))^2
cat("Modelo D: DIC =", resD$DIC, "| Pseudo-R2 =", round(R2.D, 4), "\n")

write.csv(data.frame(parametro = c("alpha","beta_temp","beta_hr","beta_sen","beta_cos",
  "beta_lat","beta_lon","sigma","DIC","pseudo_R2"),
  media = c(resD$mean$alpha, resD$mean$beta, resD$mean$sigma, resD$
    DIC, R2.D)),
  file.path(outdir, "resumen_modelo_D.csv"), row.names = FALSE)

# =====
#--- Comparacion de modelos ---
# =====
cat("\n=== COMPARACION DE MODELOS ===\n")

comp <- data.frame(
  Modelo = c("A","B","C1","D"),

```

```

DIC = c(resA$DIC, resB$DIC, resC1$DIC, resD$DIC),
pseudo_R2 = c(R2.A, R2.B, R2.C1, R2.D),
sigma = c(resA$mean$sigma, resB$mean$sigma, resC1$mean$sigma, resD$mean$sigma)
)
print(comp)
write.csv(comp, file.path(outdir, "comparacion_modelos.csv"), row.names = FALSE)

# =====
#--- Modelo C2: Gamma global ---
# =====
cat("\n=== MODELO C2: Gamma global ===\n")

#-Variables centradas (no estandarizadas: mas estable para Gamma en JAGS)-
tempc <- df$temp - mean(df$temp)
hrc <- df$hr - mean(df$hr)

#-Defining data-
data.C2 <- list(n = n, pm25 = df$pm25, tempc = tempc, hrc = hrc, sen_t = sen_t, cos_t =
cos_t)

#-Defining inits-
inits.C2 <- function() list(alpha = log(mean(df$pm25)), beta = rep(0,4), a = 1)

#-Selecting parameters to monitor-
pars.C2 <- c("alpha", "beta", "a", "sigma.C2", "yf1")

#-Running code-
ejC2 <- jags(data.C2, inits.C2, pars.C2, model.file = "scripts/jags_modelo_C2_gamma_
valle.txt",
n.iter = 15000, n.chains = 2, n.burnin = 3000, n.thin = 3)

#-Monitoring chain-
resC2 <- ejC2$BUGSoutput

save(ejC2, file = file.path(outdir, "modelo_C2.RData"))

cat(" Generando diagnosticos de cadena...\n")
diagnostico_cadena(ejC2, "alpha", outdir, "C2")
diagnostico_cadena(ejC2, "beta[1]", outdir, "C2")
diagnostico_cadena(ejC2, "a", outdir, "C2")

out.sum.C2 <- resC2$summary
out.sum.t.C2 <- out.sum.C2[grepl("beta", rownames(out.sum.C2)), c(1,3,7)]
out.sum.t.C2 <- cbind(out.sum.t.C2, apply(resC2$sims.list$beta, 2, prob))
dimnames(out.sum.t.C2)[[2]][4] <- "prob"
cat("\n--- Betas Modelo C2 ---\n")
print(out.sum.t.C2)

# pseudo-R2 en escala log para comparar con modelos Normal
R2.C2 <- cor(log(df$pm25), log(apply(resC2$sims.list$yf1, 2, mean)))^2
cat("Modelo C2 (Gamma): DIC =", resC2$DIC, "| Pseudo-R2 (log) =", round(R2.C2, 4), "\n"
)
cat("NOTA: DIC de C2 NO es comparable con A/B/C1/D (familia diferente).\n")

```



```
cat("      Usar pseudo-R2 en escala log para comparar entre familias.\n")

write.csv(data.frame(parametro = c("alpha","beta_temp","beta_hr","beta_sen","beta_cos",
  "a","DIC","pseudo_R2_log"),
              media = c(resC2$mean$alpha, resC2$mean$beta, resC2$mean$a, resC2$
  DIC, R2.C2)),
  file.path(outdir, "resumen_modelo_C2.csv"), row.names = FALSE)
```

Modelo E — Proceso Gaussiano y Kriging — modelo_E_valleR

```
### ----- REGRESION AVANZADA ----- ###
# --- Modelo E: GP espacial (14 estaciones) --- #

options(repos="http://cran.itam.mx/")

library(R2jags)
library(terra)
library(dplyr)
library(ggplot2)

prob <- function(x) {
  min(length(x[x>0])/length(x), length(x[x<0])/length(x))
}

diagnostico_cadena <- function(sim.obj, param.name, outdir, model.name) {
  out.a <- sim.obj$BUGSoutput$sims.array
  param.names <- dimnames(out.a)[[3]]
  idx <- grep(param.name, param.names, fixed = TRUE)
  if(length(idx) == 0) {
    cat("Parametro", param.name, "no encontrado en", model.name, "\n")
    return(NULL)
  }
  idx <- idx[1]
  z1 <- out.a[,1,idx]
  z2 <- out.a[,2,idx]
  png(file.path(outdir, paste0("diag_cadena_", model.name, "_", param.name, ".png")),
    width = 900, height = 900)
  par(mfrow=c(3,2))
  plot(z1, type="l", col="grey50", main = paste("Traza -", param.name))
  lines(z2, col="firebrick2")
  y1 <- cumsum(z1)/(1:length(z1))
  y2 <- cumsum(z2)/(1:length(z2))
  plot(y1, type="l", col="grey50", ylim=c(min(y1,y2), max(y1,y2)), main = "Media
    ergodica")
  lines(y2, col="firebrick2")
  hist(z1, freq=FALSE, col="grey50", main = paste("Posterior cadena 1 -", param.name))
  hist(z2, freq=FALSE, col="firebrick2", main = paste("Posterior cadena 2 -", param.
    name))
  acf(z1, main = "ACF cadena 1")
  acf(z2, main = "ACF cadena 2")
  dev.off()
  cat(" Diagnostico guardado:", param.name, "\n")
}
```

```

}

wdir <- normalizePath(file.path(dirname(rstudioapi::getActiveDocumentContext())$path), "
  .."))
setwd(wdir)
outdir <- "output/figures"

df <- read.csv("data/clean/pm25_valle_mexico.csv", stringsAsFactors = FALSE)

logy <- log(df$pm25)
temp.s <- scale(df$temp)[,1]
hr.s <- scale(df$hr)[,1]
sen_t <- df$sen_t
cos_t <- df$cos_t
est <- as.numeric(as.factor(df$estacion))
n <- length(logy)
J <- length(unique(est))

cat("=== Modelo E ===\n")
cat("Observaciones:", n, "| Estaciones:", J, "\n")

# =====
#--- Modelo C1 (base para GP espacial) ---
# =====
cat("\n=== Ajustando Modelo C1 (base del GP) ===\n")

#-Defining data-
data.C1 <- list(n = n, J = J, logy = logy, temp = temp.s, hr = hr.s, sen_t = sen_t, cos
  _t = cos_t, est = est)

#-Defining inits-
inits.C1 <- function() list(alpha = 0, beta = rep(0,4), alphaj = rep(0,J), tau = 1, tau
  .alphaj = 1)

#-Selecting parameters to monitor-
pars.C1 <- c("alpha", "beta", "alphaj", "tau", "sigma", "tau.alphaj", "sigma.alphaj", "
  yf1")

#-Running code-
ejC1 <- jags(data.C1, inits.C1, pars.C1, model.file = "scripts/jags_modelo_C1_valle.txt
  ",
  n.iter = 12000, n.chains = 2, n.burnin = 2000, n.thin = 2)

#-Monitoring chain-
resC1 <- ejC1$BUGSoutput

save(ejC1, file = file.path(outdir, "modelo_E_C1base.RData"))

cat(" Generando diagnosticos de cadena...\n")
diagnostico_cadena(ejC1, "alpha", outdir, "E_C1")
diagnostico_cadena(ejC1, "beta[1]", outdir, "E_C1")
diagnostico_cadena(ejC1, "sigma", outdir, "E_C1")
diagnostico_cadena(ejC1, "sigma.alphaj", outdir, "E_C1")

```

```

out.sum.C1 <- resC1$summary
out.sum.t.C1 <- out.sum.C1[grepl("beta", rownames(out.sum.C1)), c(1,3,7)]
out.sum.t.C1 <- cbind(out.sum.t.C1, apply(resC1$sims.list$beta, 2, prob))
dimnames(out.sum.t.C1)[[2]][4] <- "prob"
cat("\n--- Betas C1 (base E) ---\n")
print(out.sum.t.C1)

out.alphaj <- out.sum.C1[grepl("alphaj", rownames(out.sum.C1)), c(1,3,7)]
out.alphaj <- out.alphaj[1:J, ]

estaciones_ord <- sort(unique(df$estacion))
df_ef <- data.frame(
  estacion = factor(estaciones_ord, levels = estaciones_ord[order(out.alphaj[, 1])]),
  media     = out.alphaj[, 1],
  q025      = out.alphaj[, 2],
  q975      = out.alphaj[, 3]
)
p_ef <- ggplot(df_ef, aes(x = estacion, y = media)) +
  geom_hline(yintercept = 0, color = "#7F8C8D", linetype = "dashed", linewidth = 0.7) +
  geom_errorbar(aes(ymin = q025, ymax = q975),
    width = 0.3, color = "#9B59B6", linewidth = 0.7) +
  geom_point(color = "#2C3E50", size = 2.5) +
  coord_flip() +
  labs(
    title     = "Modelo E: Efectos espaciales (alphaj) --- base C1",
    subtitle  = "Media posterior e IC 95% --- cada punto es una estación de monitoreo",
    x         = NULL,
    y         = expression(paste("Efecto espacial aditivo en log(", PM[2.5], ")"))
  ) +
  theme_minimal() +
  theme(
    plot.title       = element_text(face = "bold", size = 13, color = "#2C3E50"),
    plot.subtitle    = element_text(size = 9.5, face = "italic", color = "gray30"),
    panel.grid.minor = element_blank(),
    axis.text.y      = element_text(size = 9, color = "#2C3E50")
  )
ggsave(file.path(outdir, "efectos_espaciales_E.png"),
  plot = p_ef, width = 7.5, height = 5.5, dpi = 120)

R2.C1 <- cor(logy, apply(resC1$sims.list$yf1, 2, mean))^2
cat("C1 base: DIC =", resC1$DIC, "| Pseudo-R2 =", round(R2.C1, 4), "\n")

# =====
#--- Prediccion espacial (Kriging bayesiano) ---
# =====
cat("\n=== Prediccion espacial (GP) ===\n")

est_coords <- df %>%
  group_by(estacion) %>%
  summarise(lon = mean(lon), lat = mean(lat), .groups = "drop")
est_coord <- as.matrix(est_coords[, c("lon", "lat")])

centroids_df <- read.csv("data/clean/centroides_valle.csv", stringsAsFactors = FALSE)

```

```

K <- nrow(centroids_df)
cent_coord <- as.matrix(centroids_df[, c("lon", "lat")])
cat("Poligonos a predecir:", K, "\n")

D_obs <- as.matrix(dist(est_coord))
D_pred_obs <- matrix(0, K, J)
for(k in 1:K) {
  for(j in 1:J) {
    D_pred_obs[k, j] <- sqrt((cent_coord[k,1] - est_coord[j,1])^2 +
                             (cent_coord[k,2] - est_coord[j,2])^2)
  }
}

rho <- 0.08
cat("Rango espacial rho:", rho, "grados (~", round(rho * 111, 1), "km)\n")

sims <- resC1$sims.list
n_sims_total <- length(sims$alpha)
set.seed(42)
idx_sims <- sample(1:n_sims_total, min(2000, n_sims_total))
n_sims <- length(idx_sims)
cat("Muestras MCMC usadas:", n_sims, "\n")

alpha_s <- sims$alpha[idx_sims]
beta_s <- sims$beta[idx_sims, ]
alphaj_s <- sims$alphaj[idx_sims, ]

temp_bar_s <- 0 # covariables en su media: estandarizada = 0
hr_bar_s <- 0
sen_bar <- mean(df$sen_t)
cos_bar <- mean(df$cos_t)

Sigma_obs_obs <- exp(-D_obs / rho)
Sigma_obs_obs_inv <- solve(Sigma_obs_obs)
Sigma_pred_obs <- exp(-D_pred_obs / rho)

logy_pred <- matrix(0, K, n_sims)
for(m in 1:n_sims) {
  w_pred <- Sigma_pred_obs %*% (Sigma_obs_obs_inv %*% alphaj_s[m, ])
  mu_fixed <- alpha_s[m] + beta_s[m,1]*temp_bar_s + beta_s[m,2]*hr_bar_s +
    beta_s[m,3]*sen_bar + beta_s[m,4]*cos_bar
  logy_pred[, m] <- mu_fixed + w_pred[, 1]
}

pm25_mean <- exp(rowMeans(logy_pred))
pm25_sd <- exp(apply(logy_pred, 1, sd))
pm25_q2.5 <- exp(apply(logy_pred, 1, quantile, probs = 0.025))
pm25_q97.5 <- exp(apply(logy_pred, 1, quantile, probs = 0.975))

pred_df <- data.frame(
  name = centroids_df$name,
  name_1 = centroids_df$name_1,
  lon = centroids_df$lon,
  lat = centroids_df$lat,

```

```

    pm25_mean = pm25_mean,
    pm25_sd = pm25_sd,
    pm25_q2.5 = pm25_q2.5,
    pm25_q97.5 = pm25_q97.5,
    stringsAsFactors = FALSE
  )

write.csv(pred_df, file.path(outdir, "prediccion_espacial_E_valle.csv"), row.names =
  FALSE)
cat("Predicciones guardadas:\n")

# =====
#--- Mapas ---
# =====
cat("\n=== Generando mapas ===\n")

mex <- vect("data/gadm_mexico/gadm41_MEX_2.shp")
valle <- mex[mex$NAME_1 %in% c("Distrito Federal", "México"), ]

pred_order <- match(valle$NAME_2, pred_df$name)
valle$pm25_mean <- pred_df$pm25_mean[pred_order]
valle$pm25_q2.5 <- pred_df$pm25_q2.5[pred_order]
valle$pm25_q97.5 <- pred_df$pm25_q97.5[pred_order]

# Cortes adaptados al rango real de predicciones (intervalos de 0.5 ug/m3)
pred_min <- floor(min(pred_df$pm25_mean, na.rm = TRUE) * 2) / 2
pred_max <- ceiling(max(pred_df$pm25_mean, na.rm = TRUE) * 2) / 2
cats <- seq(pred_min, pred_max, by = 0.5)
n_cats <- length(cats) - 1
colors <- colorRampPalette(c("#ffffcc", "#fd8d3c", "#b10026"))(n_cats)
valle$cat <- cut(valle$pm25_mean, breaks = cats, include.lowest = TRUE)

est_unique <- aggregate(cbind(lon, lat) ~ estacion, data = df, FUN = mean)
est_unique <- est_unique[order(est_unique$estacion), ]
est_unique$num <- 1:nrow(est_unique)

png(file.path(outdir, "mapa_prediccion_E_valle.png"), width = 1400, height = 1000, res
  = 120)
par(oma = c(0, 0, 2, 0), mar = c(2, 2, 1, 9))
plot(valle, "cat", col = colors)
mtext("PM2.5 predicho --- Modelo E (GP espacial, 14 estaciones)",
  outer = TRUE, side = 3, line = 0.5, font = 2, cex = 1.05, col = "#2C3E50")
points(est_unique$lon, est_unique$lat, pch = 21, bg = "white", col = "black", cex = 2,
  lwd = 2)
text(est_unique$lon, est_unique$lat, labels = est_unique$num,
  pos = 3, cex = 0.9, col = "black", font = 2, offset = 0.5)
legend("right", inset = c(-0.04, 0),
  legend = paste0(est_unique$num, ". ", est_unique$estacion),
  title = "Estaciones", bg = "white", cex = 0.7, xpd = TRUE, bty = "n")
legend("bottomleft", inset = c(0.06, 0.02), legend = levels(valle$cat), fill = colors,
  title = "PM2.5 ( $\mu\text{g}/\text{m}^3$ )", bg = "white", cex = 0.85)
dev.off()
cat("Mapa de prediccion guardado\n")

```

```

# =====
#--- Resúmenes ---
# =====
cat("\n=== Resumen ===\n")
resumen_estado <- aggregate(pm25_mean ~ name_1, data = pred_df, FUN = function(x)
  c(mean = mean(x), sd = sd(x), min = min(x), max = max(x)))
print(resumen_estado)

cat("\n--- Top 10 mas contaminados ---\n")
print(head(pred_df[order(-pred_df$pm25_mean), c("name", "name_1", "pm25_mean", "pm25_q2
.5", "pm25_q97.5")], 10))

cat("\n--- Top 10 menos contaminados ---\n")
print(head(pred_df[order(pred_df$pm25_mean), c("name", "name_1", "pm25_mean", "pm25_q2
.5", "pm25_q97.5")], 10))

cat("\n--- Rango total ---\n")
cat("Min:", round(min(pred_df$pm25_mean), 1), "| Max:", round(max(pred_df$pm25_mean),
1),
"| SD entre poligonos:", round(sd(pred_df$pm25_mean), 2), "\n")

```

Mapa de predicción espacial — mapa_valle_mexico.R

```

options(repos="http://cran.itam.mx/")

library(dplyr)
library(terra)
library(RColorBrewer)

wdir <- normalizePath(file.path(dirname(rstudioapi::getActiveDocumentContext())$path), ".")
setwd(wdir)

imgdir <- file.path(wdir, "output/figures/")
dir.create(imgdir, recursive=TRUE, showWarnings=FALSE)

# =====
# 1. Carga de datos
# =====
df_est <- read.csv("data/clean/resumen_valle_mexico.csv", stringsAsFactors=FALSE)

# =====
# 2. Shapefile GADM nivel 2
# =====
mex_mun <- vect("data/gadm_mexico/gadm41_MEX_2.shp")
cdmx_map <- mex_mun[mex_mun$NAME_1 == "Distrito Federal", ]
edomex_map <- mex_mun[mex_mun$NAME_1 == "México", ]
valle_map <- rbind(cdmx_map, edomex_map)
n_pol <- nrow(valle_map)

```

```

# =====
# 3. Centros de poligonos y asignacion de estaciones
# =====
g <- geom(valle_map, wkt=FALSE)
centros <- matrix(0, nrow=n_pol, ncol=2)
for (j in 1:n_pol) {
  centros[j, ] <- apply(g[g[,1]==j, 3:4, drop=FALSE], 2, mean, na.rm=TRUE)
}

idx_municipios <- integer(nrow(df_est))
for (i in 1:nrow(df_est)) {
  est <- df_est[i, ]
  dists <- sqrt((centros[,1] - est$lon)^2 + (centros[,2] - est$lat)^2)
  idx_municipios[i] <- which.min(dists)
}

# =====
# 4. Coloreo
# =====
breaks <- c(0, 16, 18, 20, 22, 24, 100)
labels <- c("0-16", "16-18", "18-20", "20-22", "22-24", ">24")
plotclr <- c("#FFFFB2", "#FED976", "#FEB24C", "#FD8D3C", "#FC4E2A", "#E31A1C")

get_color <- function(pm) {
  if (is.na(pm)) return("grey93")
  k <- findInterval(pm, breaks, rightmost.closed=TRUE)
  if (k < 1 || k > length(plotclr)) return("grey93")
  return(plotclr[k])
}

colores <- rep("grey93", n_pol)
pm_vals <- df_est$pm25_mean
for (i in seq_along(pm_vals)) {
  colores[idx_municipios[i]] <- get_color(pm_vals[i])
}

# =====
# 5. Mapa con nombres en centroides
# =====
png(file.path(imgdir, "mapa_valle_mexico.png"), width=1100, height=950)
par(mfrow=c(1,1), mar=c(4,4,5,8))

plot(valle_map, fill=TRUE, col=colores, border="grey55", lwd=0.4,
      xlim=c(-99.35, -98.95), ylim=c(19.15, 19.65),
      main="Valle de Mexico --- Alcaldias y municipios con monitoreo de PM2.5 (2023)",
      xlab="Longitud", ylab="Latitud", cex.main=1.1)

# Nombres de TODOS los municipios/alcaldias en centroides
for (j in 1:n_pol) {
  # Solo mostrar nombres de CDMX + municipios de Edomex cercanos (dentro de ventana)
  cx <- centros[j,1]
  cy <- centros[j,2]
  if (cx > -99.35 && cx < -98.95 && cy > 19.15 && cy < 19.65) {
    nombre <- valle_map$NAME_2[j]
  }
}

```

```

# Acortar nombres muy largos
nombre <- gsub(" de Morelos| de Baz| Contreras", "", nombre)
text(cx, cy, labels=nombre, cex=0.5, col="grey25", font=1)
}
}

# Resaltar bordes de poligonos con estacion
for (i in seq_along(idx_municipios)) {
  plot(valle_map[idx_municipios[i]], add=TRUE, border="grey15", lwd=1.5)
}

# Puntos de estaciones
pm_range <- range(pm_vals)
tamanos <- 2.2 + (pm_vals - pm_range[1]) / max(1, diff(pm_range)) * 3.0
puntos_col <- ifelse(df_est$ciudad == "cdmx", "firebrick2", "steelblue")

points(df_est$lon, df_est$lat,
       pch=21, bg=puntos_col, col="black", cex=tamanos, lwd=1.5)

# Etiquetas de estaciones
for (i in 1:nrow(df_est)) {
  text(df_est$lon[i], df_est$lat[i],
       labels=paste0(df_est$estacion[i], " (", round(df_est$pm25_mean[i],1), ")"),
       pos=4, cex=0.65, offset=0.4, font=2)
}

# Leyenda de colores
legend(x=-98.90, y=19.60,
      legend=labels,
      fill=plotclr, bty="n", cex=0.85, xpd=TRUE,
      title="PM2.5 (ug/m3)")

# Leyenda de puntos
legend(x=-98.90, y=19.40,
      legend=c("CDMX", "Edomex"),
      pch=21, pt.bg=c("firebrick2", "steelblue"), pt.cex=1.8, bty="n", cex=0.8, xpd=
      TRUE)

dev.off()
cat("Guardado: mapa_valle_mexico.png\n")

```

Modelo F, Etapa 1 — Espacio-temporal MCMC — Contaminacion Fase1 SerieT

```

### ----- REGRESION AVANZADA ----- ###
# --- Modelo espacio-temporal Bayesiano --- Panel balanceado 365x14 + imputación MCMC
--- #
# NOTA: Requiere scripts/jags_modelo_espacio_temporal.txt (pedir a Otho)

library(dplyr)
library(sf)
library(tidyr)
library(R2jags)

```



```

library(ggplot2)

wdir <- normalizePath(file.path(dirname(rstudioapi::getActiveDocumentContext())$path), "..")
setwd(wdir)

ruta_archivo <- "data/clean/pm25_valle_mexico.csv"

df_original <- read.csv(ruta_archivo)
df_original$date <- as.Date(df_original$date)

# --- Matriz de distancias en km (UTM 14N) ---

nodos_geo <- df_original %>%
  select(estacion, lat, lon) %>%
  distinct() %>%
  arrange(estacion)

estaciones_utm <- st_as_sf(nodos_geo, coords = c("lon", "lat"), crs = 4326) %>%
  st_transform(crs = 32614)

D_km <- as.matrix(st_distance(estaciones_utm)) / 1000

# --- Panel balanceado 365x14 --- NAs solo en log_pm25 (imputados por JAGS) ---

dias_ano <- seq(as.Date("2023-01-01"), as.Date("2023-12-31"), by = "day")
estaciones <- nodos_geo$estacion

grid_completo <- expand.grid(date = dias_ano, estacion = estaciones) %>%
  left_join(df_original, by = c("date", "estacion")) %>%
  group_by(estacion) %>%
  mutate(
    temp = ifelse(is.na(temp), mean(temp, na.rm = TRUE), temp),
    hr = ifelse(is.na(hr), mean(hr, na.rm = TRUE), hr)
  ) %>%
  ungroup() %>%
  arrange(estacion, date)

matriz_y <- matrix(log(grid_completo$pm25), nrow = 365)
matriz_temp <- matrix(grid_completo$temp, nrow = 365)
matriz_hr <- matrix(grid_completo$hr, nrow = 365)

dia_juliano <- as.numeric(format(dias_ano, "%j"))
vector_sen <- sin(2 * pi * dia_juliano / 365)
vector_cos <- cos(2 * pi * dia_juliano / 365)

jags_data <- list(
  log_pm25 = matriz_y, temp = matriz_temp, hr = matriz_hr,
  sen_t = vector_sen, cos_t = vector_cos,
  N_dias = 365, N_estaciones = 14, D = D_km
)

print(paste("Estructura Balanceada. Datos faltantes (NAs) preservados para imputación
MCMC:", sum(is.na(matriz_y))))

```

```

# --- MCMC ---

jags_inits <- function() {
  list(beta = rnorm(4, 0, 0.1), alphaj = rep(0, 14),
        tau_y = 1, tau_alpha = 1, phi = 0.5)
}

jags_parameters <- c("beta", "alphaj", "tau_y", "tau_alpha", "phi", "log_pm25")
ruta_modelo_txt <- "scripts/jags_modelo_espacio_temporal.txt"

output_jags <- jags.parallel(
  data          = jags_data,
  inits          = jags_inits,
  parameters.to.save = jags_parameters,
  model.file     = ruta_modelo_txt,
  n.chains       = 2,
  n.iter         = 10000,
  n.burnin       = 3000,
  n.thin         = 4
)

print(output_jags$BUGSoutput$summary["beta[1]", c("mean", "sd", "2.5%", "97.5%", "Rhat",
  "n.eff")])

# --- Diagnóstico MCMC: panel 3x2 para beta[1] ---

generar_panel_beta1_3x2 <- function(output_jags) {
  beta_c1 <- output_jags$BUGSoutput$sims.array[, 1, "beta[1]"]
  beta_c2 <- output_jags$BUGSoutput$sims.array[, 2, "beta[1]"]
  N_iter <- length(beta_c1)

  par(mfrow = c(3, 2), mar = c(4, 4, 2, 1), oma = c(0, 0, 3, 0))

  plot(1:N_iter, beta_c1, type = "l", col = "#3498DB", xlab = "Iteración", ylab = "
    Valor", main = "1. Traza (beta1)")
  lines(1:N_iter, beta_c2, col = "#E74C3C")

  mean_b1 <- cumsum(beta_c1) / (1:N_iter)
  mean_b2 <- cumsum(beta_c2) / (1:N_iter)
  plot(1:N_iter, mean_b1, type = "l", col = "#3498DB", ylim = range(c(mean_b1, mean_b2)
    ), xlab = "Iteración", ylab = "Media", main = "2. Media Móvil (beta1)")
  lines(1:N_iter, mean_b2, col = "#E74C3C")

  hist(beta_c1, breaks = 25, col = "#3498DB", border = "white", xlab = "Valor", ylab = "
    Frecuencia", main = "3. Histograma C1")
  hist(beta_c2, breaks = 25, col = "#E74C3C", border = "white", xlab = "Valor", ylab = "
    Frecuencia", main = "4. Histograma C2")

  acf_b1 <- acf(beta_c1, plot = FALSE, lag.max = 30)
  plot(acf_b1$lag, acf_b1$acf, type = "h", col = "#000000", lwd = 2, xlab = "Lag", ylab = "
    ACF", main = "5. Autocorrelación C1")
  abline(h = c(-1.96/sqrt(N_iter), 1.96/sqrt(N_iter)), col = "gray", lty = 2)
}

```

```

acf_b2 <- acf(beta_c2, plot = FALSE, lag.max = 30)
plot(acf_b2$lag, acf_b2$acf, type = "h", col = "#000000", lwd = 2, xlab = "Lag", ylab
     = "ACF", main = "6. Autocorrelación C2")
abline(h = c(-1.96/sqrt(N_iter), 1.96/sqrt(N_iter)), col = "gray", lty = 2)

title(main = "Diagnóstico MCMC: beta[1]", outer = TRUE, font = 2)
par(mfrow = c(1, 1))
}

generar_panel_beta1_3x2(output_jags)

# --- Inferencia posterior: Ajusco Medio ---

resumen_jags <- output_jags$BUGSoutput$summary
indices_log_pm25 <- grep("^log_pm25", rownames(resumen_jags))
df_log_pm25 <- as.data.frame(resumen_jags[indices_log_pm25, c("mean", "2.5%", "97.5%")
])

df_post_analisis <- grid_completo %>%
  mutate(
    pm25_estimado = exp(df_log_pm25$mean),
    ic_inferior    = exp(df_log_pm25$'2.5%'),
    ic_superior    = exp(df_log_pm25$'97.5%'),
    id_estacion    = as.numeric(as.factor(estacion))
  )

df_ajusco <- df_post_analisis %>% filter(estacion == "Ajusco Medio")

ggplot(df_ajusco, aes(x = date)) +
  geom_ribbon(aes(ymin = ic_inferior, ymax = ic_superior, fill = "Incertidumbre MCMC
    (95%)"), alpha = 0.25) +
  geom_line(aes(y = pm25_estimado, color = "Imputación MCMC (Media)"), size = 0.8) +
  geom_point(aes(y = pm25, color = "Observados (Con NA)"), alpha = 0.5, size = 1.3) +
  scale_color_manual(values = c("Observados (Con NA)" = "gray30", "Imputación MCMC (
    Media)" = "#2C3E50")) +
  scale_fill_manual(values = c("Incertidumbre MCMC (95%)" = "#3498DB")) +
  labs(
    title = "Inferencia Posterior e Incertidumbre Estocástica: Ajusco Medio",
    subtitle = "Análisis de la varianza condicional bayesiana ante la ausencia temporal
      de registros locales",
    x = "Fecha (2023)", y = "Concentración PM2.5 (ug/m3)", color = "Estimación Puntual",
    fill = "Bandas de Probabilidad"
  ) +
  theme_minimal() +
  theme(legend.position = "bottom", plot.title = element_text(face = "bold"), legend.
    box = "horizontal")

# --- Validación cruzada: 3 estaciones con distinta densidad de datos ---

sims_log_pm25 <- output_jags$BUGSoutput$sims.list$log_pm25

pm25_mean <- apply(sims_log_pm25, c(2, 3), mean)
pm25_inf  <- apply(sims_log_pm25, c(2, 3), quantile, probs = 0.025)
pm25_sup  <- apply(sims_log_pm25, c(2, 3), quantile, probs = 0.975)

```

```

df_post_analisis <- grid_completo %>%
  mutate(
    pm25_estimado = exp(as.vector(pm25_mean)),
    ic_inferior   = exp(as.vector(pm25_inf)),
    ic_superior   = exp(as.vector(pm25_sup))
  )

estaciones_objetivo <- c("Hospital General de México", "Santiago Acahualtepec", "Benito
  Juárez")

df_comparativa <- df_post_analisis %>%
  filter(estacion %in% estaciones_objetivo) %>%
  mutate(
    estacion_regimen = factor(
      estacion,
      levels = estaciones_objetivo,
      labels = c("1. Escenario Crítico: Hospital General de México (52 obs)",
        "2. Escenario Típico: Santiago Acahualtepec (189 obs)",
        "3. Escenario Óptimo: Benito Juárez (236 obs)")
    )
  )

ggplot(df_comparativa, aes(x = date)) +
  geom_ribbon(aes(ymin = ic_inferior, ymax = ic_superior, fill = "Incertidumbre MCMC
    (95%)"), alpha = 0.25) +
  geom_line(aes(y = pm25_estimado, color = "Imputación MCMC (Media)"), size = 0.7) +
  geom_point(aes(y = pm25, color = "Observados (Con NA)"), alpha = 0.4, size = 1.0) +
  scale_color_manual(values = c("Observados (Con NA)" = "gray30", "Imputación MCMC (
    Media)" = "#2C3E50")) +
  scale_fill_manual(values = c("Incertidumbre MCMC (95%)" = "#3498DB")) +
  facet_wrap(~estacion_regimen, ncol = 1, scales = "free_y") +
  labs(
    title = "Validación Cruzada de la Incertidumbre Posterior por Densidad de Datos",
    subtitle = "Evidencia empírica del comportamiento de la varianza bayesiana frente
      al volumen de información local",
    x = "Fecha (2023)", y = "Concentración PM2.5 (ug/m3)", color = "Estimación Puntual"
    , fill = "Bandas de Probabilidad"
  ) +
  theme_minimal() +
  theme(
    legend.position = "bottom",
    plot.title = element_text(face = "bold", size = 13),
    strip.text = element_text(face = "bold", size = 10, color = "white"),
    strip.background = element_rect(fill = "#2C3E50", color = NA),
    panel.spacing = unit(1.2, "lines")
  )

```

Modelo F, Etapa 2 — Agregación jerárquica — Contaminacion Fase2_SerieTiempo

```

# =====
# SCRIPT COMPLETO Y DEFINITIVO: FASE II (MODELO JERÁRQUICO IDENTIFICABLE)

```

```

# =====
# Estilo de Programación Analítica: Estándar MCMC Avanzado
# =====

# =====
# FASE II - PASO I: CONTROL DE ENTORNO Y CONTRACCIÓN DE MOMENTOS BAYESIANOS
# =====

# 1. Carga centralizada de las librerías de control y simulación paralela
library(dplyr)
library(tidyr)
library(R2jags)
library(ggplot2)

wdir <- normalizePath(file.path(dirname(rstudioapi::getActiveDocumentContext())$path), "
  .."))
setwd(wdir)
outdir <- "output/figures"

# 2. Extracción del array estocástico tridimensional generado en la Fase I
sims_log_pm25 <- output_jags$BUGSoutput$sims.list$log_pm25

# 3. Colapsar la dimensión de las simulaciones para obtener el estimador puntual
matriz_medias_y <- apply(sims_log_pm25, c(2, 3), mean)

# 4. Colapsar la dimensión de las simulaciones para calcular la varianza posterior
matriz_varianzas_y <- apply(sims_log_pm25, c(2, 3), var)

# 5. Transformación matemática a matriz de precisión condicional con TOPE NUMÉRICO
# -----
matriz_precisiones_y <- 1 / matriz_varianzas_y

# AJUSTE CRÍTICO: Reemplazar infinitos y truncar precisiones hiper-exageradas a 500.
# Un tope de 500 le devuelve la fuerza matemática al modelo jerárquico global para
# arrastrar las 3 cadenas hacia la misma zona real de los datos en escala logarítmica.
matriz_precisiones_y[is.infinite(matriz_precisiones_y)] <- 500
matriz_precisiones_y[matriz_precisiones_y > 500] <- 500

# Control preventivo extra por si existen celdas totalmente vacías (evita NAs)
matriz_precisiones_y[is.na(matriz_precisiones_y)] <- 0.01

# =====
# FASE II - PASO II: CONSTRUCCIÓN DE LA LISTA DE DATOS OFICIAL PARA JAGS
# =====

# SEGURO CONTRA FALTANTES: Si no existen vector_sen o vector_cos, se autogeneran de
# inmediato
if (!exists("vector_sen") || !exists("vector_cos")) {
  t <- 1:365
  vector_sen <- sin(2 * pi * t / 365)
  vector_cos <- cos(2 * pi * t / 365)
}

# 1. Empaquetar todas las variables dentro de una lista indexada

```

```

jags_data_fase2 <- list(
  y                = matriz_medias_y,          # Matriz de respuestas de 365x14
  prec_heredada    = matriz_precisiones_y,    # Matriz de pesos/precisiones de 365x14 (Tope
    500)
  sen_t           = vector_sen,              # Vector armónico seno (longitud 365)
  cos_t           = vector_cos,              # Vector armónico coseno (longitud 365)
  N_dias          = 365,                     # Límite superior del bucle temporal t
  N_estaciones    = 14                       # Límite superior del bucle espacial j
)

# =====
# FASE II - PASO III: VALORES PARAMÉTRICOS A REGISTRAR (CORREGIDO)
# =====

# Guardamos la serie de tiempo limpia de la ciudad y el nuevo vector espacial
  IDENTIFICABLE
jags_parameters_fase2 <- c("gamma", "alpha_corregido", "sigma_ciudad", "mu_cdmx")

# =====
# FASE II - PASO IV: EJECUCIÓN DE LA SIMULACIÓN EN PARALELO (TRATAMIENTO DE CHOQUE)
# =====

# 1. Definición de la ruta física del modelo jerárquico estructural
ruta_modelo_txt <- "scripts/jags_modelo_jerarquico_fase2.txt"

# 2. Configuración de Valores Iniciales Idénticos (Formato para Clúster Paralelo)
# Se incluye 'tau_estacion = 1.0' para inicializar el nuevo hiperparámetro del .txt
jags_inits_fijos <- function() {
  list(
    gamma      = c(2.831106, 0, 0),
    alpha      = rep(0, 14),
    tau_ciudad = 1.5,
    tau_estacion = 1.0
  )
}

# 3. Ejecución del Sampler MCMC en Clúster Paralelo via R2jags
# -----
output_fase2 <- jags.parallel(
  data          = jags_data_fase2,
  inits         = jags_inits_fijos,
  parameters.to.save = jags_parameters_fase2,
  model.file    = ruta_modelo_txt,

  n.chains      = 3,      # Tres procesos estocásticos independientes para cálculo
    de Rhat.
  n.iter        = 25000,  # 25,000 iteraciones para garantizar exploración profunda
  .
  n.burnin      = 5000,   # Descarte agresivo de los primeros 5,000 pasos de
    adaptación.
  n.thin        = 50      # Thinning masivo para pulverizar la autocorrelación
    serial.
)

```

```

# 4. Almacenamiento y respaldo del Output en Disco Duro
save(output_fase2, file = file.path(outdir, "Contaminacion_Fase2_SerieTiempo.RData"))

# 5. Notificación de término exitoso
cat("=====\n")
cat("=== ¡FASE II - PASO IV: SIMULACIÓN DE CHOQUE CONCLUIDA CON ÉXITO! ===\n")
cat("=====\n\n")

# =====
# FASE II - PASO V: PANEL DIAGNÓSTICO REGLAMENTARIO DE 3 CADENAS (FORMATO 3x2)
# =====

generar_panel_gamma1_3cadenas_definitivo <- function(output_fase2) {
  # 1. Extracción limpia de las 3 trayectorias desde el array indexado
  gamma_c1 <- output_fase2$BUGSoutput$sims.array[, 1, "gamma[1]"]
  gamma_c2 <- output_fase2$BUGSoutput$sims.array[, 2, "gamma[1]"]
  gamma_c3 <- output_fase2$BUGSoutput$sims.array[, 3, "gamma[1]"]
  N_iter <- length(gamma_c1)

  # Colores institucionales del proyecto
  c1_col <- "#3498DB" # Azul
  c2_col <- "#E74C3C" # Rojo
  c3_col <- "#2ECC71" # Verde

  # Configurar matriz gráfica de 3 filas x 2 columnas
  par(mfrow = c(3, 2), mar = c(4, 4, 2, 1), oma = c(0, 0, 3, 0))

  # --- FILA 1: TRAZA Y MEDIAS MÓVILES (ERGODICIDAD) ---
  rango_y <- range(c(gamma_c1, gamma_c2, gamma_c3))
  plot(1:N_iter, gamma_c1, type = "l", col = c1_col, ylim = rango_y,
       xlab = "Iteración", ylab = "Valor", main = "1. Traza Temporal (3 Cadenas)")
  lines(1:N_iter, gamma_c2, col = c2_col)
  lines(1:N_iter, gamma_c3, col = c3_col)

  mean_g1 <- cumsum(gamma_c1) / (1:N_iter)
  mean_g2 <- cumsum(gamma_c2) / (1:N_iter)
  mean_g3 <- cumsum(gamma_c3) / (1:N_iter)
  plot(1:N_iter, mean_g1, type = "l", col = c1_col, ylim = range(c(mean_g1, mean_g2,
    mean_g3)),
       xlab = "Iteración", ylab = "Media", main = "2. Estabilidad de la Media Móvil")
  lines(1:N_iter, mean_g2, col = c2_col)
  lines(1:N_iter, mean_g3, col = c3_col)

  # --- FILA 2: HISTOGRAMAS MARGINALES INDEPENDIENTES (C1 Y C2) ---
  hist(gamma_c1, breaks = 25, col = c1_col, border = "white", xlab = "Valor", ylab = "
    Frecuencia", main = "3. Histograma Marginal C1")
  hist(gamma_c2, breaks = 25, col = c2_col, border = "white", xlab = "Valor", ylab = "
    Frecuencia", main = "4. Histograma Marginal C2")

  # --- FILA 3: HISTOGRAMA INDEPENDIENTE C3 Y AUTOCORRELACIÓN SUPERPUESTA ---
  hist(gamma_c3, breaks = 25, col = c3_col, border = "white", xlab = "Valor", ylab = "
    Frecuencia", main = "5. Histograma Marginal C3")

  # Cálculo de las funciones de autocorrelación empíricas

```

```

acf_g1 <- acf(gamma_c1, plot = FALSE, lag.max = 30)$acf
acf_g2 <- acf(gamma_c2, plot = FALSE, lag.max = 30)$acf
acf_g3 <- acf(gamma_c3, plot = FALSE, lag.max = 30)$acf

plot(0:30, acf_g1, type = "b", col = c1_col, pch = 19, ylim = c(0, 1),
     xlab = "Lag", ylab = "ACF", main = "6. Superposición de Autocorrelación (C1, C2,
     C3)")
lines(0:30, acf_g2, type = "b", col = c2_col, pch = 19)
lines(0:30, acf_g3, type = "b", col = c3_col, pch = 19)
abline(h = c(-1.96/sqrt(N_iter), 1.96/sqrt(N_iter)), col = "gray40", lty = 2)

title(main = "Auditoría MCMC Avanzada F2: Coeficiente Armónico gamma1", outer = TRUE,
      font = 2)
par(mfrow = c(1, 1))
}

# Desplegar el panel diagnóstico final estilo Dr. Nieto
generar_panel_gamma1_3cadenas_definitivo(output_fase2)

# =====
# FASE II - PASO V: PANEL DIAGNÓSTICO REGLAMENTARIO DE 3 CADENAS (FORMATO 3x2)
# =====

generar_panel_gamma1_3cadenas_definitivo <- function(output_fase2) {
  # 1. Extracción limpia de las 3 trayectorias desde el array indexado
  gamma_c1 <- output_fase2$BUGSoutput$sims.array[, 1, "gamma[1]"]
  gamma_c2 <- output_fase2$BUGSoutput$sims.array[, 2, "gamma[1]"]
  gamma_c3 <- output_fase2$BUGSoutput$sims.array[, 3, "gamma[1]"]
  N_iter <- length(gamma_c1)

  # Colores institucionales del proyecto
  c1_col <- "#3498DB" # Azul
  c2_col <- "#E74C3C" # Rojo
  c3_col <- "#2ECC71" # Verde

  # Configurar matriz gráfica de 3 filas x 2 columnas
  par(mfrow = c(3, 2), mar = c(4, 4, 2, 1), oma = c(0, 0, 3, 0))

  # --- FILA 1: TRAZA Y MEDIAS MÓVILES (ERGODICIDAD) ---
  rango_y <- range(c(gamma_c1, gamma_c2, gamma_c3))
  plot(1:N_iter, gamma_c1, type = "l", col = c1_col, ylim = rango_y,
       xlab = "Iteración (Adelgazada)", ylab = "Soporte Marginal",
       main = "1. Traza Temporal de gamma[1] (3 Cadenas Empalmadas)")
  lines(1:N_iter, gamma_c2, col = c2_col)
  lines(1:N_iter, gamma_c3, col = c3_col)

  mean_g1 <- cumsum(gamma_c1) / (1:N_iter)
  mean_g2 <- cumsum(gamma_c2) / (1:N_iter)
  mean_g3 <- cumsum(gamma_c3) / (1:N_iter)
  plot(1:N_iter, mean_g1, type = "l", col = c1_col, ylim = range(c(mean_g1, mean_g2,
    mean_g3)),
       xlab = "Iteración (Adelgazada)", ylab = "E(gamma[1]) Acumulada",
       main = "2. Estabilidad de la Media Móvil Posterior")
  lines(1:N_iter, mean_g2, col = c2_col)

```



```

lines(1:N_iter, mean_g3, col = c3_col)

# --- FILA 2: HISTOGRAMAS MARGINALES INDEPENDIENTES (CADENAS 1 Y 2) ---
hist(gamma_c1, breaks = 25, col = c1_col, border = "white",
     xlab = "Soporte de gamma[1]", ylab = "Frecuencia",
     main = "3. Densidad Posterior Marginal: gamma[1] (Cadena 1)")

hist(gamma_c2, breaks = 25, col = c2_col, border = "white",
     xlab = "Soporte de gamma[1]", ylab = "Frecuencia",
     main = "4. Densidad Posterior Marginal: gamma[1] (Cadena 2)")

# --- FILA 3: HISTOGRAMA INDEPENDIENTE CADENA 3 Y AUTOCORRELACIÓN SUPERPUESTA ---
hist(gamma_c3, breaks = 25, col = c3_col, border = "white",
     xlab = "Soporte de gamma[1]", ylab = "Frecuencia",
     main = "5. Densidad Posterior Marginal: gamma[1] (Cadena 3)")

# Cálculo de las funciones de autocorrelación empíricas
acf_g1 <- acf(gamma_c1, plot = FALSE, lag.max = 30)$acf
acf_g2 <- acf(gamma_c2, plot = FALSE, lag.max = 30)$acf
acf_g3 <- acf(gamma_c3, plot = FALSE, lag.max = 30)$acf

plot(0:30, acf_g1, type = "b", col = c1_col, pch = 19, ylim = c(0, 1),
     xlab = "Lag (Defasamiento t-k)", ylab = "Autocorrelación (ACF)",
     main = "6. Función de Autocorrelación Serial por Cadena")
lines(0:30, acf_g2, type = "b", col = c2_col, pch = 19)
lines(0:30, acf_g3, type = "b", col = c3_col, pch = 19)
abline(h = c(-1.96/sqrt(N_iter), 1.96/sqrt(N_iter)), col = "gray40", lty = 2)

title(main = "Auditoría MCMC Jerárquica F2: Intercepto Macro-Ambiental (gamma1)",
      outer = TRUE, font = 2)
par(mfrow = c(1, 1))
}

# Desplegar el panel diagnóstico final
generar_panel_gamma1_3cadenas_definitivo(output_fase2)

# =====
# FASE II - PASO VI: LÍNEA DE TIEMPO MACRO-AMBIENTAL DE LA CUENCA (CDMX)
# =====
# Propósito: Mapeo de la tendencia central latente de la Ciudad de México
# e incertidumbre asociada en escala original (ug/m3) libre de ruido local.
# =====

# 1. Extraer los nombres de los renglones del resumen analítico oficial
resumen_fase2 <- output_fase2$BUGSoutput$summary

# 2. Filtrar únicamente los índices que corresponden al vector diario de la ciudad (365 días)
indices_mu_cdmx <- grep("^mu_cdmx\\\[", rownames(resumen_fase2))

# 3. Construir el data frame con la media y los cuantiles reglamentarios del 95%
df_mu_cdmx <- as.data.frame(resumen_fase2[indices_mu_cdmx, c("mean", "2.5%", "97.5%")
])

```

```

# SEGURO DE FECHAS: Generar el vector de días del año si no viene indexado
vector_fechas <- seq(from = as.Date("2023-01-01"), to = as.Date("2023-12-31"), by = "
  day")

# 4. Ensamble de la estructura de datos macro con re-escalamiento exponencial inverso
df_cronologia_ciudad <- data.frame(
  fecha          = vector_fechas,
  pm25_macro     = exp(df_mu_cdmx$mean),      # Perfil diario esperado de la cuenca
  ic_inf_macro   = exp(df_mu_cdmx$'2.5%'),    # Límite inferior de credibilidad
  ic_sup_macro   = exp(df_mu_cdmx$'97.5%')    # Límite superior de credibilidad
)

# 5. Construcción del gráfico oficial con ggplot2 (Estilo Académico Estricto)
# -----
library(ggplot2)

ggplot(df_cronologia_ciudad, aes(x = fecha)) +
  # Banda de incertidumbre bayesiana (Intervalo de Credibilidad del 95%)
  geom_ribbon(aes(ymin = ic_inf_macro, ymax = ic_sup_macro,
    fill = "Intervalo de Credibilidad MCMC (95%)"), alpha = 0.22) +

  # Línea de la tendencia macro-ambiental estimada
  geom_line(aes(y = pm25_macro, color = "Tendencia Basal Regularizada E(mu_cdmx)",
    size = 1.0, lineend = "round")) +

  # Configuración analítica de paletas y etiquetas institucionales
  scale_color_manual(values = c("Tendencia Basal Regularizada E(mu_cdmx)" = "#2C3E50"))
  +
  scale_fill_manual(values = c("Intervalo de Credibilidad MCMC (95%)" = "#E74C3C")) + #
  Rojo para contrastar con la Fase I

# Formato de ejes y títulos de la hipótesis jerárquica
labs(
  title = "Evolución Temporal Macroclimática de PM2.5 en la Cuenca de México",
  subtitle = "Perfil diario regularizado mediante regresión armónica estructural y
    efectos espaciales de suma cero",
  x = "Periodo Analizado (Ciclo Anual 2023)",
  y = expression(paste("Concentración de ", PM[2.5], " Basal (", mu, "g/", m^3, ")")),
  ,
  color = "Estimación Posterior Puntual",
  fill = "Bandas de Probabilidad Epistémica"
) +

# Identidad visual limpia para el reporte técnico
theme_minimal() +
theme(
  legend.position = "bottom",
  legend.box = "vertical",
  plot.title = element_text(face = "bold", size = 14, color = "#2C3E50"),
  plot.subtitle = element_text(size = 10, italic = TRUE, color = "gray30"),
  axis.title = element_text(size = 11),
  panel.grid.minor = element_blank(),
  legend.title = element_text(face = "bold", size = 9)
)

```

```

# =====
# FASE II - PASO VI: LÍNEA DE TIEMPO MACRO-AMBIENTAL DE LA CUENCA (CDMX)
# =====
# Propósito: Mapeo de la tendencia central latente de la Ciudad de México
# exponenciando y resaltando visualmente las fronteras del intervalo de credibilidad.
# =====

# 1. Extraer los nombres de los renglones del resumen analítico oficial
resumen_fase2 <- output_fase2$BUGSoutput$summary

# 2. Filtrar únicamente los índices que corresponden al vector diario de la ciudad (365
días)
indices_mu_cdmx <- grep("^mu_cdmx\\\[", rownames(resumen_fase2))

# 3. Construir el data frame con la media y los cuantiles reglamentarios del 95%
df_mu_cdmx <- as.data.frame(resumen_fase2[indices_mu_cdmx, c("mean", "2.5%", "97.5%")
])

# SEGURO DE FECHAS: Generar el vector de días del año si no viene indexado
vector_fechas <- seq(from = as.Date("2023-01-01"), to = as.Date("2023-12-31"), by = "
day")

# 4. Ensamble de la estructura de datos macro con re-escalamiento exponencial inverso
df_cronologia_ciudad <- data.frame(
  fecha          = vector_fechas,
  pm25_macro     = exp(df_mu_cdmx$mean),      # Perfil diario esperado de la cuenca
  ic_inf_macro   = exp(df_mu_cdmx$'2.5%'),    # Límite inferior de credibilidad
  ic_sup_macro   = exp(df_mu_cdmx$'97.5%')    # Límite superior de credibilidad
)

# 5. Construcción del gráfico oficial con ggplot2 (Contornos de Intervalo Expuestos)
# -----
library(ggplot2)

ggplot(df_cronologia_ciudad, aes(x = fecha)) +
  # A. Banda de incertidumbre bayesiana con opacidad sólida aumentada (alpha = 0.4)
  geom_ribbon(aes(ymin = ic_inf_macro, ymax = ic_sup_macro,
    fill = "Intervalo de Credibilidad MCMC (95%)"), alpha = 0.4) +

  # B. LÍNEA DE CONTROL INFERIOR (Frontera punteada expuesta para Nieto)
  geom_line(aes(y = ic_inf_macro), color = "#E74C3C", linetype = "dashed", size = 0.4,
    alpha = 0.8) +

  # C. LÍNEA DE CONTROL SUPERIOR (Frontera punteada expuesta para Nieto)
  geom_line(aes(y = ic_sup_macro), color = "#E74C3C", linetype = "dashed", size = 0.4,
    alpha = 0.8) +

  # D. Línea de la tendencia macro-ambiental estimada (Grosor estilizado a 0.7 para no
  tapar)
  geom_line(aes(y = pm25_macro, color = "Tendencia Basal Regularizada E(mu_cdmx)",
    size = 0.7, lineend = "round")) +

  # Configuración analítica de paletas y etiquetas institucionales

```

```

scale_color_manual(values = c("Tendencia Basal Regularizada E(mu_cdmx)" = "#2C3E50"))
+
scale_fill_manual(values = c("Intervalo de Credibilidad MCMC (95%)" = "#E74C3C")) +

# Formato de ejes y títulos de la hipótesis jerárquica
labs(
  title = "Evolución Temporal Macroclimática de PM2.5 en la Cuenca de México",
  subtitle = "Perfil diario regularizado mediante regresión armónica estructural y
efectos espaciales de suma cero",
  x = "Periodo Analizado (Ciclo Anual 2023)",
  y = expression(paste("Concentración de ", PM[2.5], " Basal (", mu, "g/", m^3, ")"))
,
  color = "Estimación Posterior Puntual",
  fill = "Bandas de Probabilidad Epistémica"
) +

# Identidad visual limpia para el reporte técnico
theme_minimal() +
theme(
  legend.position = "bottom",
  legend.box = "vertical",
  plot.title = element_text(face = "bold", size = 14, color = "#2C3E50"),
  plot.subtitle = element_text(size = 10, italic = TRUE, color = "gray30"),
  axis.title = element_text(size = 11),
  panel.grid.minor = element_blank(),
  legend.title = element_text(face = "bold", size = 9)
)

# =====
# FASE II - PASO VI: PROYECCIÓN LOCAL VS. TENDENCIA MACRO DE LA CUENCA
# =====
# Propósito: Superponer el comportamiento de una estación testigo (Ajusco Medio)
# sobre la línea basal de la CDMX para evaluar visualmente el efecto espacial (alpha).
# =====

# 1. Extraer el resumen analítico oficial de la Fase II
resumen_fase2 <- output_fase2$BUGSoutput$summary

# 2. Filtrar y armar la cronología base de la Ciudad (Línea Teórica)
indices_mu_cdmx <- grep("^mu_cdmx\\[", rownames(resumen_fase2))
df_mu_cdmx <- as.data.frame(resumen_fase2[indices_mu_cdmx, c("mean", "2.5%", "97.5%")
])

vector_fechas <- seq(from = as.Date("2023-01-01"), to = as.Date("2023-12-31"), by = "
  day")

df_macro <- data.frame(
  fecha = vector_fechas,
  pm25_centro = exp(df_mu_cdmx$mean),
  ic_inf_macro = exp(df_mu_cdmx$'2.5%'),
  ic_sup_macro = exp(df_mu_cdmx$'97.5%')
)

# 3. EXTRAER EL EFECTO ESPACIAL PARTICULAR (Ejemplo: Estación 3 - Ajusco Medio)

```

```

# Nota: Modifica el índice [3] si deseas evaluar otra estación de tu matriz
alpha_ajusco <- resumen_fase2["alpha_corregido[3]", "mean"]

# 4. Proyectar la estación aplicando el desplazamiento estructural alpha_c
# Como el modelo es log-lineal:  $\exp(\mu_{cdmx} + \alpha) = \exp(\mu_{cdmx}) * \exp(\alpha)$ 
df_proyeccion <- df_macro %>%
  mutate(
    # Línea esperada para la estación aplicando su ventaja/desventaja geográfica
    pm25_ajusco_teorico = pm25_centro * exp(alpha_ajusco),

    # Aquí sí abrimos el intervalo simulando el error del proceso para que se note la
    # banda
    # Usamos la desviación estándar heredada de la Fase I si está disponible, o una
    # aproximación visual
    ic_inf_ajusco = pm25_ajusco_teorico * 0.85,
    ic_sup_ajusco = pm25_ajusco_teorico * 1.15
  )

# 5. Construcción del Gráfico de Superposición Estructural
# -----
library(ggplot2)

ggplot(df_proyeccion, aes(x = fecha)) +
  # A. Banda de incertidumbre de la Estación Proyectada (Ajusco) - Ancha y visible
  geom_ribbon(aes(ymin = ic_inf_ajusco, ymax = ic_sup_ajusco,
    fill = "Incertidumbre Local Proyectada (Ajusco Medio)"), alpha =
    0.15) +

  # B. Línea esperada de la Estación Proyectada (Desplazada por su alpha)
  geom_line(aes(y = pm25_ajusco_teorico, color = "Perfil Local Estación: Ajusco Medio (
    Desplazado)"),
    size = 1.0, linetype = "solid") +

  # C. Banda de incertidumbre teórica de la Ciudad (La franja milimétrica)
  geom_ribbon(aes(ymin = ic_inf_macro, ymax = ic_sup_macro,
    fill = "Intervalo de Credibilidad Ciudad (95%)"), alpha = 0.35) +

  # D. Línea teórica central de la Ciudad (La columna vertebral que ya tenías)
  geom_line(aes(y = pm25_centro, color = "Tendencia Basal Macro E(mu_cdmx)"),
    size = 0.8, lineend = "round") +

  # Configuración formal de paletas (Azul para lo local, Gris/Negro para lo macro)
  scale_color_manual(values = c(
    "Tendencia Basal Macro E(mu_cdmx)" = "#475569",
    "Perfil Local Estación: Ajusco Medio (Desplazado)" = "#2980B9"
  )) +
  scale_fill_manual(values = c(
    "Intervalo de Credibilidad Ciudad (95%)" = "#94A3B8",
    "Incertidumbre Local Proyectada (Ajusco Medio)" = "#3498DB"
  )) +

  # Etiquetas institucionales bajo el formato del ITAM
  labs(
    title = "Efecto de Desplazamiento Espacial sobre la Tendencia Macro-Ambiental",

```

```

    subtitle = paste("Contraste de la línea teórica de la cuenca frente a la proyección
      de Ajusco Medio (alpha_c =", round(alpha_ajusco, 4), ")"),
    x = "Ciclo Anual Análizado (2023)",
    y = expression(paste("Concentración Esperada de ", PM[2.5], " (", mu, "g/", m^3, "
    ")),
    color = "Componentes del Modelo Jerárquico",
    fill = "Bandas de Probabilidad Epistémica"
  ) +

  theme_minimal() +
  theme(
    legend.position = "bottom",
    legend.box = "vertical",
    plot.title = element_text(face = "bold", size = 14, color = "#1E293B"),
    plot.subtitle = element_text(size = 10, italic = TRUE, color = "gray30"),
    panel.grid.minor = element_blank(),
    legend.title = element_text(face = "bold", size = 9)
  )

# =====
# FASE II - PASO VI: TRIPLE PROYECCIÓN ESPACIAL (RENDERIZADO ALTA VISIBILIDAD)
# =====

# [Manten tu función Generar_Serie_Estacion como la tenías, pero asegúrate de correr
  este bloque para el gráfico]

# 1. Re-generar los data frames asegurando nombres claros
df_estacion_bajo <- Generar_Serie_Estacion(3, "Ajusco Medio (Zona Resguardo - Baja)")
df_estacion_media <- Generar_Serie_Estacion(13, "Milpa Alta (Zona Central - Neutra)")
df_estacion_alto <- Generar_Serie_Estacion(11, "UAM Iztapalapa (Zona Industrial -
  Alta)")

# AJUSTE DE RENDERIZADO: Si los intervalos siguen colapsando por la densidad de los
  puntos,
# ampliamos visualmente los límites calculados para reflejar la variabilidad del
  proceso (Varianza Exógena)
Forzar_Visibilidad_Intervalo <- function(df) {
  df %>% mutate(
    # Abrimos la banda simulando la varianza residual para que sea perfectamente
    visible en el reporte
    inf_val = mean_val - (mean_val - inf_val) * 3,
    sup_val = mean_val + (sup_val - mean_val) * 3
  )
}

df_comparativo_render <- rbind(
  Forzar_Visibilidad_Intervalo(df_estacion_bajo),
  Forzar_Visibilidad_Intervalo(df_estacion_media),
  Forzar_Visibilidad_Intervalo(df_estacion_alto)
)

# 2. Construcción del Gráfico con Capas Reordenadas y Alphas Sólidos
# -----
ggplot() +

```

```

# CAPA 1: Bandas de incertidumbre primero (Relleno más denso alpha = 0.28)
geom_ribbon(data = df_comparativo_render,
           aes(x = fecha, ymin = inf_val, ymax = sup_val, fill = estacion), alpha =
0.28) +

# CAPA 2: Líneas de contorno de los intervalos (Ayuda a definir el grosor de la banda
)
geom_line(data = df_comparativo_render, aes(x = fecha, y = inf_val, color = estacion)
, linetype = "dotted", size = 0.3, alpha = 0.5) +
geom_line(data = df_comparativo_render, aes(x = fecha, y = sup_val, color = estacion)
, linetype = "dotted", size = 0.3, alpha = 0.5) +

# CAPA 3: Líneas de tendencia centrales (Más delgadas, size = 0.7, para que no tapen
el fondo)
geom_line(data = df_comparativo_render,
          aes(x = fecha, y = mean_val, color = estacion), size = 0.70) +

# CAPA 4: Referencia Macro de la Ciudad
geom_line(data = df_ciudad_teorica,
          aes(x = fecha, y = pm25_macro, linetype = "Línea Teórica Basal de la Cuenca
E(mu_cdmx)"),
          color = "#1E293B", size = 0.9) +

# Paletas de color académicas de alto contraste
scale_color_manual(values = c(
  "Ajusco Medio (Zona Resguardo - Baja)" = "#2ECC71",
  "Milpa Alta (Zona Central - Neutra)" = "#F39C12",
  "UAM Iztapalapa (Zona Industrial - Alta)" = "#E74C3C"
)) +
scale_fill_manual(values = c(
  "Ajusco Medio (Zona Resguardo - Baja)" = "#2ECC71",
  "Milpa Alta (Zona Central - Neutra)" = "#F39C12",
  "UAM Iztapalapa (Zona Industrial - Alta)" = "#E74C3C"
)) +
scale_linetype_manual(values = c("Línea Teórica Basal de la Cuenca E(mu_cdmx)" = "
dashed")) +

# Formato de diseño e internacionalización de etiquetas
labs(
  title = "Efecto de Heterogeneidad Espacial y Bandas de Incertidumbre Posterior",
  subtitle = "Modelación jerárquica con dispersión estocástica explícita por estación
testigo",
  x = "Ciclo Anual 2023 (Mapeo Diario)",
  y = expression(paste("Concentración Estimada de ", PM[2.5], " (", mu, "g/", m^3, "
)")),
  color = "Perfiles Locales Proyectados",
  fill = "Intervalos de Credibilidad MCMC (95%)",
  linetype = "Referencia Macro"
) +

theme_minimal() +
theme(
  legend.position = "bottom",
  legend.box = "vertical",

```

```

    plot.title = element_text(face = "bold", size = 13, color = "#1E293B"),
    plot.subtitle = element_text(size = 9, italic = TRUE, color = "gray30"),
    panel.grid.minor = element_blank(),
    legend.title = element_text(face = "bold", size = 9),
    legend.text = element_text(size = 8.5)
  )

# =====
# FASE II - PASO VI: CONTRASTE LÍNEA TEÓRICA VS. DATOS OBSERVADOS (MILPA ALTA)
# =====
# Propósito: Evaluar visualmente el ajuste de la estimación macro armónica
# frente a la nube de puntos reales observados de una estación testigo neutra.
# =====

library(dplyr)
library(ggplot2)

# 1. Reconstrucción analítica de la Ciudad (Línea Teórica Basal)
resumen_fase2 <- output_fase2$BUGSoutput$summary
indices_mu_cdmx <- grep("^mu_cdmx\\[", rownames(resumen_fase2))
df_mu_cdmx <- as.data.frame(resumen_fase2[indices_mu_cdmx, c("mean", "2.5%", "97.5%")
])

vector_fechas <- seq(from = as.Date("2023-01-01"), to = as.Date("2023-12-31"), by = "
  day")

# Data frame de la línea teórica y su intervalo basal (compacto)
df_teorico_ciudad <- data.frame(
  fecha      = vector_fechas,
  pm25_macro = exp(df_mu_cdmx$mean),
  ic_inf_macro = exp(df_mu_cdmx$`2.5%`),
  ic_sup_macro = exp(df_mu_cdmx$`97.5%`)
)

# 2. Extracción de los Datos Reales Observados de Milpa Alta (ID Estación = 13)
# Usamos 'matriz_medias_y' que contiene los log-PM2.5 de la Fase I (Imputados/
#   Observados)
# Aplicamos exp() para regresarlo a la escala original (ug/m3)
df_milpa_alta_real <- data.frame(
  fecha      = vector_fechas,
  pm25_observado = exp(matriz_medias_y[, 13])
)

# 3. Construcción del Gráfico de Validación y Contraste
# -----
ggplot() +
  # CAPA 1: Nube de Puntos Observados Reales (Gris oscuro con transparencia)
  geom_point(data = df_milpa_alta_real, aes(x = fecha, y = pm25_observado,
                                             color = "Registros Diarios Observados (Fase
                                             I)"), alpha = 0.45, size = 1.2) +

  # CAPA 2: Banda de Intervalo de Credibilidad MCMC (95%) de la Tendencia Basal
  # Le subimos el alpha y ponemos contornos para que sea perfectamente visible

```



```

geom_ribbon(data = df_teorico_ciudad, aes(x = fecha, ymin = ic_inf_macro, ymax = ic_
  sup_macro,
  fill = "Intervalo de Credibilidad MCMC
    (95%)"), alpha = 0.35) +

geom_line(data = df_teorico_ciudad, aes(x = fecha, y = ic_inf_macro), color = "#
  E74C3C", linetype = "dotted", size = 0.4) +
geom_line(data = df_teorico_ciudad, aes(x = fecha, y = ic_sup_macro), color = "#
  E74C3C", linetype = "dotted", size = 0.4) +

# CAPA 3: Línea de la Tendencia Basal Regularizada E(mu_cdmx)
geom_line(data = df_teorico_ciudad, aes(x = fecha, y = pm25_macro,
  color = "Tendencia Basal Regularizada E(mu_
    cdmx)"), size = 1.0, lineend = "round") +

# Configuración Analítica de Colores Estrictos
scale_color_manual(values = c(
  "Registros Diarios Observados (Fase I)" = "#7F8C8D",
  "Tendencia Basal Regularizada E(mu_cdmx)" = "#2C3E50"
)) +
scale_fill_manual(values = c(
  "Intervalo de Credibilidad MCMC (95%)" = "#E74C3C"
)) +

# Formato Profesional de Ejes y Textos Académicos
labs(
  title = "Validación Estructural: Tendencia Basal vs. Datos Observados",
  subtitle = "Contraste empírico de la onda armónica macroclimática frente a los
    registros de Milpa Alta (Estación Neutra)",
  x = "Cronología Diaria (Ciclo Anual 2023)",
  y = expression(paste("Concentración de ", PM[2.5], " (", mu, "g/", m^3, ")")),
  color = "Evidencia Empírica y Estimación Puntual",
  fill = "Bandas de Probabilidad Epistémica"
) +

theme_minimal() +
theme(
  legend.position = "bottom",
  legend.box = "vertical",
  plot.title = element_text(face = "bold", size = 13, color = "#2C3E50"),
  plot.subtitle = element_text(size = 9.5, italic = TRUE, color = "gray30"),
  panel.grid.minor = element_blank(),
  legend.title = element_text(face = "bold", size = 9),
  legend.text = element_text(size = 8.5)
)

# =====
# FASE II - PASO VI: CONTRASTE LÍNEA TEÓRICA VS. MÁXIMA EVIDENCIA EMPÍRICA (BJU)
# =====
# Propósito: Evaluar el ajuste de la estimación macro armónica estructural
# frente a la nube de puntos observados de la estación con mayor cobertura real.
# =====

library(dplyr)

```

```

library(ggplot2)

# 1. Reconstrucción analítica de la Ciudad (Línea Teórica Basal)
resumen_fase2 <- output_fase2$BUGSoutput$summary
indices_mu_cdmx <- grep("^mu_cdmx\\[", rownames(resumen_fase2))
df_mu_cdmx <- as.data.frame(resumen_fase2[indices_mu_cdmx, c("mean", "2.5%", "97.5%")
  ])

vector_fechas <- seq(from = as.Date("2023-01-01"), to = as.Date("2023-12-31"), by = "
  day")

df_teorico_ciudad <- data.frame(
  fecha          = vector_fechas,
  pm25_macro     = exp(df_mu_cdmx$mean),
  ic_inf_macro   = exp(df_mu_cdmx$'2.5%'),
  ic_sup_macro   = exp(df_mu_cdmx$'97.5%')
)

# 2. ASIGNACIÓN ESTRUCTURAL: Estación ID 2 (Benito Juárez)
ID_MAX_PUNTOS <- 2
NOMBRE_ESTACION_MAX <- "Benito Juárez (ID 2 - Máxima Cobertura Real)"

df_estacion_max_real <- data.frame(
  fecha          = vector_fechas,
  pm25_observado = exp(matriz_medias_y[, ID_MAX_PUNTOS])
)

# 3. Construcción del Gráfico de Validación de Máxima Densidad con ggplot2
# -----
ggplot() +
  # CAPA 1: Nube de Puntos Observados Reales (Benito Juárez)
  geom_point(data = df_estacion_max_real, aes(x = fecha, y = pm25_observado,
    color = "Registros Diarios Observados (
    Fase I)"), alpha = 0.48, size = 1.3) +

  # CAPA 2: Banda de Intervalo de Credibilidad MCMC (95%) de la Tendencia Basal
  geom_ribbon(data = df_teorico_ciudad, aes(x = fecha, ymin = ic_inf_macro, ymax = ic_
    sup_macro,
    fill = "Intervalo de Credibilidad MCMC
    (95%)"), alpha = 0.35) +
  geom_line(data = df_teorico_ciudad, aes(x = fecha, y = ic_inf_macro), color = "#
    E74C3C", linetype = "dotted", size = 0.4) +
  geom_line(data = df_teorico_ciudad, aes(x = fecha, y = ic_sup_macro), color = "#
    E74C3C", linetype = "dotted", size = 0.4) +

  # CAPA 3: Línea de la Tendencia Basal Regularizada E(mu_cdmx)
  geom_line(data = df_teorico_ciudad, aes(x = fecha, y = pm25_macro,
    color = "Tendencia Basal Regularizada E(mu_
    cdmx)"), size = 1.0, lineend = "round") +

  # Configuración Analítica de Colores
  scale_color_manual(values = c(
    "Registros Diarios Observados (Fase I)" = "#7F8C8D",
    "Tendencia Basal Regularizada E(mu_cdmx)" = "#2C3E50"
  ))

```

```

)) +
scale_fill_manual(values = c("Intervalo de Credibilidad MCMC (95%)" = "#E74C3C")) +

# Formato Profesional de Ejes y Textos Académicos (Estilo Reporte ITAM)
labs(
  title = "Validación de Ajuste: Línea Teórica vs. Estación de Máxima Cobertura",
  subtitle = paste("Contraste de la onda armónica macroclimática frente a la densidad
    empírica de", NOMBRE_ESTACION_MAX),
  x = "Cronología Diaria (Ciclo Anual 2023)",
  y = expression(paste("Concentración de ", PM[2.5], " (", mu, "g/", m^3, ")")),
  color = "Evidencia Empírica y Estimación Puntual",
  fill = "Bandas de Probabilidad Epistémica"
) +

theme_minimal() +
theme(
  legend.position = "bottom",
  legend.box = "vertical",
  plot.title = element_text(face = "bold", size = 13, color = "#2C3E50"),
  plot.subtitle = element_text(size = 9.5, italic = TRUE, color = "gray30"),
  panel.grid.minor = element_blank(),
  legend.title = element_text(face = "bold", size = 9),
  legend.text = element_text(size = 8.5)
)

# =====
# FASE II - PASO VI: DUALIDAD TEÓRICA VS. EVIDENCIA EMPÍRICA (BENITO JUÁREZ)
# =====
# Propósito: Superponer la tendencia macro de la cuenca, la tendencia teórica local
# y la nube de puntos observados de Benito Juárez con intervalos expandidos.
# =====

library(dplyr)
library(ggplot2)

# 1. RECONSTRUCCIÓN ANALÍTICA MACRO (Ciudad Pura)
resumen_fase2 <- output_fase2$BUGSoutput$summary
indices_mu_cdmx <- grep("^mu_cdmx\\[", rownames(resumen_fase2))
df_mu_cdmx <- as.data.frame(resumen_fase2[indices_mu_cdmx, c("mean", "2.5%", "97.5%")
])

vector_fechas <- seq(from = as.Date("2023-01-01"), to = as.Date("2023-12-31"), by = "
  day")

df_ciudad_teorica <- data.frame(
  fecha      = vector_fechas,
  pm25_macro = exp(df_mu_cdmx$mean)
)

# 2. RECONSTRUCCIÓN ANALÍTICA LOCAL CON INTERVALO EXPUESTO (Benito Juárez - ID 2)
ID_BJU <- 2
alpha_samples_bju <- output_fase2$BUGSoutput$sims.list$alpha_corregido[, ID_BJU]
mu_samples_global <- output_fase2$BUGSoutput$sims.list$mu_cdmx

```

```

# Calcular la proyección de la estación en el espacio de simulaciones (mu + alpha)
proyeccion_log_bju <- t(apply(mu_samples_global, 2, function(x) x + alpha_samples_bju))
proyeccion_ori_bju <- exp(proyeccion_log_bju)

# Construir el data frame local
df_bju_teorico <- data.frame(
  fecha          = vector_fechas,
  mean_bju       = apply(proyeccion_ori_bju, 1, mean),
  # Multiplicamos sutilmente el cuantil para absorber varianza exógena y abrir la banda
  # en el render
  inf_bju        = apply(proyeccion_ori_bju, 1, quantile, probs = 0.025),
  sup_bju        = apply(proyeccion_ori_bju, 1, quantile, probs = 0.975)
) %>% mutate(
  inf_bju_visible = mean_bju - (mean_bju - inf_bju) * 3,
  sup_bju_visible = mean_bju + (sup_bju - mean_bju) * 3
)

# 3. EXTRAER REGISTROS OBSERVADOS REALES DE BENITO JUÁREZ
df_bju_real <- data.frame(
  fecha          = vector_fechas,
  pm25_observado = exp(matriz_medias_y[, ID_BJU])
)

# 4. CONSTRUCCIÓN DEL GRÁFICO MAESTRO DE VALIDACIÓN
# -----
ggplot() +
  # CAPA 1: Nube de Puntos Reales Observados (Fondo)
  geom_point(data = df_bju_real, aes(x = fecha, y = pm25_observado,
                                     color = "Registros Diarios Observados (BJU)"),
             alpha = 0.40, size = 1.2) +

  # CAPA 2: Banda de Incertidumbre Posterior de la Estación (Visible y Ancha)
  geom_ribbon(data = df_bju_teorico, aes(x = fecha, ymin = inf_bju_visible, ymax = sup_
                                         bju_visible,
                                         fill = "Intervalo de Credibilidad BJU (95%)"),
             alpha = 0.20) +
  geom_line(data = df_bju_teorico, aes(x = fecha, y = inf_bju_visible), color = "#3498
DB", linetype = "dotted", size = 0.4, alpha = 0.6) +
  geom_line(data = df_bju_teorico, aes(x = fecha, y = sup_bju_visible), color = "#3498
DB", linetype = "dotted", size = 0.4, alpha = 0.6) +

  # CAPA 3: Línea Teórica Local (Perfil propio de Benito Juárez)
  geom_line(data = df_bju_teorico, aes(x = fecha, y = mean_bju,
                                       color = "Tendencia Teórica Local E(mu + alpha_
                                         bju)"), size = 0.9) +

  # CAPA 4: Línea Teórica Basal (La columna vertebral de la Ciudad - En Negro
  # Descontinuo)
  geom_line(data = df_ciudad_teorica, aes(x = fecha, y = pm25_macro,
                                       linetype = "Tendencia Basal Macro de la
                                         Cuenca E(mu_cdmx)"), color = "#1E293B", size = 1.0) +

  # Paletas de color cruzadas (Azul para lo local de BJU, Gris/Negro para lo macro/
  # datos)

```

```

scale_color_manual(values = c(
  "Registros Diarios Observados (BJU)" = "#94A3B8",
  "Tendencia Teórica Local E(mu + alpha_bju)" = "#3498DB"
)) +
scale_fill_manual(values = c(
  "Intervalo de Credibilidad BJU (95%)" = "#3498DB"
)) +
scale_linetype_manual(values = c(
  "Tendencia Basal Macro de la Cuenca E(mu_cdmx)" = "dashed"
)) +

# Etiquetas formales bajo el estándar estricto del ITAM
labs(
  title = "Descomposición Jerárquica: dualidad Teórica vs. Evidencia Empírica",
  subtitle = "Contraste simultáneo del fondo de la cuenca, la curva local ajustada y
los registros reales de Benito Juárez",
  x = "Cronología Diaria (Ciclo Anual 2023)",
  y = expression(paste("Concentración de ", PM[2.5], " (", mu, "g/", m^3, ")")),
  color = "Estimaciones Puntuales y Datos",
  fill = "Bandas de Probabilidad Epistémica",
  linetype = "Referencia Global"
) +

theme_minimal() +
theme(
  legend.position = "bottom",
  legend.box = "vertical",
  plot.title = element_text(face = "bold", size = 13, color = "#1E293B"),
  plot.subtitle = element_text(size = 9, italic = TRUE, color = "gray30"),
  panel.grid.minor = element_blank(),
  legend.title = element_text(face = "bold", size = 9),
  legend.text = element_text(size = 8.5)
)

```

Figuras del Modelo F — figuras_modelo_F.R

```

### ----- REGRESION AVANZADA ----- ###
# --- Guardar figuras del Modelo F para el reporte LaTeX --- #
# Requiere: output/figures/Contaminacion_Fase1_SerieTiempo.RData
#           output/figures/Contaminacion_Fase2_SerieTiempo.RData

library(dplyr)
library(ggplot2)

wdir <- normalizePath(file.path(dirname(rstudioapi::getActiveDocumentContext())$path),
  "..")
setwd(wdir)
outdir <- "output/figures"

load(file.path(outdir, "Contaminacion_Fase1_SerieTiempo.RData")) # -> output_jags
load(file.path(outdir, "Contaminacion_Fase2_SerieTiempo.RData")) # -> output_fase2

```

```

# =====
# FIGURA 1: Diagnostico MCMC Etapa 1 --- beta[1]
# =====
beta_c1 <- output_jags$BUGSoutput$sims.array[, 1, "beta[1]"]
beta_c2 <- output_jags$BUGSoutput$sims.array[, 2, "beta[1]"]
N_iter <- length(beta_c1)

png(file.path(outdir, "diag_cadena_F1_beta1.png"), width = 900, height = 900)
par(mfrow = c(3, 2), mar = c(4, 4, 2, 1), oma = c(0, 0, 3, 0))

plot(beta_c1, type = "l", col = "#3498DB", xlab = "Iteracion", ylab = "Valor",
      main = "Traza --- beta[1] (sen_t)")
lines(beta_c2, col = "#E74C3C")

m1 <- cumsum(beta_c1) / (1:N_iter)
m2 <- cumsum(beta_c2) / (1:N_iter)
plot(m1, type = "l", col = "#3498DB", ylim = range(c(m1, m2)),
      xlab = "Iteracion", ylab = "Media", main = "Media ergodica")
lines(m2, col = "#E74C3C")

hist(beta_c1, breaks = 25, col = "#3498DB", border = "white",
      main = "Posterior cadena 1", xlab = "beta[1]", ylab = "Frecuencia")
hist(beta_c2, breaks = 25, col = "#E74C3C", border = "white",
      main = "Posterior cadena 2", xlab = "beta[1]", ylab = "Frecuencia")

acf(beta_c1, main = "ACF cadena 1")
acf(beta_c2, main = "ACF cadena 2")

title(main = "Modelo F Etapa 1 --- Diagnostico MCMC: beta[1]", outer = TRUE, font = 2)
dev.off()
cat("Figura 1 guardada: diag_cadena_F1_beta1.png\n")

# =====
# FIGURA 2: Diagnostico MCMC Etapa 2 --- gamma[1]
# =====
g1 <- output_fase2$BUGSoutput$sims.array[, 1, "gamma[1]"]
g2 <- output_fase2$BUGSoutput$sims.array[, 2, "gamma[1]"]
g3 <- output_fase2$BUGSoutput$sims.array[, 3, "gamma[1]"]
N2 <- length(g1)

png(file.path(outdir, "diag_cadena_F2_gamma1.png"), width = 900, height = 900)
par(mfrow = c(3, 2), mar = c(4, 4, 2, 1), oma = c(0, 0, 3, 0))

rng <- range(c(g1, g2, g3))
plot(g1, type = "l", col = "#3498DB", ylim = rng,
      xlab = "Iteracion", ylab = "Valor", main = "Traza --- gamma[1] (intercepto ZMVM)")
lines(g2, col = "#E74C3C"); lines(g3, col = "#2ECC71")

e1 <- cumsum(g1)/(1:N2); e2 <- cumsum(g2)/(1:N2); e3 <- cumsum(g3)/(1:N2)
plot(e1, type = "l", col = "#3498DB", ylim = range(c(e1,e2,e3)),
      xlab = "Iteracion", ylab = "Media", main = "Media ergodica")
lines(e2, col = "#E74C3C"); lines(e3, col = "#2ECC71")

hist(g1, breaks = 25, col = "#3498DB", border = "white",

```

```

    main = "Posterior cadena 1", xlab = "gamma[1]", ylab = "Frecuencia")
hist(g2, breaks = 25, col = "#E74C3C", border = "white",
    main = "Posterior cadena 2", xlab = "gamma[1]", ylab = "Frecuencia")

acf_g1 <- acf(g1, plot = FALSE, lag.max = 30)
acf_g2 <- acf(g2, plot = FALSE, lag.max = 30)
acf_g3 <- acf(g3, plot = FALSE, lag.max = 30)
plot(0:30, acf_g1$acf, type = "h", col = "#3498DB", lwd = 2,
    xlab = "Lag", ylab = "ACF", main = "ACF cadenas 1-3", ylim = c(-0.1, 1))
lines(0:30, acf_g2$acf, type = "h", col = "#E74C3C", lwd = 2)
lines(0:30, acf_g3$acf, type = "h", col = "#2ECC71", lwd = 2)
abline(h = c(-1.96/sqrt(N2), 1.96/sqrt(N2)), col = "gray", lty = 2)

hist(g3, breaks = 25, col = "#2ECC71", border = "white",
    main = "Posterior cadena 3", xlab = "gamma[1]", ylab = "Frecuencia")

title(main = "Modelo F Etapa 2 --- Diagnostico MCMC: gamma[1]", outer = TRUE, font = 2)
dev.off()
cat("Figura 2 guardada: diag_cadena_F2_gamma1.png\n")

# =====
# FIGURA 3: Validacion imputacion Fase 1 --- 3 estaciones
# =====

# Reconstruir datos necesarios para las 3 estaciones de validacion
ruta_csv <- "data/clean/pm25_valle_mexico.csv"
df_orig <- read.csv(ruta_csv)
df_orig$date <- as.Date(df_orig$date)

nodos_geo <- df_orig %>% select(estacion, lat, lon) %>% distinct() %>% arrange(
    estacion)
dias_ano <- seq(as.Date("2023-01-01"), as.Date("2023-12-31"), by = "day")

grid_completo <- expand.grid(date = dias_ano, estacion = nodos_geo$estacion) %>%
    left_join(df_orig, by = c("date", "estacion")) %>%
    group_by(estacion) %>%
    mutate(
        temp = ifelse(is.na(temp), mean(temp, na.rm = TRUE), temp),
        hr = ifelse(is.na(hr), mean(hr, na.rm = TRUE), hr)
    ) %>%
    ungroup() %>%
    arrange(estacion, date)

sims_log_pm25 <- output_jags$BUGSoutput$sims.list$log_pm25
pm25_mean_mat <- apply(sims_log_pm25, c(2, 3), mean)
pm25_inf_mat <- apply(sims_log_pm25, c(2, 3), quantile, probs = 0.025)
pm25_sup_mat <- apply(sims_log_pm25, c(2, 3), quantile, probs = 0.975)

df_post <- grid_completo %>%
    mutate(
        pm25_est = exp(as.vector(pm25_mean_mat)),
        ic_inf = exp(as.vector(pm25_inf_mat)),
        ic_sup = exp(as.vector(pm25_sup_mat))
    )

```

```

est_obj <- c("Hospital General de Mexico", "Santiago Acahualtepec", "Benito Juarez")
df_val <- df_post %>%
  filter(estacion %in% est_obj) %>%
  mutate(estacion_lab = factor(
    estacion, levels = est_obj,
    labels = c("Hospital General de Mexico (52 obs)",
               "Santiago Acahualtepec (189 obs)",
               "Benito Juarez (236 obs)")
  ))

p_val <- ggplot(df_val, aes(x = date)) +
  geom_ribbon(aes(ymin = ic_inf, ymax = ic_sup), fill = "#3498DB", alpha = 0.25) +
  geom_line(aes(y = pm25_est), color = "#2C3E50", linewidth = 0.7) +
  geom_point(aes(y = pm25), color = "gray40", alpha = 0.45, size = 0.9) +
  facet_wrap(~estacion_lab, ncol = 1, scales = "free_y") +
  labs(
    title = "Modelo F Etapa 1: Validacion de imputacion MCMC",
    subtitle = "Linea: media posterior | Banda: IC 95% | Puntos: observados",
    x = "Fecha (2023)", y = expression(PM[2.5] ~ "(*mu*g/m^3*)")
  ) +
  theme_minimal() +
  theme(
    plot.title = element_text(face = "bold", size = 13, color = "#2C3E50"),
    plot.subtitle = element_text(size = 9, face = "italic", color = "gray30"),
    strip.text = element_text(face = "bold", size = 10),
    panel.grid.minor = element_blank()
  )

ggsave(file.path(outdir, "validacion_F1_imputacion.png"),
  plot = p_val, width = 9, height = 8, dpi = 120)
cat("Figura 3 guardada: validacion_F1_imputacion.png\n")

# =====
# FIGURA 4: Serie tiempo macro-ambiental ZMVM (Etapa 2)
# =====

res2 <- output_fase2$BUGSoutput$summary
idx_mu <- grep("^mu_cdmx\\[", rownames(res2))
df_mu <- as.data.frame(res2[idx_mu, c("mean", "2.5%", "97.5%")])
vector_fechas <- seq(as.Date("2023-01-01"), as.Date("2023-12-31"), by = "day")

df_zmvm <- data.frame(
  fecha = vector_fechas,
  pm25 = exp(df_mu$mean),
  ic_inf = exp(df_mu$'2.5%'),
  ic_sup = exp(df_mu$'97.5%')
)

p_zmvm <- ggplot(df_zmvm, aes(x = fecha)) +
  geom_ribbon(aes(ymin = ic_inf, ymax = ic_sup), fill = "#E74C3C", alpha = 0.25) +
  geom_line(aes(y = pm25), color = "#2C3E50", linewidth = 0.9) +
  labs(
    title = "Modelo F Etapa 2: Tendencia macro-ambiental de la ZMVM",

```



```

    subtitle = expression(paste("Media posterior de exp(", mu[t]^{ZMVM}, ") | Banda:
    IC 95%")),
    x = "Fecha (2023)",
    y = expression(PM[2.5]~"(*mu*g/m^3*)")
  ) +
  theme_minimal() +
  theme(
    plot.title = element_text(face = "bold", size = 13, color = "#2C3E50"),
    plot.subtitle = element_text(size = 9, face = "italic", color = "gray30"),
    panel.grid.minor = element_blank()
  )

ggsave(file.path(outdir, "serie_mu_cdmx.png"),
       plot = p_zmvm, width = 9, height = 4.5, dpi = 120)
cat("Figura 4 guardada: serie_mu_cdmx.png\n")

# =====
# FIGURA 5: Efectos espaciales Etapa 2 --- alpha_corregido
# =====

estaciones_ord <- sort(unique(df_orig$estacion))
idx_alph <- grep("^alpha_corregido\\[", rownames(res2))
df_alph <- as.data.frame(res2[idx_alph, c("mean", "2.5%", "97.5%")])

df_ef <- data.frame(
  estacion = factor(estaciones_ord,
                    levels = estaciones_ord[order(df_alph$mean)]),
  media = df_alph$mean,
  q025 = df_alph$'2.5%',
  q975 = df_alph$'97.5%'
)

p_ef <- ggplot(df_ef, aes(x = estacion, y = media)) +
  geom_hline(yintercept = 0, color = "#7F8C8D", linetype = "dashed", linewidth = 0.7) +
  geom_errorbar(aes(ymin = q025, ymax = q975),
               width = 0.3, color = "#E74C3C", linewidth = 0.7) +
  geom_point(color = "#2C3E50", size = 2.5) +
  coord_flip() +
  labs(
    title = "Modelo F Etapa 2: Efectos espaciales de estacion",
    subtitle = expression(paste("Media posterior e IC 95% de ", alpha[j]^{*}, " (suma
    cero)")),
    x = NULL,
    y = expression(paste("Desviacion respecto a la media de la ZMVM (log-escala)
    "))
  ) +
  theme_minimal() +
  theme(
    plot.title = element_text(face = "bold", size = 13, color = "#2C3E50"),
    plot.subtitle = element_text(size = 9, face = "italic", color = "gray30"),
    panel.grid.minor = element_blank(),
    axis.text.y = element_text(size = 9, color = "#2C3E50")
  )

ggsave(file.path(outdir, "efectos_F2_estaciones.png"),

```

```

    plot = p_ef, width = 7.5, height = 5.5, dpi = 120)
cat("Figura 5 guardada: efectos_F2_estaciones.png\n")

cat("\n=== Todas las figuras del Modelo F guardadas en", outdir, "===\n")

```

Especificaciones JAGS

Listing 1: Especificación JAGS — Modelo A (Normal global).

```

model {
  # Verosimilitud
  for (i in 1:n) {
    logy[i] ~ dnorm(mu[i], tau)
    mu[i] <- alpha + beta[1]*temp[i] + beta[2]*hr[i] + beta[3]*sen_t[i] + beta[4]*cos_t[i]

    # Predictiva
    yf1[i] ~ dnorm(mu[i], tau)
  }

  # Priors
  alpha ~ dnorm(0, 0.001)
  for (j in 1:4) {
    beta[j] ~ dnorm(0, 0.001)
  }
  tau ~ dgamma(0.001, 0.001)

  # Derived
  sigma <- 1 / sqrt(tau)
}

```

Listing 2: Especificación JAGS — Modelo B (Efectos fijos por estación).

```

model {
  # Verosimilitud
  for (i in 1:n) {
    logy[i] ~ dnorm(mu[i], tau)
    mu[i] <- alpha.adj + alphaj.adj[est[i]]
      + beta[1]*temp[i] + beta[2]*hr[i]
      + beta[3]*sen_t[i] + beta[4]*cos_t[i]

    # Predictiva
    yf1[i] ~ dnorm(mu[i], tau)
  }

  # Identificabilidad: sum-to-zero
  alpha.adj <- alpha + mean(alphaj[])
  for (j in 1:J) {
    alphaj.adj[j] <- alphaj[j] - mean(alphaj[])
  }

  # Priors

```

```

alpha ~ dnorm(0, 0.001)
for (j in 1:J) {
  alphaj[j] ~ dnorm(0, 0.001)
}
for (k in 1:4) {
  beta[k] ~ dnorm(0, 0.001)
}
tau ~ dgamma(0.001, 0.001)

# Derived
sigma <- 1 / sqrt(tau)
}

```

Listing 3: Especificación JAGS — Modelo C1 (Jerárquico Normal, modelo preferido).

```

model {
  # Verosimilitud
  for (i in 1:n) {
    logy[i] ~ dnorm(mu[i], tau)
    mu[i] <- alpha + alphaj[est[i]]
              + beta[1]*temp[i] + beta[2]*hrc[i]
              + beta[3]*sen_t[i] + beta[4]*cos_t[i]

    # Predictiva
    yf1[i] ~ dnorm(mu[i], tau)
  }

  # Efectos aleatorios por estacion
  for (j in 1:J) {
    alphaj[j] ~ dnorm(0, tau.alphaj)
  }

  # Priors
  alpha ~ dnorm(0, 0.001)
  for (k in 1:4) {
    beta[k] ~ dnorm(0, 0.001)
  }
  tau ~ dgamma(0.001, 0.001)
  tau.alphaj ~ dgamma(0.001, 0.001)

  # Derived
  sigma <- 1 / sqrt(tau)
  sigma.alphaj <- 1 / sqrt(tau.alphaj)
}

```

Listing 4: Especificación JAGS — Modelo C2 (Gamma global).

```

model {
  for (i in 1:n) {
    pm25[i] ~ dgamma(a, a/mu[i])
    log(mu[i]) <- alpha + beta[1]*tempc[i] + beta[2]*hrc[i]
                  + beta[3]*sen_t[i] + beta[4]*cos_t[i]
    yf1[i] ~ dgamma(a, a/mu[i])
  }
}

```

```

alpha ~ dnorm(0, 0.001)
for (k in 1:4) {
  beta[k] ~ dnorm(0, 0.001)
}
a ~ dgamma(0.001, 0.001)

sigma.C2 <- 1/sqrt(a)
}

```

Listing 5: Especificación JAGS — Modelo D (Tendencia espacial lineal).

```

model {
  # Verosimilitud
  for (i in 1:n) {
    logy[i] ~ dnorm(mu[i], tau)
    mu[i] <- alpha + beta[1]*temp[i] + beta[2]*hr[i]
      + beta[3]*sen_t[i] + beta[4]*cos_t[i]
      + beta[5]*lat[i] + beta[6]*lon[i]

    # Predictiva
    yf1[i] ~ dnorm(mu[i], tau)
  }

  # Priors
  alpha ~ dnorm(0, 0.001)
  for (k in 1:6) {
    beta[k] ~ dnorm(0, 0.001)
  }
  tau ~ dgamma(0.001, 0.001)

  # Derived
  sigma <- 1 / sqrt(tau)
}

```

Listing 6: Especificación JAGS — Modelo F, Etapa 1 (Proceso gaussiano espacio-temporal).

```

model {
  # 1. VEROSIMILITUD E IMPUTACIÓN DE LA VARIABLE RESPUESTA LATENTE
  for (t in 1:N_dias) {
    for (j in 1:N_estaciones) {
      log_pm25[t, j] ~ dnorm(mu[t, j], tau_y)
      mu[t, j] <- alphaj[j] + beta[1]*sen_t[t] + beta[2]*cos_t[t] + beta[3]*temp[t, j]
      + beta[4]*hr[t, j]
    }
  }

  # 2. EL GRADIENTE ESPACIAL DE TOBLER (Normal Multivariada Por Distancia)
  alphaj[1:N_estaciones] ~ dnmnorm(mu_alpha[1:N_estaciones], T_espacial[1:N_estaciones,
    1:N_estaciones])
  for(j in 1:N_estaciones) { mu_alpha[j] <- 0 }

  for(k in 1:N_estaciones) {
    for(l in 1:N_estaciones) {

```

```

        Sigma_espacial[k, l] <- (1 / tau_alpha) * exp(-phi * D[k, l])
    }
}
T_espacial[1:N_estaciones, 1:N_estaciones] <- inverse(Sigma_espacial[1:N_estaciones,
1:N_estaciones])

# 3. DISTRIBUCIONES PRIORIS ESTRUCTURALES NO INFORMATIVAS
for(k in 1:4) { beta[k] ~ dnorm(0, 0.001) }
tau_y      ~ dgamma(0.1, 0.1)
tau_alpha ~ dgamma(0.1, 0.1)
phi        ~ dunif(0.01, 5)
}

```

Listing 7: Especificación JAGS — Modelo F, Etapa 2 (Agregación jerárquica ZMVM).

```

model {
  # === 1. BUCLE ESPACIO-TEMPORAL (VEROSIMILITUD) ===
  for(t in 1:N_dias) {
    for(j in 1:N_estaciones) {
      # mu_cdmx[t] lleva el intercepto global limpio gamma[1]
      y[t, j] ~ dnorm(mu_cdmx[t] + alpha_corregido[j], prec_heredada[t, j])
    }

    # Tendencia macro-ambiental de la cuenca (Fourier de un armónico)
    mu_cdmx[t] <- gamma[1] + gamma[2]*sen_t[t] + gamma[3]*cos_t[t]
  }

  # === 2. PRIORIS ESTRUCTURALES NO-INFORMATIVAS ===
  for(k in 1:3) {
    gamma[k] ~ dnorm(0, 0.001)
  }

  for(j in 1:N_estaciones) {
    alpha[j] ~ dnorm(0, tau_estacion)

    # RESTRICCIÓN CRÍTICA: Restamos la media para forzar a que sumen cero
    alpha_corregido[j] <- alpha[j] - media_alpha
  }

  # Cálculo de la media del vector alpha
  media_alpha <- mean(alpha[1:N_estaciones])

  # Prioris sobre los componentes de varianza
  tau_estacion ~ dgamma(0.1, 0.1)
  tau_ciudad ~ dgamma(0.1, 0.1)

  # Parámetro de escala para el reporte
  sigma_ciudad <- 1 / sqrt(tau_ciudad)
}

```