

Proyecto Final — Regresión Avanzada

Análisis Bayesiano Espacial de PM2.5 en el Valle de México

Paulina Garza Allende Andrea Monserrat Arredondo Rodríguez
Othoniel Camacho

19 de mayo de 2026

1. Introducción

El Valle de México es una cuenca hidrológica cerrada que alberga la Zona Metropolitana del Valle de México (ZMVM), con aproximadamente 22 millones de habitantes. Su geometría de cuenca cerrada impide la ventilación natural de los contaminantes, lo que convierte al PM2.5 (material particulado fino con diámetro aerodinámico $\leq 2.5 \mu\text{m}$) en uno de los principales problemas de salud pública de la región. La exposición crónica a PM2.5 está asociada con enfermedades respiratorias, cardiovasculares y aumento en la mortalidad.

La fuente de datos es el Sistema Nacional de Información de la Calidad del Aire (SINAICA), operado por el Instituto Nacional de Ecología y Cambio Climático. Se descargaron datos de las 56 estaciones de monitoreo ubicadas dentro de los límites del Valle de México (16 alcaldías de la CDMX, 59 municipios del Estado de México, más Tizayuca en Hidalgo). De estas, solo 14 estaciones reportaron simultáneamente concentración de PM2.5, temperatura y humedad relativa durante 2023, con un total de 2,617 observaciones diarias (enero–diciembre de 2023).

La pregunta central de este proyecto es:

¿Qué tan importante es la estructura espacial para explicar la variación de PM2.5 en el Valle de México, y podemos usarla para predecir la contaminación en zonas sin sensores?

Para responderla se ajustan seis modelos bayesianos de complejidad creciente en JAGS a través del paquete `R2jags`:

1. **Modelo A — Normal global:** ¿cuánto de la variación de PM2.5 explican el clima y la estacionalidad, sin considerar la ubicación?
2. **Modelo B — Efectos fijos:** ¿existen diferencias sistemáticas entre estaciones que no se explican por clima?
3. **Modelo C1 — Jerárquico:** ¿es mejor modelar esas diferencias como un proceso aleatorio común con encogimiento (*shrinkage*) que como parámetros independientes?

4. **Modelo C2 — Gamma:** ¿es la distribución Gamma, que respeta el soporte positivo de PM2.5, mejor que la Normal sobre el logaritmo?
5. **Modelo D — Tendencia lat/lon:** ¿captura un gradiente lineal en latitud y longitud el patrón espacial, o se necesita un modelo no lineal?

El **Modelo E** usa los efectos espaciales del Modelo C1 para hacer kriging bayesiano y predecir PM2.5 en los 141 polígonos del Valle de México, incluyendo los 44 municipios de EDOMEX sin estaciones de monitoreo.

Finalmente, el **Modelo F — Espacio-Temporal Jerárquico** integra ambas dimensiones en un marco unificado: ajusta un panel balanceado 365×14 donde los valores faltantes se imputan directamente como variables latentes dentro del muestreador MCMC, la estructura espacial entre estaciones se modela mediante una Normal Multivariada con kernel exponencial, y una segunda etapa de agregación jerárquica estima la tendencia macro-ambiental diaria de la ZMVM con propagación explícita de la incertidumbre de la primera etapa.

2. Descripción de la información

Variables

Cuadro 1: Variables utilizadas en el análisis.

Variable	Descripción	Rol	Escala
pm25	Concentración diaria promedio de PM2.5 ($\mu\text{g}/\text{m}^3$)	Respuesta	Razón
temp	Temperatura diaria promedio ($^{\circ}\text{C}$)	Covariable meteorológica	Intervalo
hr	Humedad relativa diaria promedio (%)	Covariable meteorológica	Intervalo
sen_t	$\sin(2\pi \cdot \text{día}/365)$	Covariable estacional (Fourier)	Intervalo
cos_t	$\cos(2\pi \cdot \text{día}/365)$	Covariable estacional (Fourier)	Intervalo
lat, lon	Coordenadas geográficas de la estación	Predictor espacial	Intervalo
estación	Nombre de la estación de monitoreo	Agrupador	Nominal

La temperatura y la humedad relativa se estandarizaron (media 0, desviación estándar 1) antes de ingresarlas a JAGS, para mejorar la convergencia del MCMC y hacer comparables las magnitudes de los coeficientes. PM2.5 se transforma a escala logarítmica en todos los modelos Normal (A, B, C1, D), lo que estabiliza la varianza y linealiza la relación con las covariables. Los términos de Fourier sen_t y cos_t capturan el ciclo anual de la contaminación mediante una suma armónica de un solo par de frecuencias, suficiente para describir la estacionalidad predominante observada en los datos.

Estaciones de monitoreo

Cuadro 2: Resumen por estación (datos 2023, $n = 2,617$ observaciones totales).

Estación	Municipio	n	Temp. (°C)	HR (%)	PM2.5 ($\mu\text{g}/\text{m}^3$)
Santiago Acahualtepec	Iztapalapa	189	17.4	46.4	23.5
Hospital General México	Cuauhtémoc	52	19.2	33.1	22.7
Gustavo A. Madero	G. A. Madero	154	19.4	45.2	22.7
Tlalnepantla	Tlalnepantla	174	18.5	41.9	21.8
San Agustín	Ecatepec	84	19.9	49.5	20.7
UAM Iztapalapa	Iztapalapa	207	19.7	49.5	20.6
Merced	Venustiano C.	235	20.0	47.8	20.6
UAM Xochimilco	Coyoacán	233	17.5	48.2	20.5
Nezahualcóyotl	Nezahualcóyotl	218	19.5	43.9	20.4
Benito Juárez	Benito Juárez	236	19.2	45.3	19.8
FES Aragón	Nezahualcóyotl	233	20.1	48.0	18.0
Pedregal	Álvaro Obregón	181	17.2	49.7	16.2
Ajusco Medio	Tlalpan	188	14.5	55.2	16.0
Biblioteca	Tizayuca	233	14.5	50.9	15.4

El rango de concentraciones promedio entre estaciones va de $15.4 \mu\text{g}/\text{m}^3$ (Biblioteca, Tizayuca) a $23.5 \mu\text{g}/\text{m}^3$ (Santiago Acahualtepec, Iztapalapa), una diferencia de 52 % entre la estación más limpia y la más contaminada. Todas las estaciones superan la guía de la OMS de $5 \mu\text{g}/\text{m}^3$ para el promedio anual.

Análisis exploratorio




Figura 1: Histogramas de las variables principales. La distribución de PM2.5 tiene cola de derecha pronunciada; en escala logarítmica se aproxima más a la Normal, lo que justifica la transformación utilizada en los modelos.




Figura 2: $\log(\text{PM}_{2.5})$ en función de temperatura, humedad relativa y día del año. La línea lowess muestra la tendencia suavizada. La relación con temperatura es positiva; con humedad relativa, también positiva dentro de cada estación; con el tiempo, se observa un mínimo estival seguido de un repunte en agosto–septiembre que coincide con el final de la temporada de lluvias.




Figura 3: $\text{PM}_{2.5}$ en función de temperatura, humedad y día del año, coloreado por entidad federativa (CDMX, Estado de México, Hidalgo). La heterogeneidad espacial visible entre grupos motiva la inclusión de efectos por estación en los modelos.




Figura 4: PM_{2.5} por estación, ordenadas de menor a mayor concentración media. La línea punteada roja marca el promedio global ($\approx 19.7 \mu\text{g}/\text{m}^3$). Se observan diferencias claras entre estaciones, especialmente en los extremos: Ajusco Medio y Biblioteca tienen niveles sistemáticamente menores que Santiago Acahualtepec y Gustavo A. Madero.




Figura 5: PM2.5 por mes. Se aprecia un máximo en invierno (enero–marzo), un mínimo en verano (junio–julio) y un repunte en agosto–septiembre, patrón que motiva el uso de términos de Fourier en la especificación del modelo.




Figura 6: Matriz de correlación de las variables. PM2.5 está más correlacionado con `sen.t` ($r = 0.48$) y con `cos.t`, lo que confirma la importancia de la estacionalidad. La correlación con temperatura y humedad es moderada.

3. Modelado e implementación

Configuración general

Todos los modelos se ajustaron en JAGS con dos cadenas de Markov, partiendo de valores iniciales distintos para verificar convergencia. Las distribuciones iniciales son poco informativas: $\mathcal{N}(0, 1000)$ para los coeficientes (varianza 1,000, equivalente a la precisión $\tau = 0.001$ en notación JAGS) y $\text{Ga}(0.001, 0.001)$ para las precisiones.

La convergencia se evalúa mediante seis paneles por parámetro: traza de ambas cadenas (patrón tipo “oruga” indica buena mezcla), promedio ergódico (debe estabilizarse al mismo valor en ambas cadenas), histogramas de la distribución final en cada cadena (deben coincidir) y función de autocorrelación (ACF, debe caer rápidamente a cero).

Criterio de información de la desvianza (DIC). Para comparar modelos dentro de una misma familia distribucional se usa el DIC, definido como

$$\text{DIC} = \bar{D} + p_D = 2\bar{D} - D(\bar{\theta}),$$

donde $\bar{D} = E_{\theta|\mathbf{y}}[-2 \log f(\mathbf{y}|\theta)]$ es la deviance media posterior, $D(\bar{\theta})$ es la deviance evaluada en la media posterior, y $p_D = \bar{D} - D(\bar{\theta})$ es el número efectivo de parámetros. Modelos con DIC menor son preferibles; diferencias > 10 puntos son consideradas sustanciales. El DIC sólo es comparable entre modelos con idéntica variable respuesta y familia distribucional.

Pseudo- R^2 y significancia. El pseudo- R^2 se define como el cuadrado de la correlación entre los valores observados y los predichos a posteriori:

$$R^2 = [\text{Corr}(y_i, \hat{y}_i)]^2,$$

donde $\hat{y}_i = E[Y_i|\mathbf{y}]$ es la media de la distribución final predictiva.

La significancia de los coeficientes se evalúa mediante el intervalo de credibilidad al 95 %: si el intervalo no contiene el cero, el parámetro es considerado significativo. Como medida complementaria se reporta

$$p(\beta_k) = \min(P(\beta_k > 0), P(\beta_k < 0)),$$

donde valores cercanos a 0 indican que toda la masa de la distribución final se concentra en un solo signo (el parámetro es claramente distinto de cero).

3.1. Modelo A — Normal global

El Modelo A es la línea base. Ignora por completo la ubicación geográfica y modela $\log(\text{PM2.5})$ exclusivamente con clima y estacionalidad:

$$\log(\text{PM2.5}_i) \sim \mathcal{N}(\mu_i, \tau^{-1}), \quad \mu_i = \alpha + \beta_1 \text{temp}_i + \beta_2 \text{hr}_i + \beta_3 \text{sen_t}_i + \beta_4 \text{cos_t}_i. \quad (1)$$

Las distribuciones iniciales son:

$$\alpha \sim \mathcal{N}(0, 1000), \quad \beta_k \sim \mathcal{N}(0, 1000) \quad (k = 1, \dots, 4), \quad \tau \sim \text{Ga}(0.001, 0.001).$$

Se corrieron 10,000 iteraciones con 1,000 de calentamiento y sin adelgazamiento, con 9,000 muestras activas por cadena.

Diagnóstico




Figura 7: Diagnósticos del Modelo A para el intercepto α . La traza muestra el patrón de “oruga” característico de buena mezcla; el promedio ergódico de ambas cadenas converge al mismo valor; los histogramas de la distribución final son idénticos; la ACF cae a cero desde el rezago 1. El mismo comportamiento se observa para $\beta_1, \dots, \beta_4$ y σ .

Resultados

Cuadro 3: Media de la distribución final del Modelo A.

Parámetro	Media
Intercepto α (log-PM2.5 global promedio)	2.819
β_1 : cambio en log-PM2.5 por 1-DE de temperatura	0.096
β_2 : cambio en log-PM2.5 por 1-DE de humedad relativa	0.031
β_3 : amplitud seno del patrón estacional (sen_t)	0.351
β_4 : amplitud coseno del patrón estacional (cos_t)	0.172
Desviación estándar residual $\sigma = 1/\sqrt{\tau}$	0.424
DIC	2 942.6
Pseudo- R^2	0.313

El intercepto $\hat{\alpha} = 2.819$ corresponde a un PM2.5 esperado de $e^{2.819} \approx 16.8 \mu\text{g}/\text{m}^3$ cuando todas las covariables están en sus valores medios. El coeficiente de temperatura ($\hat{\beta}_1 = 0.096$) indica que por cada unidad de desviación estándar adicional en temperatura (equivalente a $\approx 2.1^\circ\text{C}$), la concentración esperada de PM2.5 aumenta en $e^{0.096} \approx 1.10$, es decir un 10 %. En el contexto del Valle de México, esto refleja que los días más cálidos dentro de una misma temporada tienden a ser más secos y con menor dilución de contaminantes por lluvias.

Los términos de Fourier describen un ciclo anual con amplitud $\sqrt{0.351^2 + 0.172^2} \approx 0.39$ log-unidades, equivalente a una variación de $\pm 38\%$ alrededor de la media estacional. El máximo de la función estacional ocurre alrededor del día 58 (fines de febrero), correspondiente al final de la temporada seca e inicio de la temporada de incendios forestales.

El Modelo A explica el 31.3 % de la variación total de log-PM2.5 (pseudo- $R^2 = 0.313$).




Figura 8: Observado vs. predicho en escala log para el Modelo A. La dispersión considerable alrededor de la diagonal indica que el modelo global no captura las diferencias sistemáticas entre estaciones.

3.2. Modelo B — Efectos fijos por estación

El Modelo B agrega a la ecuación (1) un efecto fijo α_j por cada estación:

$$\log(\text{PM2.5}_i) \sim \mathcal{N}(\mu_i, \tau^{-1}), \quad \mu_i = \tilde{\alpha} + \tilde{\alpha}_{j[i]} + \beta_1 \text{temp}_i + \beta_2 \text{hr}_i + \beta_3 \text{sen_t}_i + \beta_4 \text{cos_t}_i, \quad (2)$$

donde $\tilde{\alpha} = \alpha + \overline{\alpha_j}$ y $\tilde{\alpha}_j = \alpha_j - \overline{\alpha_j}$ son los ajustes de suma-cero aplicados post-muestreo para garantizar identificabilidad. Cada efecto tiene distribución inicial independiente: $\alpha_j \sim \mathcal{N}(0, 1000)$.

Se corrieron 12,000 iteraciones con 2,000 de calentamiento y adelgazamiento de 2, con 5,000 muestras activas por cadena.

Diagnóstico




Figura 9: Diagnósticos del Modelo B para el intercepto α . Las cadenas muestran buena convergencia: traza estacionaria, promedios ergódicos que coinciden, histogramas de la distribución final idénticos y ACF que cae rápidamente.

Resultados

Cuadro 4: Distribución final de los coeficientes del Modelo B. IC: intervalo de credibilidad al 95 %. $p = \min(P(\beta_k > 0), P(\beta_k < 0))$: valores cercanos a 0 indican que el parámetro es claramente distinto de cero.

Parámetro	Media	IC 2.5 %	IC 97.5 %	p
β_1 (temp., 1-DE ≈ 2.1 °C)	0.1045	0.0665	0.1416	0.000
β_2 (humedad rel., 1-DE ≈ 7.8 pp)	0.0460	0.0159	0.0754	0.001
β_3 (sen.t, amplitud estacional)	0.3331	0.3028	0.3635	0.000
β_4 (cos.t, fase estacional)	0.2145	0.1708	0.2571	0.000
Intercepto ajustado $\tilde{\alpha}$				2.830
σ residual				0.406
DIC				2724.2
Pseudo- R^2				0.375

Al controlar por estación, la humedad relativa se vuelve significativa ($\hat{\beta}_2 = 0.046$, IC = [0.016, 0.075]). Esto se debe a que, en el Modelo A, la correlación de HR con la estación de monitoreo ocultaba parte del efecto real. Por cada unidad de desviación estándar en HR (≈ 7.8 puntos porcentuales adicionales), PM2.5 sube $e^{0.046} - 1 \approx 4.7$ %. El patrón estacional se mantiene: amplitud conjunta $\sqrt{0.333^2 + 0.215^2} \approx 0.397$ log-unidades.




Figura 10: Efectos fijos por estación $\tilde{\alpha}_j$ (ajuste suma-cero). Barras verticales son intervalos de credibilidad al 95 %. Valores positivos indican estaciones más contaminadas que el promedio global; negativos, menos contaminadas. Santiago Acahualtepec es la estación más contaminada (+0.26 log-unidades, equivalente a +29 %) y Biblioteca la más limpia (−0.28, equivalente a −24 %).

Cuadro 5: Efectos fijos por estación del Modelo B ($\tilde{\alpha}_j$, restricción suma-cero). Un factor $e^{\tilde{\alpha}_j}$ mayor que 1 indica una estación más contaminada que el promedio global.

Estación	$\tilde{\alpha}_j$	Factor ($e^{\tilde{\alpha}_j}$)
Santiago Acahualtepec	+0.258	1.29
Tlalnepantla	+0.143	1.15
Ajusco Medio	+0.073	1.08
UAM Xochimilco	+0.075	1.08
Benito Juárez	+0.048	1.05
Merced	+0.032	1.03
Nezahualcóyotl	+0.019	1.02
San Agustín	+0.016	1.02
Gustavo A. Madero	−0.040	0.96
UAM Iztapalapa	−0.045	0.96
Pedregal	−0.059	0.94
Hospital General México	−0.102	0.90
FES Aragón	−0.143	0.87
Biblioteca	−0.275	0.76

La mejora sobre el Modelo A es sustancial: $\Delta\text{DIC} = 2,942.6 - 2,724.2 = 218.4$ puntos, lo que indica que la estructura espacial tiene un efecto fuerte sobre PM2.5 que no es explicado por clima ni estacionalidad.

3.3. Modelo C1 — Jerárquico Normal

Fundamento teórico. El Modelo B trata los 14 efectos por estación como parámetros fijos e independientes. Sin embargo, si consideramos que las estaciones comparten una misma cuenca atmosférica y están sometidas a procesos de contaminación similares, resulta razonable suponer que sus efectos son *intercambiables* (de Finetti, 1937): la distribución conjunta de $(\alpha_1, \dots, \alpha_J)$ es invariante ante permutaciones. Bajo este supuesto, el teorema de representación de de Finetti garantiza que los efectos son condicionalmente independientes dado un parámetro común, lo que conduce naturalmente al modelo jerárquico.

Especificación. El Modelo C1 trata las diferencias entre estaciones como realizaciones de una distribución común, en lugar de parámetros fijos independientes:

$$\begin{aligned}
 \log(\text{PM2.5}_i) &\sim \mathcal{N}(\mu_i, \tau^{-1}), \\
 \mu_i &= \alpha + \alpha_{j[i]} + \beta_1 \text{temp}_i + \beta_2 \text{hr}_i + \beta_3 \text{sen_t}_i + \beta_4 \text{cos_t}_i, \\
 \alpha_j &\sim \mathcal{N}(0, \tau_\alpha^{-1}), \quad j = 1, \dots, 14.
 \end{aligned} \tag{3}$$

Aquí $\tau_\alpha = 1/\sigma_\alpha^2$ es la hiperprecisión que controla cuánto se permite que las estaciones se devíen del intercepto global α . Las distribuciones iniciales son:

$$\alpha \sim \mathcal{N}(0, 1000), \quad \beta_k \sim \mathcal{N}(0, 1000), \quad \tau \sim \text{Ga}(0.001, 0.001), \quad \tau_\alpha \sim \text{Ga}(0.001, 0.001).$$

El modelo jerárquico induce *encogimiento* (*shrinkage*): los efectos estimados para estaciones con pocas observaciones o con valores extremos son atraídos hacia el promedio global α , lo que reduce la varianza del estimador a costa de un pequeño sesgo.

Se corrieron 12,000 iteraciones con 2,000 de calentamiento y adelgazamiento de 2 (5,000 muestras activas por cadena).

Diagnóstico




Figura 11: Diagnósticos del Modelo C1: intercepto α (izq.) e hiperparámetro σ_α (der.). Ambos muestran convergencia satisfactoria. El mismo comportamiento se observa para $\beta_1, \dots, \beta_4$ y σ .

Resultados

Cuadro 6: Media de la distribución final del Modelo C1 (modelo preferido).

Parámetro	Media
Intercepto global α	2.830
β_1 (temperatura, 1-DE ≈ 2.1 °C)	0.103
β_2 (humedad relativa, 1-DE ≈ 7.8 pp)	0.045
β_3 (sen_t)	0.334
β_4 (cos_t)	0.211
σ residual (variabilidad dentro de estación)	0.406
σ_α (variabilidad entre estaciones)	0.134
DIC	2723.7
Pseudo- R^2	0.375

El hiperparámetro $\hat{\sigma}_\alpha = 0.134$ resume la variabilidad entre estaciones: el 68 % de las estaciones se desvía menos de ± 0.134 log-unidades del promedio global, lo que en escala multiplicativa equivale a ± 14 %. El 95 % se desvía menos de ± 0.268 log-unidades (± 31 %). Este valor es sustancial en un contexto de salud pública: dos habitantes del Valle de México, uno en la estación más contaminada y otro en la más limpia, están expuestos a concentraciones que difieren en un factor de $e^{0.134 \times 4} \approx 1.71$, es decir 71 % más en la zona más contaminada.




Figura 12: Efectos aleatorios por estación α_j del Modelo C1. Barras verticales son intervalos de credibilidad al 95 %. Comparado con el Modelo B (Fig. 10), los efectos son ligeramente más pequeños debido al encogimiento jerárquico hacia la media global. El orden relativo de las estaciones se preserva.

Cuadro 7: Efectos aleatorios por estación del Modelo C1 (α_j). IC al 95 %.

Estación	Media	DE	IC 95 %
Santiago Acahualtepec	+0.243	0.047	[+0.151, +0.334]
Tlalnepantla	+0.133	0.047	[+0.041, +0.225]
UAM Xochimilco	+0.071	0.045	[-0.017, +0.159]
Ajusco Medio	+0.065	0.052	[-0.037, +0.167]
Benito Juárez	+0.045	0.044	[-0.041, +0.132]
Merced	+0.031	0.046	[-0.059, +0.121]
Nezahualcóyotl	+0.018	0.045	[-0.070, +0.107]
San Agustín	+0.015	0.055	[-0.093, +0.123]
Gustavo A. Madero	-0.037	0.049	[-0.133, +0.059]
UAM Iztapalapa	-0.042	0.046	[-0.133, +0.049]
Pedregal	-0.058	0.046	[-0.148, +0.033]
Hospital General México	-0.086	0.061	[-0.206, +0.034]
FES Aragón	-0.137	0.046	[-0.227, -0.048]
Biblioteca	-0.265	0.048	[-0.359, -0.172]

Comparando con el Modelo B, se observa el encogimiento jerárquico esperado: Santiago Acahualtepec pasa de +0.258 (B) a +0.243 (C1), y Biblioteca de -0.275 a -0.265 . Con ≈ 186 observaciones por estación en promedio, los datos tienen suficiente información para que el hiperparámetro esté bien identificado y el encogimiento sea moderado.

3.4. Modelo C2 — Gamma global

El Modelo C2 modela PM2.5 directamente en escala original (no logarítmica), usando una distribución Gamma con función liga logarítmica:

$$\text{PM2.5}_i \sim \text{Gamma}(a, a/\mu_i), \quad \log(\mu_i) = \alpha + \beta_1 \text{tempc}_i + \beta_2 \text{hrc}_i + \beta_3 \text{sen_t}_i + \beta_4 \text{cos_t}_i, \quad (4)$$

donde tempc_i y hrc_i son temperatura y HR centradas (restando la media global, sin estandarizar, para mayor estabilidad numérica del muestreador Metropolis-Hastings de JAGS). El parámetro $a > 0$ es la forma de la Gamma: su media es μ_i y su varianza es μ_i^2/a ; valores grandes de a implican menor coeficiente de variación. La distribución inicial es $a \sim \text{Ga}(0.001, 0.001)$. Los valores iniciales se fijan en $\alpha_0 = \log(\bar{y}) \approx 2.94$ para evitar valores inválidos de μ durante el calentamiento.

Se corrieron 15,000 iteraciones con 3,000 de calentamiento y adelgazamiento de 3 (4,000 muestras activas por cadena).

Diagnóstico




Figura 13: Diagnósticos del parámetro de forma a del Modelo C2. Las cadenas muestran mayor autocorrelación que en los modelos Normal (la ACF tarda más en caer), lo que es típico de la Gamma ajustada con Metropolis-Hastings en JAGS. El promedio ergódico converge alrededor de $a \approx 6.6$.

Resultados

Cuadro 8: Media de la distribución final del Modelo C2 (Gamma global). El DIC *no es comparable* con los modelos A, B, C1 y D porque la variable respuesta está en escala original (no logarítmica). Se usa el pseudo- R^2 en escala log para comparar entre familias.

Parámetro	Media
Intercepto α (log-media cuando covariables = 0)	2.908
β_1 (temperatura, por °C centrado)	0.027
β_2 (humedad relativa, por punto porcentual centrado)	0.004
β_3 (sen_t)	0.312
β_4 (cos_t)	0.190
Parámetro de forma a (mayor a = menor variabilidad)	6.625
DIC (no comparable entre familias)	17 636.6
Pseudo- R^2 en escala log	0.310

El Modelo C2 tiene un pseudo- R^2 ligeramente menor que el Modelo A (0.310 vs 0.313), lo que sugiere que, sin efectos por estación, la Normal sobre el logaritmo describe los datos tan bien o mejor que la Gamma. La ventaja conceptual de la Gamma (soporte positivo estricto para PM2.5) no se traduce en mejor ajuste empírico con este conjunto de datos. El parámetro $\hat{a} = 6.6$ implica un coeficiente de variación de $1/\sqrt{6.6} \approx 0.39$, consistente con la dispersión observada. El DIC de C2 es muy alto porque se calcula sobre PM2.5 en escala original (no logarítmica), por lo que *no debe compararse* con los valores de A, B, C1 o D.

3.5. Modelo D — Tendencia espacial lineal

El Modelo D agrega al Modelo A los efectos lineales de latitud y longitud estandarizadas:

$$\log(\text{PM2.5}_i) \sim \mathcal{N}(\mu_i, \tau^{-1}), \quad \mu_i = \alpha + \beta_1 \text{temp}_i + \cdots + \beta_4 \text{cos_t}_i + \beta_5 \text{lat}_i + \beta_6 \text{lon}_i, \quad (5)$$

con 6 coeficientes en total. Este modelo prueba si el patrón espacial puede describirse con un gradiente lineal simple en lugar de efectos individuales por estación. Se corrieron 10,000 iteraciones con 1,000 de calentamiento.

Diagnóstico




Figura 14: Diagnósticos del Modelo D para el intercepto α . La convergencia es satisfactoria: traza estacionaria, promedios ergódicos coincidentes y ACF que decae rápidamente.

Resultados

Cuadro 9: Distribuciones finales del Modelo D, con énfasis en los coeficientes espaciales.

Parámetro	Media
β_1 (temperatura)	0.084
β_2 (humedad relativa)	0.020
β_3 (sen.t)	0.326
β_4 (cos.t)	0.185
β_5 (latitud, 1-DE $\approx 0.25^\circ \approx 28$ km)	-0.089
β_6 (longitud, 1-DE $\approx 0.19^\circ \approx 18$ km)	+0.004
σ residual	0.416
DIC	2841.6
Pseudo- R^2	0.341

Aunque el coeficiente de latitud tiene signo negativo ($\hat{\beta}_5 = -0.089$), su intervalo de credibilidad incluye el cero, y lo mismo ocurre para la longitud. Más importante: el Modelo D apenas mejora sobre el Modelo A ($\Delta\text{DIC} = 2,942.6 - 2,841.6 = 101.0$ puntos), muy por debajo de los 218 puntos ganados por el Modelo B. Esto confirma que el patrón espacial de PM2.5 en el Valle de México *no es un gradiente lineal* en latitud y longitud: hay zonas contaminadas y limpias que no siguen una tendencia norte-sur o este-oeste simple. La estructura espacial requiere un modelo no lineal, como el proceso gaussiano del Modelo E.

3.6. Modelo E — Proceso Gaussiano y Kriging Bayesiano

Proceso gaussiano como modelo espacial

Los datos de PM2.5 son observaciones *referenciadas puntualmente*: cada medición $Y(s_j)$ corresponde a una localización específica $s_j = (\text{lon}_j, \text{lat}_j)$. Cuando las observaciones presentan dependencia espacial, el marco adecuado es el *proceso gaussiano* (PG): una colección de variables aleatorias tal que cualquier subconjunto finito tiene distribución normal multivariada. Un PG se caracteriza por su función de media $\mu(s)$ y su función de covarianza $\Sigma(s, t)$ (Nieto Barajas, 2026):

$$Y(s) \sim \mathcal{N}(\mu(s), \Sigma(s, t)).$$

Bajo el supuesto de *estacionariedad de segundo orden* — $\mu(s) = \mu$ constante y $\text{Cov}(Y(s), Y(s+h)) = C(h)$ solo depende del desplazamiento h — e *isotropía* — $C(h)$ depende solo de la distancia $\|h\|$ — la función de covarianza exponencial es:

$$\Sigma(s_i, s_j) = \sigma^2 e^{-\phi d_{ij}},$$

donde $d_{ij} = \|s_i - s_j\|$ es la distancia euclidiana entre localizaciones y $\phi > 0$ es el parámetro de rango inverso.

Especificación del Modelo E

El modelo de regresión espacial adoptado tiene la forma aditiva (Nieto Barajas, 2026, §7.2):

$$Y(s) = \mu(s) + \omega(s),$$

donde $\mu(s) = \mathbf{x}(s)' \boldsymbol{\beta}$ es el predictor lineal fijo y $\omega(s)$ es un efecto aleatorio espacial con distribución gaussiana.

En lugar de ajustar el PG completo en JAGS — lo que requeriría muestrear la matriz de covarianzas $n \times n$ en cada iteración — se adopta una aproximación en dos etapas que es computacionalmente eficiente y aprovecha los resultados del Modelo C1:

1. Los efectos aleatorios $\hat{\alpha}_j$ del Modelo C1 se interpretan como realizaciones del proceso gaussiano en las 14 localizaciones con estaciones: $\hat{\alpha}_j \approx \omega(s_j)$.
2. Se modela $\boldsymbol{\omega} = (\omega(s_1), \dots, \omega(s_J))'$ como un PG estacionario e isotrópico con kernel exponencial:

$$\boldsymbol{\omega} \sim \mathcal{N}_J(\mathbf{0}, \Sigma_{\text{obs}}), \quad [\Sigma_{\text{obs}}]_{ij} = e^{-d_{ij}/\rho},$$

con rango $\rho = 0.08^\circ \approx 8.9$ km. A esa distancia la correlación cae a $e^{-1} \approx 0.37$; para estaciones a $d > 3\rho \approx 27$ km la correlación es prácticamente nula (< 0.05).

Kriging bayesiano

La predicción en un polígono sin estación con centroide s_0 se obtiene mediante la distribución predictiva bayesiana (Nieto Barajas, 2026, §7.2):

$$f(y_0 | \mathbf{y}, \mathbf{x}_0) = \int f(y_0 | \mathbf{y}, \theta, \mathbf{x}_0) f(\theta | \mathbf{y}) d\theta,$$

integrada sobre la incertidumbre paramétrica $\theta = (\alpha, \beta, \tau)$. El predictor del efecto espacial en s_0 , condicional en los efectos observados, es:

$$\hat{\omega}(s_0) = \Sigma_{\text{pred,obs}} \Sigma_{\text{obs,obs}}^{-1} \hat{\alpha},$$

donde $[\Sigma_{\text{pred,obs}}]_j = e^{-d_{0j}/\rho}$ es el vector de covarianzas entre el punto nuevo y las 14 estaciones. La predicción final combina la componente fija (covariables en sus valores medios anuales) con la componente espacial:

$$\hat{y}_0 = \hat{\alpha} + \hat{\beta}' \bar{\mathbf{x}} + \hat{\omega}(s_0).$$

Se usan 2,000 muestras MCMC de la distribución final del Modelo C1 para propagar la incertidumbre paramétrica y obtener intervalos de credibilidad para cada polígono.

3.7. Modelo F — Espacio-Temporal Jerárquico

El Modelo F aborda las dos limitaciones principales del Modelo E: (i) los datos faltantes se tratan como parámetros a estimar, no se descartan, y (ii) la estructura espacio-temporal se ajusta de forma conjunta en lugar de proceder en dos pasos. El modelo se ajusta en dos etapas secuenciales.

Etapas 1 — Modelo espacio-temporal con proceso gaussiano

Se construye un panel balanceado 365×14 donde las celdas sin observación quedan como NA en la variable respuesta. JAGS trata esas celdas como variables latentes y las imputa simultáneamente con el resto del muestreo.

La verosimilitud del panel es:

$$\log(\text{PM}_{2.5})_{t,j} \sim \mathcal{N}(\mu_{t,j}, \tau_y^{-1}),$$

$$\mu_{t,j} = \alpha_j + \beta_1 \text{sen}_t + \beta_2 \text{cos}_t + \beta_3 \text{temp}_{t,j} + \beta_4 \text{hr}_{t,j}.$$

Los efectos espaciales de estación $\alpha = (\alpha_1, \dots, \alpha_J)'$ se modelan mediante una Normal Multivariada con estructura de covarianza exponencial en función de la distancia euclidiana en km (proyección UTM 14N):

$$\alpha \sim \mathcal{N}_J(\mathbf{0}, \Sigma_\alpha), \quad [\Sigma_\alpha]_{kl} = \frac{1}{\tau_\alpha} e^{-\phi D_{kl}},$$

donde D_{kl} es la distancia en km entre las estaciones k y l , y $\phi > 0$ es el parámetro de rango estimado desde los datos (a diferencia del Modelo E, donde ρ se fijó en 0.08°).

Las distribuciones iniciales son:

$$\beta_k \sim \mathcal{N}(0, 0.001), \quad \tau_y \sim \text{Ga}(0.1, 0.1), \quad \tau_\alpha \sim \text{Ga}(0.1, 0.1), \quad \phi \sim \text{Uniforme}(0.01, 5).$$

La cadena se corrió con `jags.parallel`: 2 cadenas, 10,000 iteraciones, 3,000 de calentamiento, adelgazamiento `thin` = 4. La salida principal es el array tridimensional de simulaciones de $\log(\text{PM}_{2.5})_{t,j}$, incluyendo los valores imputados.

Etapla 2 — Agregación jerárquica a nivel ZMVM

Las medias posteriores $\hat{y}_{t,j}$ y varianzas posteriores $\hat{v}_{t,j}$ de $\log(\text{PM}_{2.5})_{t,j}$ de la Etapa 1 sirven como datos para un segundo modelo jerárquico que estima la tendencia macro-ambiental diaria de la cuenca:

$$\hat{y}_{t,j} \sim \mathcal{N}(\mu_t^{\text{ZMVM}} + \alpha_j^*, \hat{\tau}_{t,j}), \quad \hat{\tau}_{t,j} = \min\left(\frac{1}{\hat{v}_{t,j}}, 500\right),$$

donde la precisión heredada $\hat{\tau}_{t,j}$ pondera cada estación en función de la información que aportó en la Etapa 1 (estaciones con mayor incertidumbre reciben menor peso). La tendencia macro-ambiental sigue un modelo armónico:

$$\mu_t^{\text{ZMVM}} = \gamma_1 + \gamma_2 \sin t + \gamma_3 \cos t.$$

Los efectos espaciales de estación α_j^* se modelan con una restricción de suma cero para identificabilidad:

$$\alpha_j \sim \mathcal{N}(0, \tau_{\text{est}}^{-1}), \quad \alpha_j^* = \alpha_j - \bar{\alpha},$$

con distribuciones iniciales $\gamma_k \sim \mathcal{N}(0, 0.001)$ y $\tau_{\text{est}} \sim \text{Ga}(0.1, 0.1)$.

La cadena se corrió con `jags.parallel`: 3 cadenas, 25,000 iteraciones, 5,000 de calentamiento, adelgazamiento `thin` = 50. El adelgazamiento agresivo es necesario porque el modelo M-H sobre parámetros continuos genera autocorrelación serial alta. Los parámetros de interés son γ , α^* y μ_t^{ZMVM} ($t = 1, \dots, 365$).

4. Interpretación de resultados

4.1. Comparación de modelos

Cuadro 10: Comparación de los modelos. El DIC es comparable solo dentro de los modelos con la misma variable respuesta y familia distribucional (A, B, C1, D). El Modelo C2 (Gamma) no es comparable con ellos porque la variable respuesta está en escala original; se compara mediante el pseudo- R^2 en escala logarítmica.

Modelo	Estructura	DIC	Pseudo- R^2	σ
A — Normal global	Solo clima y estacionalidad	2 942.6	0.313	0.424
D — Tendencia lat/lon	A + gradiente lineal espacial	2 841.6	0.341	0.416
B — Efectos fijos	A + 14 efectos fijos estación	2 724.2	0.375	0.406
C1 — Jerárquico	A + efectos aleatorios est.	2 723.7	0.375	0.406
C2 — Gamma global	Familia Gamma (DIC no comparable)	—	0.310	—

La jerarquía de modelos es clara:

1. El Modelo A es la línea base; el clima y la estacionalidad explican el 31 % de la variación.
2. El Modelo D mejora sobre A ($\Delta\text{DIC} = -101$), pero mucho menos de lo esperado si el patrón fuera un gradiente lineal: la dependencia espacial es no lineal.
3. Los Modelos B y C1 son claramente superiores ($\Delta\text{DIC} \approx -218$ respecto a A), lo que confirma que la heterogeneidad espacial entre estaciones es el factor explicativo más importante después del clima.
4. El Modelo C1 es marginalmente preferible al B ($\Delta\text{DIC} = 0.5$) y tiene la ventaja adicional de cuantificar la variabilidad entre estaciones mediante σ_α y de permitir predicciones en nuevas estaciones sin datos mediante el proceso gaussiano del Modelo E.

Se elige el **Modelo C1** como el modelo preferido.

4.2. Predicción espacial — Resultados del Modelo E




Figura 15: Efectos espaciales $\hat{\alpha}_j$ por estación usados como puntos de anclaje para el kriging. El rango de variación (-0.27 a $+0.24$) es consistente con $\hat{\sigma}_\alpha = 0.134$ del Modelo C1.




Figura 16: Predicción de PM2.5 promedio para los 141 polígonos del Valle de México (Modelo E, kriging bayesiano con kernel exponencial, $\rho = 0.08^\circ$). Puntos blancos indican la ubicación de las 14 estaciones de monitoreo. El gradiente sur-oriente (más contaminado) hacia el norte (más limpio) es coherente con la topografía de cuenca cerrada y la ventilación predominante del poniente.

Cuadro 11: Municipios y alcaldías más y menos contaminados según el Modelo E. IC: intervalo de credibilidad al 95 %.

Municipio/Alcaldía	Entidad	PM2.5 ($\mu\text{g}/\text{m}^3$)	IC 2.5 %	IC 97.5 %
<i>Zonas más contaminadas</i>				
Tláhuac	CDMX	19.53	18.68	20.43
La Paz	Edomex	19.37	18.53	20.24
Valle de Chalco Solidaridad	Edomex	19.06	18.08	20.12
Tlalnepantla de Baz	Edomex	18.97	18.22	19.80
Xochimilco	CDMX	18.66	17.88	19.47
<i>Zonas menos contaminadas</i>				
Zumpango	Edomex	16.33	15.46	17.23
Temascalapa	Edomex	16.40	15.47	17.34
Hueypoxtla	Edomex	16.65	15.64	17.66
Tecámac	Edomex	16.88	15.93	17.85
Nextlalpan	Edomex	17.02	16.04	18.02

El rango de predicciones va de $16.3 \mu\text{g}/\text{m}^3$ (Zumpango) a $19.5 \mu\text{g}/\text{m}^3$ (Tláhuac), con una desviación estándar entre polígonos de $0.41 \mu\text{g}/\text{m}^3$. Aunque el rango absoluto es moderado ($3.2 \mu\text{g}/\text{m}^3$), las implicaciones para salud son relevantes: la evidencia epidemiológica sugiere que aumentos de $10 \mu\text{g}/\text{m}^3$ en PM2.5 se asocian con incrementos del 7–10 % en mortalidad cardiovascular. Un habitante de Tláhuac está expuesto, en promedio, a 19 % más PM2.5 que uno de Zumpango.

4.3. Predicción temporal — Cuarto trimestre de 2023

El Modelo C1 se usó también para generar predicciones del promedio mensual de PM2.5 sobre las 14 estaciones durante el cuarto trimestre de 2023, evaluando el predictor en las covariables medias de cada mes. La distribución predictiva posterior muestra un patrón claramente ascendente (Tabla 12), consistente con el máximo invernal capturado por los términos de Fourier.

Cuadro 12: Predicción de PM2.5 promedio mensual (14 estaciones) para el cuarto trimestre de 2023. IC: intervalo de credibilidad al 95 %.

Mes	Media ($\mu\text{g}/\text{m}^3$)	IC 2.5 %	IC 97.5 %
Octubre	13.41	12.42	14.45
Noviembre	16.11	14.82	17.46
Diciembre	17.29	16.08	18.57

Diciembre de 2023 ($17.3 \mu\text{g}/\text{m}^3$) supera la guía anual de la OMS ($15 \mu\text{g}/\text{m}^3$), reflejando el deterioro de la calidad del aire en temporada de bajas temperaturas y alta inversión térmica. Los intervalos de credibilidad se amplían de octubre a diciembre (de 2.0 a $2.5 \mu\text{g}/\text{m}^3$), lo que refleja la mayor variabilidad interdiaria propia del invierno.

¿Qué factores explican la variación temporal de PM2.5? Los términos de Fourier (estacionalidad anual) son los predictores más fuertes: un ciclo con amplitud ≈ 0.40 log-unidades captura el máximo invernal (febrero-marzo) y el mínimo de verano (junio-julio). La temperatura tiene un efecto positivo y significativo (+10 % de PM2.5 por cada desviación estándar adicional, ≈ 2.1 °C), consistente con condiciones de menor dilución y mayor inversión térmica en días cálidos. La humedad relativa también tiene un efecto positivo y significativo (+4.7 %), detectado una vez que se controla por estación.

¿Existen diferencias sistemáticas entre municipios no explicadas por clima? Sí, y son grandes. La inclusión de efectos por estación reduce el DIC en 218 puntos (de 2,942.6 a 2,724.2), evidencia contundente de heterogeneidad espacial. Las diferencias entre la estación más contaminada (Santiago Acahualtepec, +29 %) y la más limpia (Biblioteca, Tizayuca, -24 %) no son atribuibles al clima: son características estructurales del territorio.

¿Es mejor el modelo jerárquico que los efectos fijos? Con el tamaño de muestra disponible (≈ 186 obs/estación), ambos son prácticamente equivalentes en ajuste ($\Delta\text{DIC} = 0.5$ puntos). La ventaja del Modelo C1 es doble: cuantifica explícitamente la variabilidad entre estaciones ($\hat{\sigma}_\alpha = 0.134$) y proporciona los efectos espaciales $\hat{\alpha}_j$ como puntos de anclaje para el kriging bayesiano del Modelo E, algo imposible con efectos fijos no estructurados.

¿Podemos predecir en zonas sin sensores? El Modelo E produce predicciones plausibles para los 141 polígonos, coherentes con la topografía: las zonas de cuenca baja (Tláhuac, La Paz, Valle de Chalco) acumulan más contaminantes, mientras que las zonas al norte del valle (Zumpango, Temascalapa) presentan mejor calidad del aire. La principal limitación es que el parámetro de rango $\rho = 0.08^\circ$ está fijo (no se estima desde los datos), lo que introduce un supuesto que no se verifica formalmente con 14 estaciones. Los intervalos de credibilidad en municipios sin estaciones cercanas son 30–50 % más amplios que en los municipios con cobertura directa, reflejando correctamente la mayor incertidumbre de la interpolación en zonas alejadas de sensores.

4.4. Resultados del Modelo F




Figura 17: Diagnósticos MCMC del Modelo F Etapa 1 para β_1 (coeficiente del término sen_t). Las dos cadenas mezclan correctamente y la ACF decae dentro de los primeros lags.




Figura 18: Diagnósticos MCMC del Modelo F Etapa 2 para γ_1 (intercepto global de la ZMVM). Se usaron 3 cadenas con adelgazamiento $\text{thin} = 50$; las tres trayectorias convergen a la misma región.

Diagnóstico de convergencia.

Imputación de datos faltantes. La Etapa 1 imputa de forma coherente los valores no observados de cada estación. El modelo asigna mayor incertidumbre en las fechas sin observación, lo que se refleja en intervalos de credibilidad más amplios en esas celdas.

Modelo F Etapa 1: Validacion de imputacion MCMC

Línea: media posterior | Banda: IC 95% | Puntos: observados




Figura 19: Validación de la imputación MCMC (Etapa 1) para tres estaciones con distinta densidad de datos: Hospital General de México (52 obs, escenario crítico), Santiago Acahualtepec (189 obs, escenario típico) y Benito Juárez (236 obs, escenario óptimo). La banda gris es el intervalo de credibilidad al 95%; los puntos grises son los valores observados.

Tendencia macro-ambiental de la ZMVM. La Etapa 2 produce la serie de tiempo μ_t^{ZMVM} que resume la tendencia diaria de la calidad del aire en la cuenca, libre del ruido local de cada estación.




Figura 20: Serie de tiempo macro-ambiental de la ZMVM estimada por el Modelo F Etapa 2. La línea sólida es la media posterior de $\exp(\mu_t^{ZMVM})$ en escala $\mu\text{g}/\text{m}^3$; la banda roja es el intervalo de credibilidad al 95 %. El patrón estacional es claro: máximo invernal (enero–marzo), mínimo estival (junio–agosto) y repunte en el cuarto trimestre.

Efectos espaciales de estación. Los coeficientes α_j^* (suma cero) cuantifican la desviación de cada estación respecto a la tendencia de la cuenca, controlando por estacionalidad.




Figura 21: Efectos espaciales de estación del Modelo F Etapa 2 (α_j^* , restricción de suma cero). Los valores positivos indican estaciones sistemáticamente más contaminadas que la media de la cuenca; los negativos, más limpias.

Comparación con los modelos previos. El Modelo F extiende al E en tres aspectos clave: (i) el parámetro de rango espacial ϕ se estima desde los datos (no se fija a priori), lo que permite que los propios datos determinen el alcance de la dependencia espacial; (ii) la imputación de los 2,617 valores observados se complementa con la estimación de los $365 \times 14 - 2,617 = 2,493$ valores faltantes como variables latentes, aprovechando la estructura espacio-temporal; (iii) la Etapa 2 produce una síntesis coherente de la calidad del aire de la ZMVM que propaga la incertidumbre de la Etapa 1 mediante las precisiones heredadas $\hat{\tau}_{t,j}$.

5. Referencias

1. SINAICA — Sistema Nacional de Información de la Calidad del Aire, Instituto Nacional de Ecología y Cambio Climático. <https://sinaica.inecc.gob.mx/data.php?tipo=V>. Consultado en 2025.
2. Nieto Barajas, L. E. (2026). *Notas de Regresión Avanzada*, Temas 2–7. Departamento de Estadística, ITAM.
3. de Finetti, B. (1937). La prévision: ses lois logiques, ses sources subjectives. *Annales de l'Institut Henri Poincaré*, 7, 1–68.
4. Gelfand, A. E., & Schliep, E. M. (2016). Spatial statistics and Gaussian processes: A beautiful marriage. *Statistical Science*, 31(1), 109–130.

5. Lunn, D., Jackson, C., Best, N., Thomas, A., & Spiegelhalter, D. (2013). *The BUGS Book*. CRC Press.
6. GADM Database of Global Administrative Areas, Level 2 (Municipios/Alcaldías). <https://gadm.org>.
7. OMS (2021). *Global Air Quality Guidelines*. World Health Organization.
8. R Core Team (2025). *R: A Language and Environment for Statistical Computing*. R Foundation for Statistical Computing, Vienna, Austria.
9. Plummer, M. (2003). JAGS: A program for analysis of Bayesian graphical models using Gibbs sampling. *Proceedings of the 3rd International Workshop on Distributed Statistical Computing*. Vienna, Austria.

A. Código R

El código completo está disponible en los siguientes archivos del repositorio:

- `scripts/descarga_masiva_valle.R` — descarga de datos SINAICA
- `scripts/limpieza_valle_mexico.v2.R` — procesamiento y filtrado
- `scripts/eda_valle_mexico.v2.R` — análisis exploratorio
- `scripts/modelos_A_B_C1_D.v2_profesor.R` — Modelos A, B, C1, C2, D
- `scripts/modelo_E_valle.v2_profesor.R` — Modelo E (PG espacial)
- `scripts/jags_modelo_A_valle.txt` — especificación JAGS Modelo A
- `scripts/jags_modelo_B_valle.txt` — especificación JAGS Modelo B
- `scripts/jags_modelo_C1_valle.txt` — especificación JAGS Modelo C1
- `scripts/jags_modelo_C2_gamma_valle.txt` — especificación JAGS Modelo C2
- `scripts/jags_modelo_D_valle.txt` — especificación JAGS Modelo D

A continuación se incluye la especificación JAGS del modelo preferido (C1):

Listing 1: Especificación JAGS del Modelo C1 (Jerárquico Normal).

```
model {
  for (i in 1:n) {
    logy[i] ~ dnorm(mu[i], tau)
    mu[i] <- alpha + alphaj[est[i]]
              + beta[1]*temp[i] + beta[2]*hr[i]
              + beta[3]*sen_t[i] + beta[4]*cos_t[i]
    yf1[i] ~ dnorm(mu[i], tau)
  }
}
```

```

for (j in 1:J) {
  alphaj[j] ~ dnorm(0, tau.alphaj)
}
alpha ~ dnorm(0, 0.001)
for (k in 1:4) { beta[k] ~ dnorm(0, 0.001) }
tau      ~ dgamma(0.001, 0.001)
tau.alphaj ~ dgamma(0.001, 0.001)
sigma    <- 1 / sqrt(tau)
sigma.alphaj <- 1 / sqrt(tau.alphaj)
}

```

Nota sobre notación: En JAGS, el segundo argumento de `dnorm` es la *precisión* $\tau = 1/\sigma^2$ (no la varianza). Así, `dnorm(0, 0.001)` corresponde a $\mathcal{N}(0, 1000)$ en notación estándar de varianza, es decir, una distribución inicial prácticamente plana sobre los coeficientes.