

Proyecto Final — Regresión Avanzada

Análisis Bayesiano Espacial de PM2.5 en el Valle de México

Paulina Garza Allende Andrea Monserrat Arredondo Rodríguez

19 de mayo de 2026

1. Introducción

El Valle de México es una cuenca hidrológica cerrada que alberga la Zona Metropolitana del Valle de México (ZMVM), con aproximadamente 22 millones de habitantes. Su geometría de cuenca cerrada impide la ventilación natural de los contaminantes, lo que convierte al PM2.5 (material particulado fino con diámetro aerodinámico $\leq 2.5 \mu\text{m}$) en uno de los principales problemas de salud pública de la región. La exposición crónica a PM2.5 está asociada con enfermedades respiratorias, cardiovasculares y aumento en la mortalidad.

La fuente de datos es el Sistema Nacional de Información de la Calidad del Aire (SINAICA), operado por el Instituto Nacional de Ecología y Cambio Climático. Se descargaron datos de las 56 estaciones de monitoreo ubicadas dentro de los límites del Valle de México (16 alcaldías de la CDMX, 59 municipios del Estado de México, más Tizayuca en Hidalgo). De estas, solo 14 estaciones reportaron simultáneamente concentración de PM2.5, temperatura y humedad relativa durante 2023, con un total de 2,617 observaciones diarias (enero–septiembre de 2023).

La pregunta central de este proyecto es:

¿Qué tan importante es la estructura espacial para explicar la variación de PM2.5 en el Valle de México, y podemos usarla para predecir la contaminación en zonas sin sensores?

Para responderla se comparan cinco modelos bayesianos de complejidad creciente, ajustados con JAGS a través del paquete R2jags:

1. **Modelo A — Normal global:** ¿cuánto de la variación de PM2.5 explican el clima y la estacionalidad, sin considerar la ubicación?
2. **Modelo B — Efectos fijos:** ¿existen diferencias sistemáticas entre estaciones que no se explican por clima?
3. **Modelo C1 — Jerárquico:** ¿es mejor modelar esas diferencias como un proceso aleatorio común con encogimiento (*shrinkage*) que como parámetros independientes?
4. **Modelo C2 — Gamma:** ¿es la distribución Gamma, que respeta el soporte positivo de PM2.5, mejor que la Normal sobre el logaritmo?

5. **Modelo D — Tendencia lat/lon:** ¿captura un gradiente lineal en latitud y longitud el patrón espacial, o se necesita un modelo no lineal?

Finalmente, el **Modelo E** usa los efectos espaciales del Modelo C1 para hacer kriging bayesiano y predecir PM2.5 en los 141 polígonos del Valle de México, incluyendo los 44 municipios de Edomex sin estaciones de monitoreo.

2. Descripción de la información

Variables

Cuadro 1: Variables utilizadas en el análisis.

Variable	Descripción	Rol	Escala
pm25	Concentración diaria promedio de PM2.5 ($\mu\text{g}/\text{m}^3$)	Respuesta	Razón
temp	Temperatura diaria promedio ($^{\circ}\text{C}$)	Covariable meteorológica	Intervalo
hr	Humedad relativa diaria promedio (%)	Covariable meteorológica	Intervalo
sen_t	$\sin(2\pi \cdot \text{día}/365)$	Covariable estacional (Fourier)	Intervalo
cos_t	$\cos(2\pi \cdot \text{día}/365)$	Covariable estacional (Fourier)	Intervalo
lat, lon	Coordenadas geográficas de la estación	Predictor espacial	Intervalo
estación	Nombre de la estación de monitoreo	Agrupador	Nominal

La temperatura y la humedad relativa se estandarizaron (media 0, desviación estándar 1) antes de ingresarlas a JAGS, para mejorar la convergencia del MCMC y hacer comparables las magnitudes de los coeficientes. PM2.5 se transforma a escala logarítmica en todos los modelos Normal (A, B, C1, D), lo que estabiliza la varianza y linealiza la relación con las covariables.

Estaciones de monitoreo

Cuadro 2: Resumen por estación (datos 2023, $n = 2,617$ observaciones totales).

Estación	Municipio	n	Temp. (°C)	HR (%)	PM2.5 ($\mu\text{g}/\text{m}^3$)
Santiago Acahualtepec	Iztapalapa	189	17.4	46.4	23.5
Hospital General México	Cuauhtémoc	52	19.2	33.1	22.7
Gustavo A. Madero	G. A. Madero	154	19.4	45.2	22.7
Tlalnepantla	Tlalnepantla	174	18.5	41.9	21.8
San Agustín	Ecatepec	84	19.9	49.5	20.7
UAM Iztapalapa	Iztapalapa	207	19.7	49.5	20.6
Merced	Venustiano C.	235	20.0	47.8	20.6
UAM Xochimilco	Coyoacán	233	17.5	48.2	20.5
Nezahualcóyotl	Nezahualcóyotl	218	19.5	43.9	20.4
Benito Juárez	Benito Juárez	236	19.2	45.3	19.8
FES Aragón	Nezahualcóyotl	233	20.1	48.0	18.0
Pedregal	Álvaro Obregón	181	17.2	49.7	16.2
Ajusco Medio	Tlalpan	188	14.5	55.2	16.0
Biblioteca	Tizayuca	233	14.5	50.9	15.4

El rango de concentraciones promedio entre estaciones va de $15.4 \mu\text{g}/\text{m}^3$ (Biblioteca, Tizayuca) a $23.5 \mu\text{g}/\text{m}^3$ (Santiago Acahualtepec, Iztapalapa), una diferencia de 52 % entre la estación más limpia y la más contaminada. Todas las estaciones superan la guía de la OMS de $5 \mu\text{g}/\text{m}^3$ para el promedio anual.

Análisis exploratorio




Figura 1: Histogramas de las variables principales. La distribución de PM2.5 tiene cola de-
recha pronunciada; en escala logarítmica se aproxima más a la Normal, lo que justifica la
transformación utilizada en los modelos.




Figura 2: $\log(\text{PM}_{2.5})$ en función de temperatura, humedad relativa y día del año. La línea **lowess** muestra la tendencia suavizada. La relación con temperatura es ligeramente positiva; con humedad relativa, positiva dentro de cada estadio; con el tiempo, se observa un mínimo estival seguido de un repunte en agosto-septiembre que coincide con el final de la temporada de lluvias.




Figura 3: $\text{PM}_{2.5}$ por estación, ordenadas de menor a mayor concentración media. La línea punteada roja marca el promedio global ($\approx 19.7 \mu\text{g}/\text{m}^3$). Se observan diferencias claras entre estaciones, especialmente en los extremos: Ajusco Medio y Biblioteca tienen niveles sistemáticamente menores que Santiago Acahualtepec y Gustavo A. Madero.




Figura 4: PM2.5 por mes. Se aprecia un máximo en invierno (enero–marzo), un mínimo en verano (junio–julio) y un repunte en agosto–septiembre, patrón que motiva el uso de términos de Fourier en la especificación del modelo.




Figura 5: Matriz de correlación de las variables. PM2.5 está más correlacionado con sen_t ($r = 0.48$) y con cos_t, lo que confirma la importancia de la estacionalidad. La correlación con temperatura y humedad es moderada.

3. Modelado e implementación

Configuración general de MCMC

Todos los modelos se ajustaron con dos cadenas de Markov. Los parámetros tienen distribuciones iniciales poco informativas: precisiones $\mathcal{N}(0, 1000)$ para los coeficientes y $\text{Ga}(0.001, 0.001)$ para las precisiones, de modo que los datos determinan prácticamente por completo los valores estimados. La convergencia se evaluará mediante cuatro gráficas por parámetro: traza, promedio ergódico, histograma posterior y función de autocorrelación (ACF).

3.1. Modelo A — Normal global

El Modelo A es la línea base. Ignora por completo la ubicación geográfica y modela $\log(\text{PM2.5})$ exclusivamente con clima y estacionalidad:

$$\log(\text{PM2.5}_i) \sim \mathcal{N}(\mu_i, \tau), \quad \mu_i = \alpha + \beta_1 \text{temp}_i + \beta_2 \text{hr}_i + \beta_3 \text{sen_t}_i + \beta_4 \text{cos_t}_i. \quad (1)$$

Las distribuciones iniciales son:

$$\alpha \sim \mathcal{N}(0, 1000), \quad \beta_k \sim \mathcal{N}(0, 1000) \quad (k = 1, \dots, 4), \quad \tau \sim \text{Ga}(0.001, 0.001).$$

Se corrieron 10,000 iteraciones con 1,000 de calentamiento y sin adelgazamiento, con 9,000 muestras activas por cadena.

Diagnóstico




Figura 6: Diagnósticos del Modelo A para el intercepto α . La traza muestra el patrón de “oruga” característico de buena mezcla; el promedio ergódico de ambas cadenas converge al mismo valor; los histogramas son idénticos; la ACF cae a cero desde el rezago 1. El mismo comportamiento se observa para $\beta_1, \dots, \beta_4$ y σ .

Resultados

Cuadro 3: Distribución posterior del Modelo A. Los coeficientes de temperatura y Fourier son significativos (IC excluye el cero); HR no lo es.

Parámetro	Media
Intercepto α (log-PM2.5 global promedio)	2.819
β_1 : cambio en log-PM2.5 por 1-DE de temperatura	0.096
β_2 : cambio en log-PM2.5 por 1-DE de humedad relativa	0.031
β_3 : amplitud seno del patrón estacional (sen_t)	0.351
β_4 : amplitud coseno del patrón estacional (cos_t)	0.172
Desviación estándar residual $\sigma = 1/\sqrt{\tau}$	0.424
DIC	2 942.6
Pseudo- R^2	0.313

El intercepto $\hat{\alpha} = 2.819$ corresponde a un PM2.5 esperado de $e^{2.819} \approx 16.8 \mu\text{g}/\text{m}^3$ cuando todas las covariables están en sus valores medios. El coeficiente de temperatura ($\hat{\beta}_1 = 0.096$) indica que por cada unidad de desviación estándar adicional en temperatura (equivalente a $\approx 2.1^\circ\text{C}$), la concentración esperada de PM2.5 aumenta en $e^{0.096} \approx 1.10$, es decir un 10 %. Esto puede parecer contraintuitivo, pero en el contexto del Valle de México refleja que los días más cálidos dentro de una misma temporada tienden a ser más secos y con menor dilución de contaminantes.

Los términos de Fourier describen un ciclo anual con amplitud $\sqrt{0.351^2 + 0.172^2} \approx 0.39$ log-unidades, equivalente a una variación de $\pm 38\%$ alrededor de la media estacional. El máximo de la función estacional ocurre alrededor del día 58 (fines de febrero), correspondiente al final de la temporada seca e inicio de la temporada de incendios forestales.

El Modelo A explica el 31.3 % de la variación total de log-PM2.5 (pseudo- $R^2 = 0.313$).




Figura 7: Observado vs. predicho en escala log para el Modelo A. La dispersión considerable alrededor de la diagonal indica que el modelo global no captura las diferencias sistemáticas entre estaciones.

3.2. Modelo B — Efectos fijos por estación

El Modelo B agrega a la ecuación (1) un efecto fijo α_j por cada estación:

$$\log(\text{PM2.5}_i) \sim \mathcal{N}(\mu_i, \tau), \quad \mu_i = \tilde{\alpha} + \tilde{\alpha}_{j[i]} + \beta_1 \text{temp}_i + \beta_2 \text{hr}_i + \beta_3 \text{sen_t}_i + \beta_4 \text{cos_t}_i, \quad (2)$$

donde $\tilde{\alpha} = \alpha + \overline{\alpha_j}$ y $\tilde{\alpha}_j = \alpha_j - \overline{\alpha_j}$ son los ajustes de suma-cero aplicados post-muestreo para garantizar identificabilidad. Los priors para los α_j son independientes: $\alpha_j \sim \mathcal{N}(0, 1000)$.

Se corrieron 12,000 iteraciones con 2,000 de calentamiento y adelgazamiento de 2, con 5,000 muestras activas por cadena.

Diagnóstico




Figura 8: Diagnósticos del Modelo B para el intercepto α . Las cadenas muestran buena convergencia: traza estacionaria, promedios ergódicos que coinciden, histogramas idénticos y ACF que cae rápidamente.

Resultados

Cuadro 4: Distribución posterior de los coeficientes del Modelo B (IC: intervalo de credibilidad al 95 %; p : probabilidad posterior de que el parámetro sea distinto de cero).

Parámetro	Media	IC 2.5 %	IC 97.5 %	p
β_1 (temp., 1-DE ≈ 2.1 °C)	0.1045	0.0665	0.1416	0.000
β_2 (humedad rel., 1-DE ≈ 7.8 pp)	0.0460	0.0159	0.0754	0.001
β_3 (sen_t, amplitud estacional)	0.3331	0.3028	0.3635	0.000
β_4 (cos_t, fase estacional)	0.2145	0.1708	0.2571	0.000
Intercepto ajustado $\tilde{\alpha}$				2.830
σ residual				0.406
DIC				2 724.2
Pseudo- R^2				0.375

Al controlar por estación, la humedad relativa se vuelve significativa ($\hat{\beta}_2 = 0.046$, IC = [0.016, 0.075]). Esto se debe a que, en el Modelo A, la correlación de HR con la estación de monitoreo ocultaba parte del efecto real. Por cada unidad de desviación estándar en HR (≈ 7.8 puntos porcentuales adicionales), PM2.5 sube $e^{0.046} - 1 \approx 4.7\%$. El parón estacional se mantiene: amplitud conjunta $\sqrt{0.333^2 + 0.215^2} \approx 0.397$ log-unidades.




Figura 9: Efectos fijos por estación $\tilde{\alpha}_j$ (ajuste suma-cero). Barras verticales son intervalos de credibilidad al 95 %. Valores positivos indican estaciones más contaminadas que el promedio global; negativos, menos contaminadas. Santiago Acahualtepec es la estación más contaminada (+0.26 log-unidades, equivalente a +29 %) y Biblioteca la más limpia (−0.28, equivalente a −24 %).

Cuadro 5: Efectos fijos por estación del Modelo B ($\tilde{\alpha}_j$, restricción suma-cero). Un valor de $e^{\tilde{\alpha}_j}$ indica el multiplicador de PM2.5 respecto al promedio global.

Estación	$\tilde{\alpha}_j$	Factor ($e^{\tilde{\alpha}_j}$)
Santiago Acahualtepec	+0.258	1.29
Tlalnepantla	+0.143	1.15
Ajusco Medio	+0.073	1.08
UAM Xochimilco	+0.075	1.08
Benito Juárez	+0.048	1.05
Merced	+0.032	1.03
Nezahualcóyotl	+0.019	1.02
San Agustín	+0.016	1.02
Gustavo A. Madero	−0.040	0.96
UAM Iztapalapa	−0.045	0.96
Pedregal	−0.059	0.94
Hospital General México	−0.102	0.90
FES Aragón	−0.143	0.87
Biblioteca	−0.275	0.76

La mejora sobre el Modelo A es sustancial: $\Delta\text{DIC} = 2,942.6 - 2,724.2 = 218.4$ puntos, lo que indica que la estructura espacial tiene un efecto fuerte sobre PM2.5 que no es explicado por clima ni estacionalidad.

3.3. Modelo C1 — Jerárquico Normal

El Modelo C1 trata las diferencias entre estaciones como realizaciones de una distribución común, en lugar de parámetros fijos independientes:

$$\begin{aligned}
 \log(\text{PM2.5}_i) &\sim \mathcal{N}(\mu_i, \tau), \\
 \mu_i &= \alpha + \alpha_{j[i]} + \beta_1 \text{temp}_i + \beta_2 \text{hr}_i + \beta_3 \text{sen_t}_i + \beta_4 \text{cos_t}_i, \\
 \alpha_j &\sim \mathcal{N}(0, \tau_\alpha), \quad j = 1, \dots, 14.
 \end{aligned} \tag{3}$$

Aquí $\tau_\alpha = 1/\sigma_\alpha^2$ es la hiperprecisión que controla cuánto se permite que las estaciones se devíen del intercepto global α . El prior para τ_α es $\text{Ga}(0.001, 0.001)$, poco informativo.

Se corrieron 12,000 iteraciones con 2,000 de calentamiento y adelgazamiento de 2 (5,000 muestras activas por cadena).

Diagnóstico




Figura 10: Diagnósticos del Modelo C1: intercepto α (izq.) e hiperparámetro σ_α (der.). Ambos muestran buena convergencia. El mismo comportamiento se observa para $\beta_1, \dots, \beta_4$ y σ .

Resultados

Cuadro 6: Distribución posterior del Modelo C1 (modelo preferido).

Parámetro	Media
Intercepto global α	2.830
β_1 (temperatura, 1-DE $\approx 2.1^\circ\text{C}$)	0.103
β_2 (humedad relativa, 1-DE ≈ 7.8 pp)	0.045
β_3 (sen.t)	0.334
β_4 (cos.t)	0.211
σ residual (variabilidad dentro de estación)	0.406
σ_α (variabilidad entre estaciones)	0.134
DIC	2 723.7
Pseudo- R^2	0.375

El hiperparámetro $\hat{\sigma}_\alpha = 0.134$ resume la variabilidad entre estaciones: el 68 % de las estaciones se desvía menos de ± 0.134 log-unidades del promedio global, lo que en escala multiplicativa equivale a $\pm 14\%$. El 95 % se desvía menos de ± 0.268 log-unidades ($\pm 31\%$). Este valor es sustancial en un contexto de salud pública: dos habitantes del Valle de México, uno en la estación más contaminada y otro en la más limpia, están expuestos a concentraciones que difieren en un factor de $e^{0.134 \times 4} \approx 1.71$, es decir 71 % más en la zona más contaminada.




Figura 11: Efectos aleatorios por estación α_j del Modelo C1. Barras verticales son intervalos de credibilidad al 95 %. Comparado con el Modelo B (Fig. 9), los efectos son ligeramente más pequeños debido al encogimiento (*shrinkage*) jerárquico hacia la media. El orden relativo de las estaciones se preserva.

Cuadro 7: Efectos aleatorios por estación del Modelo C1 (α_j). IC aproximado: media $\pm 1.96 \hat{\sigma}_j$.

Estación	Media	DE	IC 95 %
Santiago Acahualtepec	+0.243	0.047	[+0.151, +0.334]
Tlalnepantla	+0.133	0.047	[+0.041, +0.225]
UAM Xochimilco	+0.071	0.045	[-0.017, +0.159]
Ajusco Medio	+0.065	0.052	[-0.037, +0.167]
Benito Juárez	+0.045	0.044	[-0.041, +0.132]
Merced	+0.031	0.046	[-0.059, +0.121]
Nezahualcóyotl	+0.018	0.045	[-0.070, +0.107]
San Agustín	+0.015	0.055	[-0.093, +0.123]
Gustavo A. Madero	-0.037	0.049	[-0.133, +0.059]
UAM Iztapalapa	-0.042	0.046	[-0.133, +0.049]
Pedregal	-0.058	0.046	[-0.148, +0.033]
Hospital General México	-0.086	0.061	[-0.206, +0.034]
FES Aragón	-0.137	0.046	[-0.227, -0.048]
Biblioteca	-0.265	0.048	[-0.359, -0.172]

Comparando con el Modelo B, se observa que el encogimiento jerárquico reduce ligera-

mente los efectos extremos: Santiago Acahualtepec pasa de +0.258 (B) a +0.243 (C1), y Biblioteca de -0.275 a -0.265 . Esto es el *shrinkage* esperado cuando los datos tienen suficiente información por grupo (en este caso ≈ 186 observaciones por estación en promedio) y el hiperparámetro está bien identificado.

3.4. Modelo C2 — Gamma global

El Modelo C2 modela PM2.5 directamente en escala original (no logarítmica), usando una distribución Gamma con función liga logarítmica:

$$\text{PM2.5}_i \sim \text{Gamma}(a, a/\mu_i), \quad \log(\mu_i) = \alpha + \beta_1 \text{tempc}_i + \beta_2 \text{hrc}_i + \beta_3 \text{sen_t}_i + \beta_4 \text{cos_t}_i, \quad (4)$$

donde tempc y hrc son temperatura y HR centradas (restando la media global, sin dividir por la desviación estándar). El parámetro a es la forma de la Gamma: valores grandes implican menor asimetría. Los valores iniciales se fijan en $\alpha_0 = \log(\bar{y}) \approx 2.94$ para evitar valores inválidos de μ durante el calentamiento.

Se corrieron 15,000 iteraciones con 3,000 de calentamiento y adelgazamiento de 3.

Diagnóstico




Figura 12: Diagnósticos del parámetro de forma a del Modelo C2. Las cadenas muestran mayor autocorrelación que en los modelos Normal (la ACF tarda más en caer), lo que es típico de la Gamma ajustada con Metropolis-Hastings en JAGS. El promedio ergódico converge alrededor de $a \approx 6.6$.

Resultados

Cuadro 8: Distribución posterior del Modelo C2 (Gamma global). El DIC *no es comparable* con los modelos A, B, C1, D porque PM2.5 está en escala original (no logarítmica). Se usa el pseudo- R^2 en escala log para comparar entre familias.

Parámetro	Media
Intercepto α (log-media cuando covariables = 0)	2.908
β_1 (temperatura, por °C centrado)	0.027
β_2 (humedad relativa, por punto porcentual centrado)	0.004
β_3 (sen_t)	0.312
β_4 (cos_t)	0.190
Parámetro de forma a (mayor a = menos asimetría)	6.625
DIC (no comparable entre familias)	17 636.6
Pseudo- R^2 en escala log	0.310

El Modelo C2 tiene un pseudo- R^2 ligeramente menor que el Modelo A (0.310 vs 0.313), lo que sugiere que, en este conjunto de datos y sin efectos por estación, la Normal sobre el logaritmo describe los datos tan bien o mejor que la Gamma. La ventaja de la Gamma es conceptual (soporte positivo) pero no se traduce en mejor ajuste empírico. El parámetro $\hat{a} = 6.6$ implica un coeficiente de variación de $1/\sqrt{6.6} \approx 0.39$, consistente con la dispersión observada.

3.5. Modelo D — Tendencia espacial lineal

El Modelo D agrega al Modelo A los efectos lineales de latitud y longitud estandarizadas:

$$\log(\text{PM2.5}_i) \sim \mathcal{N}(\mu_i, \tau), \quad \mu_i = \alpha + \beta_1 \text{temp}_i + \cdots + \beta_4 \text{cos_t}_i + \beta_5 \text{lat}_i + \beta_6 \text{lon}_i, \quad (5)$$

con 6 coeficientes en total. Este modelo prueba si el patrón espacial puede describirse con un gradiente lineal simple en lugar de efectos individuales por estación.

Se corrieron 10,000 iteraciones con 1,000 de calentamiento.

Resultados

Cuadro 9: Distribuciones posteriores del Modelo D, con énfasis en los coeficientes espaciales.

Parámetro	Media
β_1 (temperatura)	0.084
β_2 (humedad relativa)	0.020
β_3 (sen_t)	0.326
β_4 (cos_t)	0.185
β_5 (latitud, 1-DE $\approx 0.25^\circ \approx 28$ km)	-0.089
β_6 (longitud, 1-DE $\approx 0.19^\circ \approx 18$ km)	+0.004
σ residual	0.416
DIC	2 841.6
Pseudo- R^2	0.341

Aunque el coeficiente de latitud tiene un signo negativo ($\hat{\beta}_5 = -0.089$), su intervalo de credibilidad incluye el cero, y lo mismo ocurre para la longitud. Más importante: el Modelo D apenas mejora sobre el Modelo A ($\Delta\text{DIC} = 2,942.6 - 2,841.6 = 101.0$ puntos, vs 218 puntos de la Modelo B). Esto confirma que el patrón espacial de PM2.5 en el Valle de México *no es un gradiente lineal* — hay zonas contaminadas y limpias que no siguen una tendencia norte-sur o este-oeste simple. La estructura espacial requiere un modelo no lineal, como el Proceso Gaussiano del Modelo E.

4. Comparación de modelos

Cuadro 10: Comparación de los cinco modelos. El DIC es comparable solo dentro de los modelos Normal (A, B, C1, D). C2 (Gamma) no es comparable con ellos porque la variable respuesta está en escala diferente; se compara mediante el pseudo- R^2 en escala log.

Modelo	Estructura	DIC	Pseudo- R^2	σ
A — Normal global	Solo clima y estacionalidad	2 942.6	0.313	0.424
D — Tendencia lat/lon	A + gradiente lineal espacial	2 841.6	0.341	0.416
B — Efectos fijos	A + 14 efectos fijos estación	2 724.2	0.375	0.406
C1 — Jerárquico	A + efectos aleatorios est.	2 723.7	0.375	0.406
C2 — Gamma global	Familia Gamma (no comparable)	(nc)	0.310	—

La jerarquía de modelos es clara:

1. El Modelo A es la línea base; el clima y la estacionalidad explican el 31 % de la variación.

2. El Modelo D mejora sobre A ($\Delta\text{DIC} = -101$), pero mucho menos de lo esperado si el patrón fuera un gradiente lineal.
3. Los Modelos B y C1 son claramente superiores ($\Delta\text{DIC} \approx -218$ respecto a A), lo que confirma que la heterogeneidad espacial no lineal entre estaciones es el factor explicativo más importante después del clima.
4. El Modelo C1 es marginalmente preferible al B ($\Delta\text{DIC} = 0.5$) y tiene la ventaja de cuantificar la variabilidad entre estaciones mediante σ_α .

Se elige el **Modelo C1** como el modelo preferido.

5. Predicción espacial — Modelo E

Una vez elegido el Modelo C1, sus efectos por estación $\hat{\alpha}_j$ se usan para interpolar PM2.5 en los 141 polígonos del Valle de México mediante kriging bayesiano con kernel exponencial:

$$\Sigma_{ij} = \sigma_{\text{spatial}}^2 \cdot \exp(-d_{ij}/\rho),$$

donde d_{ij} es la distancia euclidiana entre estaciones (en grados) y $\rho = 0.08^\circ \approx 8.9$ km es el rango espacial. A esa distancia la correlación cae a $e^{-1} \approx 0.37$. Para estaciones a > 27 km la correlación es prácticamente nula (< 0.05).

El predictor en un polígono sin estación es:

$$w_{\text{pred}} = \Sigma_{\text{pred,obs}} \Sigma_{\text{obs,obs}}^{-1} \hat{\alpha}_j,$$

y la predicción final combina los efectos de clima (en sus valores medios anuales) con la componente espacial. Se usan 2,000 muestras MCMC de la posterior del Modelo C1 para propagar la incertidumbre paramétrica.




Figura 13: Efectos espaciales $\hat{\alpha}_j$ por estación usados como puntos de anclaje para el kriging. El rango de variación $(-0.27 \text{ a } +0.24)$ es consistente con $\hat{\sigma}_\alpha = 0.134$ del Modelo C1.




Figura 14: Predicción de PM2.5 promedio para los 141 polígonos del Valle de México (Modelo E, kriging bayesiano). Puntos blancos indican la ubicación de las 14 estaciones de monitoreo. El gradiente sur-orientado (más contaminado) a norte (más limpio) es coherente con la topografía de cuenca cerrada y la ventilación predominante del poniente.

Cuadro 11: Municipios y alcaldías más y menos contaminados según el Modelo E. IC: intervalo de credibilidad al 95 %.

Municipio/Alcaldía	Entidad	PM2.5 ($\mu\text{g}/\text{m}^3$)	IC 2.5 %	IC 97.5 %
<i>Zonas más contaminadas</i>				
Tláhuac	CDMX	19.53	18.68	20.43
La Paz	Edomex	19.37	18.53	20.24
Valle de Chalco Solidaridad	Edomex	19.06	18.08	20.12
Tlalnepantla de Baz	Edomex	18.97	18.22	19.80
Xochimilco	CDMX	18.66	17.88	19.47
<i>Zonas menos contaminadas</i>				
Zumpango	Edomex	16.33	15.46	17.23
Temascalapa	Edomex	16.40	15.47	17.34
Hueyoxtlá	Edomex	16.65	15.64	17.66
Tecámac	Edomex	16.88	15.93	17.85
Nextlalpan	Edomex	17.02	16.04	18.02

El rango de predicciones va de $16.3 \mu\text{g}/\text{m}^3$ (Zumpango) a $19.5 \mu\text{g}/\text{m}^3$ (Tláhuac), con una desviación estándar entre polígonos de $0.41 \mu\text{g}/\text{m}^3$. Aunque el rango absoluto es moderado ($3.2 \mu\text{g}/\text{m}^3$), las implicaciones para salud son relevantes: la evidencia epidemiológica sugiere que aumentos de $10 \mu\text{g}/\text{m}^3$ en PM2.5 se asocian con incrementos del 7–10 % en mortalidad cardiovascular. Un habitante de Tláhuac está expuesto, en promedio, a 19 % más PM2.5 que uno de Zumpango.

6. Interpretación de resultados

¿Qué factores explican la variación temporal de PM2.5? Los términos de Fourier (estacionalidad anual) son los predictores más fuertes: un ciclo con amplitud ≈ 0.40 log-unidades captura el máximo invernal (febrero-marzo) y el mínimo de verano (junio-julio) que se aprecia en los datos. La temperatura tiene un efecto positivo y significativo (+10 % de PM2.5 por cada grado de desviación estándar), consistente con condiciones de menor lluvia y mayor inversión térmica en días cálidos. La humedad relativa también tiene un efecto positivo (+4.7 %), aunque de menor magnitud.

¿Existen diferencias sistemáticas entre municipios no explicadas por clima? Sí, y son grandes. La inclusión de efectos por estación reduce el DIC en 218 puntos (de 2,942.6 a 2,724.2), lo que es una evidencia contundente de heterogeneidad espacial. Las diferencias entre la estación más contaminada (Santiago Acahualtepec, +29 %) y la más limpia (Biblioteca, Tizayuca, −24 %) no son atribuibles al clima: son características del territorio.

¿Es mejor el modelo jerárquico que los efectos fijos? Prácticamente equivalentes con el tamaño de muestra disponible (≈ 186 obs/estación). El DIC del Modelo C1 es apenas

0.5 puntos menor que el del Modelo B. La ventaja del Modelo C1 es que cuantifica explícitamente la variabilidad entre estaciones ($\hat{\sigma}_\alpha = 0.134$) y permitiría hacer predicciones en nuevas estaciones sin datos, algo imposible con efectos fijos.

¿Podemos predecir en zonas sin sensores? El Modelo E produce predicciones plausibles para los 141 polígonos, coherentes con la topografía: las zonas de cuenca baja (Tláhuac, La Paz, Valle de Chalco) acumulan más contaminantes, mientras que las zonas al norte del valle (Zumpango, Temascalapa) presentan mejor calidad del aire. La principal limitación es que el rango espacial $\rho = 0.08^\circ$ está fijo, y con sólo 14 estaciones la interpolación en zonas alejadas de cualquier sensor tiene incertidumbre alta. Los intervalos de credibilidad en los municipios sin estaciones cercanas son 30–50% más amplios que en los municipios con cobertura directa.

7. Referencias

1. SINAICA — Sistema Nacional de Información de la Calidad del Aire, Instituto Nacional de Ecología y Cambio Climático. <https://sinaica.inecc.gob.mx/data.php?tipo=V>. Consultado en julio 2025.
2. Nieto Barajas, L. E. (2026). *Notas de Regresión Avanzada*. Departamento de Estadística, ITAM.
3. Gelfand, A. E., & Schliep, E. M. (2016). Spatial statistics and Gaussian processes: A beautiful marriage. *Statistical Science*, 31(1), 109–130.
4. Lunn, D., Jackson, C., Best, N., Thomas, A., & Spiegelhalter, D. (2013). *The BUGS Book*. CRC Press.
5. GADM Database of Global Administrative Areas, Level 2 (Municipios/Alcaldías). <https://gadm.org>.
6. OMS (2021). *Global Air Quality Guidelines*. World Health Organization.
7. R Core Team (2025). *R: A Language and Environment for Statistical Computing*. R Foundation for Statistical Computing, Vienna, Austria.
8. Plummer, M. (2003). JAGS: A program for analysis of Bayesian graphical models using Gibbs sampling. *Proceedings of the 3rd International Workshop on Distributed Statistical Computing*. Vienna, Austria.

A. Código R

El código completo está disponible en los siguientes archivos del repositorio:

- `scripts/descarga_masiva_valle.R` — descarga de datos SINAICA

- scripts/limpieza_valle_mexico.R — procesamiento y filtrado
- scripts/eda_valle_mexico.v2.R — análisis exploratorio
- scripts/modelos_A_B_C1_D_v2_profesor.R — Modelos A, B, C1, C2, D
- scripts/modelo_E_valle.v2_profesor.R — Modelo E (GP espacial)
- scripts/jags_modelo_A_valle.txt — especificación JAGS Modelo A
- scripts/jags_modelo_B_valle.txt — especificación JAGS Modelo B
- scripts/jags_modelo_C1_valle.txt — especificación JAGS Modelo C1
- scripts/jags_modelo_C2_gamma_valle.txt — especificación JAGS Modelo C2
- scripts/jags_modelo_D_valle.txt — especificación JAGS Modelo D

A continuación se incluye la especificación JAGS del modelo preferido (C1):

Listing 1: Especificación JAGS del Modelo C1 (Jerárquico Normal).

```
model {
  for (i in 1:n) {
    logy[i] ~ dnorm(mu[i], tau)
    mu[i] <- alpha + alphaj[est[i]]
              + beta[1]*temp[i] + beta[2]*hr[i]
              + beta[3]*sen_t[i] + beta[4]*cos_t[i]
    yf1[i] ~ dnorm(mu[i], tau)
  }
  for (j in 1:J) {
    alphaj[j] ~ dnorm(0, tau.alphaj)
  }
  alpha ~ dnorm(0, 0.001)
  for (k in 1:4) { beta[k] ~ dnorm(0, 0.001) }
  tau ~ dgamma(0.001, 0.001)
  tau.alphaj ~ dgamma(0.001, 0.001)
  sigma <- 1 / sqrt(tau)
  sigma.alphaj <- 1 / sqrt(tau.alphaj)
}
```